

介入下予測モデルの性能はどう検証するか — 人工打ち切り+逆確率重み付けで反実仮想の較正・判別・Brierを測る(方法論・Epidemiology2024)

出典 Keogh RH, Van Geloven N. Prediction Under Interventions: Evaluation of Counterfactual Performance Using Longitudinal Observational Data. Epidemiology. 2024;35(3):329-339. DOI: 10.1097/EDE.0000000000001713

掲載誌 Epidemiology(2024)

原著 doi.org/10.1097/EDE.0000000000001713(本文PDFは別途)

原題 Prediction Under Interventions: Evaluation of Counterfactual Performance Using Longitudinal Observational Data



聖路加ICUでの実践への示唆

聖路加ICUでの実践

病棟プロトコルへの落とし込み

- **今日の診療は変わらない。**これは統計方法論の論文であり、特定の治療を推奨するものではない。ただし「予測モデルをどう評価して院内に入れるか」という判断の枠組みは変わる
- **当院で使っている予測は、ほぼすべて「観察下の予測」。**APACHE II・SOFA・JIPADの標準化死亡比・RRS起動基準・退室後死亡予測モデルは、いずれも「その集団で実際に行われた治療の混ざり合い」のもとでの転帰を予測している。「この患者を今ICUに入れたら」「今挿管したら／しなかったら」という問いには、原理的に答えていない
- **臨床が本当に欲しいのは介入下予測のほう。**ICU入室の可否、挿管のタイミング、RRT導入、移植・補助循環の適応、DNAR相談の切り出し — いずれも「AとBの治療方針それぞれのもとで、この人の3か月後はどうなるか」を並べて提示できて初めて意思決定支援になる
- **院内でAI・予測モデルの導入を検討するときの質問が1つ増える：**提示されたc-index・校正曲線は「観察された治療のもとでの性能」か、「特定の治療戦略のもとでの性能」か。後者を謳うモデルなのに前者の指標しか出ていなければ、その数字は意思決定支援の裏づけにならない
- **「その治療を実際に受けた人だけで検証しました」は要注意。**本論文が示すとおり、この素朴な部分集合アプローチは選択バイアスで性能を過大にも過小にも見せる。院内の内部検証・外部検証の設計を見るときに使えるチェックポイント
- **JIPADのような縦断レジストリとの相性。**介入下予測の検証には、予測因子だけでなく交絡調整に必要な変数と「治療の開始・中止の時点」が縦断的に要る。将来この種の検証を当院データで行うなら、収集項目の設計段階から効いてくる



この論文の位置づけ (Known / Unknown / What's new)

補足

リサーチ・イン・コンテキスト

- **Known**: 患者背景で条件づけた「特定の治療方針のもとでの絶対リスク」(介入下予測／反実仮想予測／因果予測)は、患者への説明にも希少資源の配分にも必要な情報である。通常の予測モデルはこれを与えない。観察データから介入下予測を作る方法(周辺構造モデル、クローニング・打ち切り・重み付け、g-formula など)はここ数年で複数提案されてきた
- **Unknown**: 作った介入下予測モデルの**性能をどう検証するか**が空白だった。検証とは「モデルの推定リスク」と「観察された転帰」を突き合わせる作業だが、介入下予測の場合、検証データの一部の人はその治療戦略に従っていないため、突き合わせるべき観察値がそもそも存在しない。あるスコーピングレビューでは、介入下予測を扱った13研究のうち**性能評価をしていたのは0件**で、この分野で最も差し迫った問題と名指しされていた。先行研究は点治療＋二値アウトカムに限られ(Coston ら、Pajouheshnia ら、Boyer らが縦断戦略まで形式化)、**time-to-event アウトカムは未カバー**だった
- **What's new**: time-to-event アウトカムに対する**反実仮想的性能指標の初の一般的な一式**。人工打ち切り(artificial censoring)と逆確率重み付けで「全員がその治療戦略に従ったかのような検証データ」を作り、そのうえで較正(平均較正・十分位較正曲線)、判別(c-index・累積／動的AUCt)、全体的予測誤差(Brierスコア・scaled Brier)を推定する。シミュレーションで「性能が良いときは良いと、悪いときは悪いと」正しく判定できることを示し、米国肝移植待機リスト43,190人での応用で実運用可能性を示した



全体要約

要旨

ひとことで 観察データしかない状況で「もし全員がこの治療方針に従っていたら、このモデルの予測はどれだけ当たっていたか」を測る方法を作った論文。**人工打ち切りで戦略から逸脱した時点以降を切り落とし、逆確率重み付けでその選択バイアスを補正した「疑似検証データ」**の上で、**較正・判別・Brier**を計算する。

- 介入下予測(prediction under interventions) = 「この患者がこの治療戦略に従ったとき、時点 t までにイベントが起きる確率」の推定値。標準的な予測モデルが与える「実際に観察された治療の混合のもとでの確率」とは別物
- 検証の難しさは反実仮定の根本問題そのもの。ある患者が移植を受けた後、その人が移植を受けなかった場合の転帰は原理的に観察できない
- 提案手法は2段階。①検証データで、対象の治療戦略から逸脱した時点で追跡を人工的に打ち切る(時刻0で逸脱する人もいる)②残った追跡時間を、打ち切られなかった確率の逆数(IPACW: inverse probability of artificial censoring weights)で重み付けする
- 重みは時間依存共変量の履歴に依存する。通常の脱落・研究終了による打ち切り(IPCW)とは別に推定し、両者を掛け合わせた合成重みを使う
- 較正は重み付きKaplan-Meierで反実仮想的な転帰割合を推定し、観察／期待比(O/E比)と十分位ごとの較正プロットで評価。判別は比較可能ペアに時間依存重みを掛けたc-index・AUCt。Brierスコアも同様に重み付き推定量を提案
- 妥当性は3つの因果仮定(条件つき逐次交換可能性・一致性・正直性)と重みモデルの正しい特定に依存する
- シミュレーション(シナリオ1〜3)で、提案法は真の性能をほぼ不偏に再現。対照的に、素朴な「実際にその戦略に従った人だけを見る」部分集合アプローチは、無治療戦略の較正を誤り、c-index・AUCtを過大評価し、scaled Brierを負に見せた(=モデルが無情報モデル以下という誤ったシグナル)
- 仮定を意図的に破ったシナリオでは提案法にもバイアスが出るが、加法ハザードモデルのシナリオで **58/64(90%)** の比較において部分集合アプローチよりバイアスが小さかった
- 応用: SRTRの肝移植待機者43,190人。3年時点の平均推定リスクは無移植戦略54.1%・移植戦略11.7%。c-indexは0.749対0.561、AUCtは0.781対0.552、scaled Brierは66.8%対12.0%、O/E比は0.983対1.060
- 限界として著者自身が、重みモデルへの依存、正直性違反の回避のため十分な人数が従う戦略に限るべきこと、構造モデルを使う方法より効率が落ちること、内部検証(交差検証・ブートストラップ)への拡張とサンプルサイズ設計が未解決であることを挙げている

詳細

1. まず前提 — 「介入下予測」とは何か(初めての人にも)🍀

要旨

5分で背景を掴む 集中治療で使う予測モデルの大半は「この患者が死ぬ確率」を出す。だが臨床の問いはいつも「この患者を、こう治療したらどうなるか」である。この違いを埋めるのが介入下予測であり、本論文はその予測が当たっているかを測る方法の話である。以下、必要な用語を順に定義する。

通常の予測モデルが答えている問い。 APACHE II、SOFA、あるいは機械学習の敗血症予測モデル。これらが推定しているのは「開発データの集団で実際に行われていた診療のもとでの、転帰の分布」である。開発データの中には、早期に昇圧薬を入れられた人も入れられなかった人も、腹臥位にした人もしなかった人も混ざっている。したがってモデルの出す「死亡確率30%」は、**当時の診療パターンが今後も同じように続くという前提の下での30%**にすぎない。診療が変われば予測も外れる。

介入下予測が答えている問い。 介入下予測(prediction under interventions)は、患者背景 X を条件に、「もしこの人が治療戦略 a に従ったら、時点 τ までにイベントが起きる確率はいくつか」を推定する。数式では、戦略 a のもとでの反実仮想イベント時刻を T^a とし、

- $R^a(\tau|X) = \Pr(T^a \leq \tau | X)$

を推定する。同義語として「因果予測(causal prediction)」「反実仮想予測(counterfactual prediction)」「仮想的介入下の予測」があり、本論文は "prediction under interventions" で統一している。

なぜ集中治療で必要か。 2つの用途が挙げられている。①患者・家族が複数の選択肢のリスクとベネフィットを天秤にかけられるようにすること。②ドナー臓器のように**供給が制約された資源の配分**を決めること。後者は「この人に肝臓を今渡したら3年生存はどうか／渡さなかったらどうか」の両方を全待機者について並べないと決められない。

治療戦略(treatment strategy)の型。 本論文が扱うのは「決定論的で静的な(deterministic static)戦略」で、時刻0以降の治療を $a = (a_0, a_1, a_2, \dots)$ と指定するもの。具体例としてシミュレーションと応用で使われるのは次の2つだけである。

記号	戦略の名前	内容
$a = 0$	never treated (無治療)	時刻0以降、一度も治療を開始しない
$a = 1$	always treated (常時治療)	時刻0で治療を開始し、その後も継続する

先行研究の多くは「無治療リスク」だけを対象にしていた(治療されなかった場合のベースラインリスクを出して、そこから治療効果を差し引くという発想)。本論文はこれを一般の戦略に広げている。dynamic regime (「乳酸が4を超えたら開始」のような状態依存の戦略)への拡張も容易だと考察で述べている。

「反実仮想の根本問題」。ある患者に治療を行い転帰を観察したら、その患者が治療を受けなかった場合の転帰は永遠に観察できない。だから介入下予測は、開発時も検証時もこの壁にぶつかる。RCTからなら介入下予測を作れる（実際そうした例はある）が、RCTは元々この目的で設計されておらず、組入基準が厳しく、症例数が小さく、追跡も短い。そこで電子カルテ・コホート・レジストリといった**縦断観察データ**が主戦場になる。

時間依存交絡 (time-dependent confounding)。観察データを使う以上、治療を受けた人と受けなかった人は背景が違う。しかも縦断データではこれが厄介な形をとる。たとえば「腎機能が悪化した人ほど透析を導入され、透析導入がその後の腎機能に影響し、腎機能はまた次の透析継続判断に効く」。このように、**ある変数が(1)治療の開始・継続を決め、(2)転帰を予測し、かつ(3)過去の治療の影響を受ける**とき、それは時間依存交絡因子である。通常の回帰でこの変数を単純に共変量に入れると、治療効果の一部を吸い取ってしまい、逆に入れないと交絡が残る。これを解くのが逆確率重み付けを使う周辺構造モデル (marginal structural model) や、クローニング・打ち切り・重み付け (cloning-censoring-weighting) といった因果推論の道具立てで、本論文の付録1で概観されている。

予測モデルの「性能」を測る3本柱。検証 (validation) とは、モデルの推定リスクと検証データの観察転帰を突き合わせる作業である。time-to-event の場合、標準的には次の3つを見る。

指標	何を見ているか	集中治療での実感
較正 (calibration)	予測確率の絶対値が合っているか。 「30%と言った群で本当に30%起きるか」	意思決定に直結。ここがずれていると数字を患者に示せない
判別 (discrimination)	予測が患者の順位づけをできているか。 c-index、時点 τ の累積／動的AUC _t	資源配分 (誰を先にするか) に効く
全体的予測誤差	較正と判別を合わせた総合。Brierスコア (平均二乗誤差のtime-to-event版)	scaled Brier は「無情報モデルより何%マシか」。負なら無情報モデル以下

較正はさらに2段階ある。**平均較正**は集団全体の平均推定リスクと実際の転帰割合を比べる (観察／期待比＝O/E比、1.0が理想)。**十分位較正**は予測リスクで10等分 (G=10) し、群ごとの平均推定リスクを横軸、実際の転帰割合を縦軸にプロットする (対角線に乗るのが理想)。

そして本論文の中心問題。検証データが観察データである以上、そこに含まれる人の一部は評価したい治療戦略に従っていない。「もし全員が移植を受けていたら」の予測と突き合わせるべき「全員が移植を受けたときの転帰」は、データのどこにも書かれていない。**推定リスクに対応する観察値が存在しない**ため、既存の検証手法がそのまま使えない。これが本論文の出発点である。

素朴な回避策と、その落とし穴。これまで time-to-event の場面で使われてきた場当たり的な方法が「**部分集合アプローチ (subset approach)**」である。すなわち、「無治療戦略のもとでの予測を検証したいなら、実

際に一度も治療を受けなかった人だけを取り出して、その人たちの転帰と比べる」。直感的だが、これは**選択バイアス**に晒される。実際に無治療で通した人は、たまたま状態が安定していた人（治療を要さなかった人）に偏っているからである。本論文はこのバイアスの向きと大きさをシミュレーションで具体的に示す。

提案手法の直感。本論文は、部分集合アプローチと同じく「戦略に従っている間のデータだけを使う」が、そこに**重み**を掛ける。従っていた人が「従わなかった同類の人の分も代表する」ように重み付けすれば、集団全体が戦略に従った世界を再現できる。この考え方は治療効果推定でおなじみのIPWそのものであり、本論文の新しさは、それを**性能指標（較正・判別・Brier）の推定量として書き下した点**にある。

2. 背景と目的

著者らは冒頭で、意思決定に必要なのは「患者背景で条件づけた、治療選択ごとの絶対リスク」だと述べる。標準的な予測モデルは、開発集団の観察された転帰分布を狙うため、この情報を与えない。

観察データから介入下予測を作る方法は近年増えている。周辺構造モデルの応用、g-formula、あるいは試験由来の治療効果推定値と観察データ由来の無治療リスクを組み合わせる方法などである。しかし**検証の側は置き去りになっていた**。Lin らのスコーピングレビューでは、介入下予測を扱った13研究のうち性能評価を行っていたものは0件で、Sperrin らはこれを本分野で最も差し迫った問題と述べている。

先行の理論的仕事としては、点治療+二値アウトカムの設定で Coston ら・Pajouheshnia らが反実仮想的評価を扱い、Boyer らがこれを形式化して縦断的治療戦略へ拡張した。だが time-to-event アウトカムはどれもカバーしていない。

本論文の目的は、**time-to-event アウトカムに対する反実仮想的性能指標の初の一般的な一式**を提示すること。想定するのは、縦断観察データを検証データとして使い、かつ「ある治療レジメンを時間を通じて維持する」タイプの戦略を評価する場面である。

3. 方法(Methods)

- **デザイン**: 統計方法論の提案。推定対象(estimand)の定義 → 推定量の導出 → シミュレーション研究による評価 → 実データ応用、という構成
- **推定対象**: $R^a(\tau|X) = \Pr(T^a \leq \tau | X)$ 。予測時点で利用可能な予測因子 X を条件とした、戦略 a のもとでの時点 τ までのイベントリスク。本論文は「この推定を行えるモデルが既に存在する」ことを前提とし、モデル開発ではなく**検証**に集中する
- **主要アウトカム**(=評価対象の性能指標): 反実仮想的な較正(O/E比・十分位較正プロット)、判別(c-index・累積／動的AUCt)、全体的予測誤差(Brierスコア・scaled Brier)
- **解析**: 人工打ち切り+逆確率重み付け。以下に分解する

3-1. 検証データに求められる構造

外部検証データ(n人)を想定する。要件は次のとおりで、ここが実務上のハードルになる。

要件	内容
母集団	モデルを使う予定の集団を反映していること (targeted validation の考え方)
データ形式	観察研究データで縦断構造。各人が定期的な時点 $k = 0, 1, 2, \dots$ で観察される (例: 外来受診・検査日)。イベント時刻・打ち切り時刻は連続時間で観察
変数	予測因子 X に加え、 交絡調整に十分な変数一式 (時間依存交絡を含む) を含むこと
治療情報	各時点の治療状態 A_k (開始・中止のタイミング) が分かること
初期条件	全員が時刻0の直前は未治療 ($A_{\{0-\}} = 0$)。時刻0以降は任意の治療パターンをとってよい

記号は次のとおり。 T =イベント時刻、 C =通常の打ち切り時刻、観察される追跡終了は $T^* = \min(T, C)$ 、イベント指示子は D 。時間依存共変量は L_k 、治療状態は A_k 。予測因子 X は、ベースライン交絡因子 L_0 の全部または一部 (L_0^* と表記) に加えて、**転帰を予測するが治療状態には影響しない変数 P** から成る ($X = \{L_0^*, P\}$)。

図の解説

Figure 1. 検証データの構造を表す有向非巡回グラフ(DAG)。3段構成で、上段に時間依存共変量 $L_0 \rightarrow L_1 \rightarrow L_2 \rightarrow L_3 \rightarrow L_4$ が左から右へ矢印で連なり、中段に治療 $A_0 \rightarrow A_1 \rightarrow A_2 \rightarrow A_3 \rightarrow A_4$ 、下段に離散時間アウトカム $Y_1 \rightarrow Y_2 \rightarrow Y_3 \rightarrow Y_4 \rightarrow Y_5$ が並ぶ。各 L_k からは同時点の A_k へ斜め下向きの矢印が伸び (共変量が治療開始・継続を決める)、各 A_k からは次の $L_{\{k+1\}}$ へ斜め上向きの矢印が伸びる (治療が将来の共変量を変える)。 L_k と A_k の双方から下段の Y へも矢印が入り、共変量が転帰を予測することを示す。左端の P (ベースラインの予後変数) からは、下段の Y_1 から Y_5 すべてに向かって扇状に長い矢印が伸びるが、 A へは矢印が出ていない (治療に影響しない予後因子であることを表す)。 Y_k は「時点 $k-1$ と k の間にイベントが起きたか」の指示子で、各受診の間にさらに細かい時間区間を挟んでいけば連続時間の設定に近づく。この図の要点は、 L_k が (1) 治療の開始・継続を決め、(2) 転帰を予測し、(3) 過去の治療の影響を受けるという三条件を満たす時間依存交絡因子であること。原図・無改変

この検証データの各人 i に対し、介入下予測モデルを当てはめて推定リスク $R^a(\tau|X_i)$ を得る。ここまですが準備である。

3-2. 第1段階:人工打ち切り(artificial censoring)

観察された検証データから、「全員がその戦略に従った世界」を模した修正版検証データを作る。第1段階では、**その人が戦略から逸脱した時点で追跡を打ち切る**。

- 「常時治療 ($a = 1$)」戦略の評価では、時刻0で治療を始めなかった人はその場(時刻0)で打ち切られ、途中で中断した人は中断時点で打ち切られる
- 「無治療 ($a = 0$)」戦略の評価では、治療を開始した時点で打ち切られる。最後まで無治療だった人は打ち切られない

修正版検証データを V^a と書く。この操作は、予測が得られるどんな戦略にも適用できる。ただし条件があり、**その戦略に従う人が検証データ内に十分な規模で存在する必要がある**。

3-3. 第2段階:逆確率重み付け(IPACW)

人工打ち切りだけでは、残った人は「その戦略を続けられた人」に偏っている(=部分集合アプローチと同じ選択バイアス)。そこで、時刻 t における重みを「**その時点まで人工打ち切りされなかった確率の逆数**」とする。条件づけるのは、交絡調整に必要な共変量履歴(DAGでいう L の履歴)である。

式(2)で定義される inverse probability of artificial censoring weights(IPACW) $G^{-1}_a(t|L)$ は、各時点 k について「時点 k まで人工打ち切りされずに来た条件つき確率」の積の逆数であり、これは同時に「共変量履歴と過去の治療のもとで、時点 k に戦略どおりの治療 a_k をとる確率」の積の逆数と書ける。

△ 注意

重みモデルは検証データで当て直す 重みを推定するモデルは**検証データ**でフィットしなければならない。開発データでフィットした重みモデルと混同してはいけない。開発集団と検証集団では治療の割り当てパターンが違いうからである。

さらに、通常の右側打ち切り(脱落・研究終了)に対する重み $G^{-1}_c(t)$ がある。本論文は簡単のため通常の打ち切りは共変量に依存しないと仮定するが($G_c(t) = P(C > t)$)、共変量依存の打ち切りへの拡張も可能だと述べている。人工打ち切りと通常の打ち切りが独立と仮定して、式(3)で合成重みを定義する。

- $G^{-1}_{[a,c]}(t|L) = G^{-1}_a(t|L) \times G^{-1}_c(t)$

3-4. 妥当性が依存する仮定

提案手法と以下の性能推定量の妥当性は、次の因果仮定に依存する(すべての時点 k について成立が必要)。

仮定	内容	破れる典型例
条件つき逐次交換可能性	共変量履歴・予後変数・過去の治療・生存で条件づけられ、その時点の治療割り当ては反実仮想転帰と独立	未測定交絡(記録に残らない主治医の印象・患者の希望など)
一貫性	$A = a$ のとき観察転帰 T は反実仮想転帰 T^a に一致する	「治療」の定義が曖昧で、実際には複数の異なる介入が混在している
正値性	共変量履歴と過去の治療で条件づけたとき、戦略ごとの治療をとる確率が0でも1でもない	特定の重症度では全員が必ず治療される(または誰も治療されない)

加えて、**重みを推定するモデルが正しく特定されていることが要る**。判別指標については、正値性の仮定をさらに拡張し、対象戦略のもとで比較可能ペアの数がゼロにならないことが必要になる。

3-5. 反実仮想的な較正

平均較正は、モデルの平均推定リスクと、戦略 a のもとでの反実仮想的な転帰割合を比べる。前者は個々の推定リスクの単純平均。後者は V^a に重み $G^{-1}_a(t|L)$ を掛けた重み付きKaplan–Meier法で推定する。両者の比が観察／期待比(O/E比)で、1.0が理想。

十分位較正では、推定リスクを等サイズの G 群(例: $G=10$)に分け、群ごとに同じ重み付きKaplan–Meier法で反実仮想的な転帰割合を推定し、群平均推定リスクに対してプロットする。対角線に乗れば良好。

3-6. 反実仮想的な判別(c-index・AUCt)

c-index やAUCtは、2人の患者ペアを比べ、生存時間が短かったほうにモデルが高いリスクを割り当てていたかを見る。打ち切りがあると、一方が他方のイベント前に打ち切られたペアは「比較可能でない」ため、標準的な設定では重み付き推定量が既に開発されている(Uno、Gerds、Blanche らの仕事)。

本論文はこれを拡張し、**重みが時間依存共変量を取り込めるようにした**。推定対象は、戦略 a のもとで反実仮想イベント時刻が短かった側にモデルがより高いリスクを与えていた確率(時点 t で打ち切った条件つき)。推定量(式(4))は、 V^a における比較可能ペアについて「 i の推定リスク $>$ j の推定リスク」の指示子を、ペアの重みで加重平均する形をとる。ペアの重みは、 i と j それぞれの合成重み $G^{-1}_{\{a,c\}}$ の積である(i 側は左極限をとる)。

累積／動的AUCt についての対応する結果は付録2に置かれている。

3-7. 反実仮想的なBrierスコア

Brierスコアは平均二乗誤差を time-to-event に拡張したもので、推定対象は「戦略 a のもとで時点 t までにイベントが起きたか(0/1)と推定リスクの差の二乗」の期待値。 V^a では時点 t 前に打ち切られていない人だけが寄与するので、寄与する観察に「打ち切られずに残っている確率」の逆数を掛ける(式(5))。重みは2種類に分かれる。

対象	重み
時点 t 以前にイベントを観察された人	そのイベント時点での合成重みの逆数
時点 t 時点でイベントなく残っている人	時点 t での合成重みの逆数

scaled Brier score($1 - \text{Brier} / \text{帰無モデルのBrier}$)も定義される。帰無モデルとは「全員に集団平均リスクを割り当てるモデル」で、そのBrierも同じ式(5)で、推定リスクを反実仮想的転帰割合に置き換えて推定する。scaled Brier が負であれば、そのモデルは**全員に平均リスクを割り当てるだけのモデルより悪い**ことを意味する。

4. シミュレーション研究

4-1. 設計

1回のシミュレーション実行ごとに次を行う。

手順	内容
①	開発データセットを生成し、無治療戦略・常時治療戦略それぞれの介入下予測モデルを導出
②	縦断観察型の検証データセットを生成し、①のモデルで両戦略下の予測を得る
③	検証データ上で、提案する反実仮想的性能評価と、場当たり的な部分集合アプローチの両方を適用
④	③の推定値を、「完全な検証データ」から得た性能と比較する。完全な検証データとは、全員がその戦略に従うように生成した仮想データで、2つの戦略それぞれに1つずつ用意される(=真の性能)

主要な3シナリオは次のとおり。

シナリオ	設定	期待される答え
1	開発データと検証データを同じモデルから生成(予測モデルは正しく特定されている)	性能は良好。良好と正しく判定できるか
2	開発データのベースラインハザードが検証データより高い(ハザードモデルの形は同じ)	リスクを過大推定しているはず。それを検出できるか
3	開発・検証は同じモデルだが、検証データでの予測に 誤差を含む L_0 (L_0^* と表記)を使う	判別と全体性能が落ちるはず。それを検出できるか

シナリオ2・3は「性能が悪いはずの状況」を意図的に作っており、**手法が悪さを悪いと言えるか**を試すための設計である。3つの主要シナリオではいずれも一致性・正直性・条件つき交換可能性・重みモデルの正しい特定がすべて成立している。さらに**これらの仮定を1つずつ破る追加3シナリオ**を用意し、手法がどこでどう壊れるかを検討している。データ生成機構は加法ハザードモデル版と比例ハザードモデル版の両方を用意した。

図2～4に示されるのは加法ハザードモデル版の結果で、時間地平線は $\tau = 5$ 。比例ハザード版と追加シナリオは補遺(eFigures 8–13、eTables 7–11)に置かれている。

4-2. シナリオ1の結果(正しく特定されたモデル)

図の解説

Figure 2. シミュレーション結果：加法ハザードモデル・シナリオ1。2列4行のパネル構成で、左列が無治療(never treated)戦略、右列が常時治療(always treated)戦略。3種類の推定が色と記号で区別され、黒丸＝完全な検証データから得た真の性能、オレンジ四角＝部分集合アプローチ、緑三角＝提案する人工打ち切り+逆確率重み付けによる反実仮想的推定である。最上段は較正プロットで、横軸が推定リスクの十分位ごとの平均予測リスク、縦軸が観察された転帰割合、灰色の破線が対角線(完全較正)。左パネルでは緑三角の系列がおおむね対角線上に乗るのに対し、オレンジ四角の系列は対角線の上方に大きく外れて走り、予測0.6付近で観察0.64、予測0.78付近で観察0.91まで持ち上がっている。右パネルではオレンジも緑も対角線上に重なる。2段目は時点5で打ち切ったc-indexの箱ひげ図で、左パネルは黒(中央値約0.54)と緑(同)がほぼ一致する一方、オレンジは約0.575と明らかに上方にずれる。右パネルでは3者とも約0.555～0.56で一致。3段目は時点5の累積／動的AUC_tで、左パネルは黒と緑が約0.57で一致し、オレンジは約0.63と上方に外れる。右パネルは3者一致(約0.58)。最下段はscaled Brierスコア(%)で、左パネルは黒と緑が約+1.5%で正の値をとるのに対し、オレンジの箱は中央値約-3%と負の領域に落ち、下ひげは-10%以下に伸びる。右パネルは3者とも約+1.5～2%で一致する。原図・無改変

読み取れることは明快である。

- 提案法(緑)は、較正プロットで正しく対角線上に位置し、O/E比の平均は1.0にごく近い
- 部分集合アプローチ(オレンジ)は、**無治療戦略について較正不良を誤って示唆**した
- 判別も同様で、提案法はc-index・AUCtを正しく推定したが、部分集合アプローチは無治療戦略でこれらを**過大評価**した
- scaled Brierでは、部分集合アプローチは無治療戦略で**平均して負の値**を出した。これは「開発したモデルは、検証データの全員に平均リスクを割り当てるだけの帰無モデルより劣る」というシグナルであり、真の scaled Brier が正であることと矛盾する
- 常時治療戦略については、提案法も部分集合アプローチも不偏だった(右列で3者が重なる)

つまり、部分集合アプローチのバイアスは戦略によって現れ方が違う。この設定では、無治療戦略で目立ち、常時治療戦略では目立たなかった。バイアスの大きさと向きの議論は補遺(eAppendix 4)にある。

4-3. シナリオ2の結果(開発データのベースラインハザードが高い)

図の解説

Figure 2の様式と同一のFigure 3。シミュレーション結果：加法ハザードモデル・シナリオ2。最上段の較正プロットでは、左(無治療)・右(常時治療)とも、緑三角の系列が灰色破線の対角線より明確に下方に位置する。左パネルでは予測0.75付近で観察0.60、予測0.85付近で観察0.79という具合に、予測が観察を上回っている。オレンジ四角の系列は緑より上に位置し、より対角線に近く見える(=過大推定を過小に見積もっている)。右パネルでは緑とオレンジがほぼ重なり、いずれも対角線の下方を走る。2段目のc-indexと3段目のAUCtはシナリオ1と同一の分布で、左パネルでオレンジのみが上方に外れる構図も変わらない。最下段のscaled Brierでは、左パネルの黒と緑がともに中央値約-5%と負の領域にあるのに対し、オレンジのみが約+2%と正の領域に浮き上がっている。右パネルは3者とも約-7~-8%で一致し負である。原図・無改変

- 反実仮想的な較正指標は、**推定リスクが観察転帰割合より高いこと(過大推定)を正しく検出**した。較正曲線が対角線の下に来て、O/E比は1未満、scaled Brier は両戦略とも負になる
- 部分集合アプローチのO/E比は高すぎ、無治療戦略では**scaled Brierを誤って正と示唆**した(=ダメなモデルを合格にしてしまう)
- 判別はベースラインハザードの変化に影響されないため、c-index・AUCtの結果はシナリオ1と同一

4-4. シナリオ3の結果(誤差を含む予測因子)

図の解説

Figure 2・3と同一様式のFigure 4。シミュレーション結果：加法ハザードモデル・シナリオ3。最上段左（無治療）の較正プロットでは、緑三角の系列が対角線をまたぐ緩いS字を描き、低い予測（0.55付近）では観察が予測より高く（0.63付近）、高い予測（0.80付近）では観察が予測より低い（0.76付近）という、予測が両端で行き過ぎている（too extreme）パターンを示す。オレンジ四角の系列は対角線の上方に大きく外れて走る。右パネル（常時治療）では緑とオレンジが接近し、いずれも対角線のわずかに上方を通る。2段目のc-indexでは、左パネルで黒と緑がともに中央値約0.535と、シナリオ1より低い水準で一致し、オレンジのみ約0.56と上方に外れる。右パネルは3者とも約0.54で一致。3段目のAUCtも同様に、左パネルは黒と緑が約0.555で一致し、オレンジは約0.60。右パネルは3者一致（約0.56）。最下段のscaled Brierでは、左パネルの黒と緑がともに0%付近であるのに対し、オレンジは中央値約-5%と負に落ちる。右パネルは3者とも0%付近で一致する。原図・無改変

- 誤差を含む L_0 を使ったことによる **c-index・AUCt・scaled Brier の低下を、反実仮想的指標は正しく捉えた**
- 較正プロットは「推定リスクが極端すぎる」こと、すなわち非常に高い推定リスクと非常に低い推定リスクに対応する実際の転帰割合が平均寄りに寄ることを正しく示した
- ただし患者全体で平均すればリスクは依然としてよく較正されており、O/E比は1付近にとどまる。**平均較正だけ見ていると、この種の劣化を見逃す**
- 部分集合アプローチは、無治療戦略でまたもO/E比と判別指標を過大評価した

その他の性能指標についてのシナリオ1～3の結果（eFigures 5-7）も、上記の観察を裏づけている。

4-5. 仮定を破ったときの挙動

因果仮定を意図的に破った追加シナリオでは、予想どおり反実仮想的性能推定にもバイアスが生じた。バイアスの大きさは違反の程度によって変わる。

指標	仮定違反下でのバイアス
判別(c-index・AUCt)	数値的には 軽微 だった
較正のO/E比	シナリオによっては より顕著 なバイアスが出た

それでも、加法ハザードモデルのシナリオでは 58/64 (90%) の比較で、反実仮想的指標のバイアスは素朴な部分集合アプローチより小さかった（eTable 10）。

caution

90%は「常に勝つ」ではない 裏を返せば **6/64(約10%)では部分集合アプローチのほうがバイアスが小さかった**。仮定が破れた状況で提案法の優越は保証されない。仮定の妥当性の吟味を省略してよい理由にはならない。

5. 応用:米国肝移植待機リストへの適用

5-1. 臨床課題とデータ

対象は米国の Scientific Registry of Transplant Recipients (SRTR)。米国のすべてのドナー、待機登録者、移植レシピエントのデータを含み、Organ Procurement and Transplantation Network (OPTN) の各機関から提出される。

- **対象**: 2014年1月1日から2019年4月30日の間に肝移植待機リストに登録された **43,190人**
- **記録項目**: 移植日、死亡日、待機リストからの除外日と理由、加えてバイオマーカー・合併症・併存症の縦断的測定
- **アウトカム**: 死亡、または健康状態の悪化による待機リストからの除外の**複合アウトカム**
- **時間地平線**: 3年
- **評価する2つの介入戦略**: (1) その時点で肝移植を受ける、(2) その時点でも将来も移植を受けない
- **予測の条件づけ**: 個人特性の最新の測定値

臨床的な狙いは明確である。**新しいドナー臓器が利用可能になった瞬間に、待機中の全候補者について両戦略下の推定リスクを並べ、臓器配分の判断材料にすること。**

5-2. データセットの構成と解析

解析データセットは2種を結合して作られている。

構成要素	内容
①	移植を受けた時点以降を追跡するデータセット
②	待機リスト登録時から一連のランドマーク時点を起点とし、その時点でまだ待機中かつ未移植の人に限定したデータセット群

結合データをランダムに **70%(開発)／30%(検証)** に分割した。開発データで2つの介入下予測モデルを構築(移植の効果推定に用いられてきた手法を介入下予測の設定に拡張したもの)、検証データで本論文の反実仮想的検証法を適用している。詳細は補遺(eAppendix 5、eTables 12-14)。

5-3. 較正の結果

図の解説

Figure 5. 肝移植への応用:無移植戦略・移植戦略のもとでの推定リスクの較正。左パネルは横軸が時間(0～3年)、縦軸が生存確率(0～1.0)。4本の曲線があり、黒の実線が無移植戦略の平均予測生存曲線、灰色の実線が移植戦略の平均予測生存曲線、黒の破線が無移植戦略の反実仮想生存曲線、灰色の破線が移植戦略の反実仮想生存曲線である(破線は人工打ち切り+逆確率重み付けで推定)。黒の2本は3年時点で0.46～0.49付近まで下降し、破線が実線よりわずかに上を走る(予測がやや低すぎる)。灰色の2本は3年時点で0.88～0.89付近と高い位置にとどまり、両者はほぼ重なる。右パネルは横軸が3年時点の群平均推定リスク(0～1.0)、縦軸が反実仮想的な転帰割合で、破線が等値線。黒丸で結ばれた無移植戦略の系列は10点が全域に広がり、低リスク側(予測0.17付近で観察0.21)ではやや上、高リスク側(予測1.0付近で観察0.89)では下に位置して、等値線をまたぐ緩いS字を描く。灰色の系列は予測リスク0.07～0.23という狭い範囲に10点が固まり、等値線の近傍で上下に不規則に振れ、一部の点は右下方向へ折り返している。原図・無改変

- 3年時点の**平均推定リスク**:無移植戦略 **54.1%**、移植戦略 **11.7%**。2戦略で平均予測生存曲線は大きく異なる
- 「観察された」(＝反実仮想的に推定された)全生存曲線は平均予測曲線に近いが、**無移植戦略では予測曲線がわずかに低すぎた**
- 平均較正は移植戦略のほうが良好
- 十分位較正では、**無移植戦略に過適合の兆候**。低リスクは過小推定、高リスクは過大推定される傾向
- 移植戦略でも同様のパターンだが、**予測リスクの範囲がきわめて狭い**(およそ7～23%)

5-4. Table(原表の日本語化)

Table. 肝移植への応用:反実仮想的性能の評価

指標	無移植戦略	移植戦略
校正:3年時点のリスクに基づく観察／期待比	0.983	1.060
判別:3年までのc-index	0.749	0.561
判別:3年時点のAUCt	0.781	0.552
予測誤差:3年時点のscaled Brierスコア(%)	66.8	12.0

※AUCt=累積／動的な受信者動作特性曲線下面積。

著者らは、この反実仮想的検証によって**モデル性能のあらゆる側面を評価できた**とし、結果はモデル改良や代替モデルとの比較に使えると述べる。また、部分集合アプローチを用いていたら**性能について誤った印象を与えていたはず**であることを補遺(eTable 15、eFigure 14)で示している。

6. 考察(著者の主張と留保)

達成したこと。time-to-event アウトカムに対する介入下予測の反実仮想的検証法を提案した。時間依存交絡のある縦断観察データを扱え、治療を時間を通じて維持するタイプの介入に対応する。校正・判別・全体的予測誤差という3側面をカバーする**初の一般的な指標一式**である。シミュレーションで真の性能を正しく捉えること、悪い性能を悪いと検出できることを示し、肝移植の応用で臓器配分という重大な判断を支える予測の性能を定量できることを示した。

依存する仮定。重みモデルの正しい特定、および一貫性・正直性・条件つき交換可能性。これらが破れたときのバイアスはシミュレーションで示したとおりである。

正直性違反を避ける実務的助言。検証データ内で十分な規模の部分集団が実際に従っている治療戦略のみを検討すべきである。推定の不確実性を大きくしないためにも同様である。戦略の記述を実務的(pragmatic)に緩めることが助けになる場合がある。

効率の問題。構造モデルを使わない打ち切り+重み付けのアプローチは、治療効果をモデル化する方法に比べて一般に**効率が悪い**。二値アウトカムの反実仮想的評価では、検証段階でアウトカムモデルを使う代替法が提案されている。**二重ロバスト(doubly robust)な拡張はモデル化仮定の緩和に向けた優先課題**であり、縦断的 time-to-event の設定では、Dickerman らが介入下予測に用いた g-formula の路線と同様に、縦断データの時間的モデル化が必要になる。

適用範囲。本論文は縦断的な治療使用歴と時間固定・時間依存交絡因子、イベント／打ち切り時刻を持つ検証データを想定したが、**点治療や時間固定交絡のみのより単純な設定にも使える**。動的レジメンのような複雑な戦略への拡張も容易である。

検証データへの要求。介入下予測の検証には、予測因子だけでなく、**交絡制御に必要な追加変数と、治療の開始・中止の情報**が検証データに含まれている必要がある。著者はこれを強調している。

未解決の課題。

課題	内容
内部検証 への拡張	シミュレーションは外部検証データを想定。応用では分割標本を使った。交差検証・ブートストラップへの拡張には追加の研究が必要。特に交差検証では、各foldの標本サイズが小さいと重みの安定した推定が難しくなる
サンプル サイズ設 計	必要症例数を求める方法が未確立
モデル更 新	再較正 (recalibration) などの更新手法が未整備

締めくくりとして、介入下予測モデルの**開発**手法は増えているのに**検証**への注目が乏しかったこと、反実仮想的性能評価は介入下予測モデルの実装に向けた要の一步であり、モデル選択・チューニングの新しい道具にもなりうることを述べている。

7. 批判的吟味(JCでの論点)

- ① **検証データへの要求が実務的にきつい**。必要なのは「予測因子+交絡調整に十分な変数一式+治療の開始・中止の時点」が縦断的に揃ったデータである。時間依存交絡を制御するには、その交絡因子が測られていなければならない。ICUの電子カルテは変数が豊富に見えるが、「なぜその治療を始めたのか」を決めた情報の多くは記録に残らない(家族の意向、主治医の見立て、ベッドの空き)。未測定交絡が残れば条件つき逐次交換可能性が破れ、その帰結はシミュレーションが示すとおりである。
- ② **「観察された転帰」自体が推定値である**。通常の検証では、比較対象の観察転帰は実データそのものである。本手法では、比較対象(反実仮想的転帰割合)が重み付きKaplan–Meierによる**推定量**になる。つまり**基準線そのものが仮定に依存して動く**。較正プロットの縦軸がずれていれば、モデルの較正が悪いのか、重みモデルが誤特定なのかを分離できない。この識別不能性は論文中で明示的には論じられていない。
- ③ **応用の移植戦略の性能は、臨床的にはほぼ無情報**。c-index 0.561、AUCt 0.552、scaled Brier 12.0%。c-index 0.5がコイン投げであることを考えれば、**移植を受けた場合の3年転帰について、このモデルは患者の順位づけをほとんどできていない**。予測リスクの範囲が7~23%と狭いことも原因の一つだが、臓器配分に使うことを目的に掲げた予測としては、この数字をどう受け止めるかがJCの論点になる。もっとも著者の

主張は「このモデルを使え」ではなく「**この数字を出せるようになった**」ことなので、方法論としての達成と、応用例の臨床的価値は分けて評価すべきである。

④ **無移植戦略の高いc-index(0.749)は驚くべき値ではない**。末期肝疾患の待機患者では、MELD系の指標だけでかなりの予測ができる。無移植で3年追った転帰は自然経過に近く、既存の予後スコアが強い領域である。したがって0.749は方法の優秀さではなく、対象の性質を反映している可能性が高い。

⑤ **較正曲線に見える過適合の解釈**。無移植戦略で「低リスクは過小推定・高リスクは過大推定」というパターンは典型的な過適合の兆候だが、**分割標本(同一データの70/30分割)**で検証している以上、真の外部妥当性の評価ではない。集団・時代・施設が変われば結果は変わる。著者自身が「多くの予測研究は初め内部検証に頼る」と認めており、交差検証への拡張は今後の課題として残されている。

⑥ **シミュレーションの構造は提案手法に有利な条件を含む**。主要3シナリオではすべての因果仮定と重みモデルの特定が成立している。この状況で提案手法が不偏なのは、ほぼ数学的に期待される帰結である。むしろ情報量が多いのは追加3シナリオ(仮定違反)のほうだが、その結果は本文に数値が出ておらず補遺に置かれている。本文に残った要約は「58/64(90%)で部分集合より良かった」という**一行の集計**であり、どの仮定をどの程度破ったときに較正のO/E比がどれだけずれるのか、実務者が判断できる形にはなっていない。

⑦ **部分集合アプローチのバイアスが戦略依存であること**。シナリオ1では無治療戦略でのみ部分集合アプローチが外れ、常時治療戦略では外れなかった。したがって「部分集合アプローチは常に危険」ではなく、**どちらに、どれだけずれるかは治療選択の機序に依存する**。ずれの方を事前に予測できないことこそが問題であり、そこが提案法を使う理由になる。

⑧ **通常の打ち切りを共変量非依存と仮定している**。脱落が重症度に依存する(例:状態が悪化して転院・追跡不能)状況はICUデータでは珍しくない。著者は共変量依存への拡張は可能と述べるが、実装と評価は本論文では行われていない。

⑨ **効率の悪さは著者も認めている**。構造モデルを使わない打ち切り+重み付けは非効率で、推定のばらつきが大きい。図2~4の箱ひげ図でも、緑(提案法)の箱は黒(真値)より縦に長く、外れ値も多い。**同じ標本サイズでも結論の不安定さが増す**ことは実務上の代償である。二重ロバスト化が優先課題とされるのはこのためである。

⑩ **再現性**。シミュレーションのRコードは公開されているが、**応用に用いたSRTRデータは現時点で公開されていない**。応用部分の再現は外部からはできない。

8. 主要な引用文献一覧

文献	内容	出典
van Geloven N, et al.	予測と因果推論の交差点。臨床予測モデルにおける治療の役割を整理し、介入下予測の必要性を提起した本分野の基礎文献	Eur J Epidemiol. 2020;35:619–630
Nguyen T-L, et al.	RCT(国際脳卒中試験)を用いて反実仮想的臨床予測モデルから個別化治療効果を推定した実例	J Clin Epidemiol. 2020;125:47–56
Efthimiou O, et al.	治療選択の個別化を目的とした予測モデルの性能測定	Stat Med. 2023;42:1188–1206
Sperrin M, et al.	周辺構造モデルで治療のdrop-inを調整して臨床予測モデルを開発する方法。本論文が批判する「部分集合アプローチ」の出典	Stat Med. 2018;37:4142–4154
Lin L, et al.	仮想的介入下の予測を可能にする因果的手法のスコーピングレビュー。13研究中0件しか性能評価をしていなかったという指摘の出典	Diagn Progn Res. 2021;5:3
Dickerman BA, et al.	g-formula を用いた仮想的治療戦略下の反実仮想リスク予測。HIV治療への応用	Eur J Epidemiol. 2022;37:367–376
Xu Z, et al.	将来のスタチン開始を考慮した心血管疾患リスク予測。試験の効果推定値と観察データを組み合わせる路線	Am J Epidemiol. 2021;190:2000–2014
Sperrin M, et al. (招待論説)	治療drop-inに対して因果予測が必要だという主張。「本分野で最も差し迫った問題」の出典	Am J Epidemiol. 2021;190:2015–2018
Pajouheshnia R, et al.	予後モデルの検証時に治療使用を考慮するシミュレーション研究。二値アウトカムでの先行研究	BMC Med Res Methodol. 2017;17:103
Coston A, et al.	反実仮想的リスク評価・評価・公平性。二値アウトカム・点治療での反実仮想評価の先行研究	Proc. FAT* 2020;20:582–593

文献	内容	出典
Boyer CB, et al.	反実仮想予測のモデル性能評価を形式化し、縦断的治療戦略へ拡張した先行研究 (time-to-event は未カバー)	arXiv:2308.13026 [stat]; 2023
Sperrin M, et al.	targeted validation の考え方。予測モデルは意図された集団・状況で検証されるべき	Diagn Progn Res. 2022
McLernon DJ, et al.	生存アウトカムを持つ予測モデルの性能と臨床的有用性の評価。標準設定での指標の全体像を与える実務ガイダンス	Ann Intern Med. 2022;176:105–114
Uno H, et al. (2007, 2011)	打ち切りのある回帰モデルにおけるt年生存者の予測ルール評価、およびC統計量。本論文の重み付きc-index推定量の下敷き	J Am Stat Assoc. 2007;102:527–537 / Stat Med. 2011;30:1105–1117
Gerds TA, et al.	共変量依存打ち切り下の時間依存 concordance index。同上	Stat Med. 2013;32:2173–2184
Blanche P, et al.	マーカー依存打ち切り下の時間依存ROC推定量の比較	Biom J. 2013;55:687–704
Graf E, et al.	生存データの予後分類スキームの評価と比較。Brierスコアの time-to-event 版の出典	Stat Med. 1999;18:2529–2545
Gerds TA, Schumacher M.	右側打ち切り下でのBrierスコアの一致推定。本論文のBrier推定量が拡張した対象	Biom J. 2006;48:1029–1040
Gong Q, Schaubel DE.	観察データと部分条件つきモデルによる生存への平均治療効果推定。肝移植応用の予測モデル構築に用いた手法	Biometrics. 2017;73:134–144
Strohmaier S, et al.	腎不全患者における初回単一臓器の死体腎移植と長期透析の年齢横断的な生存ベネフィット比較	JAMA Netw Open. 2022;5:e2234971
Hernán MA, et al.	逆確率重み付けによる動的治療レジメンの比較。効率に関する議論の出典	Basic Clin Pharmacol Toxicol. 2006;98:237–242

✓ Take home message

TAKE HOME

結論 介入下予測(「この治療方針をとったらこの患者はどうなるか」)は意思決定支援の本命だが、その性能を検証する方法がこれまで存在しなかった。本論文は、**検証データで戦略から逸脱した時点を人工的に打ち切り、逆確率重み付けで「全員がその戦略に従った世界」を再現したうえで、較正・c-index・AUCt・Brierを測る**方法を time-to-event アウトカムに対して初めて体系化した。実務への持ち帰りは1つ。**「その治療を実際に受けた人だけで検証しました」というモデルの性能報告は信用しない** — シミュレーションでは、この部分集合アプローチが判別を過大評価し、良いモデルのscaled Brierを負に見せ、悪いモデルのscaled Brierを正に見せた。院内でAI・予測モデルの導入可否を判断するとき、**提示された性能が「観察された治療の混合下」か「特定の治療戦略下」かを必ず問う**。ただし本手法は仮定に強く依存し(未測定交絡・正值性・重みモデルの特定)、効率も構造モデルを使う方法に劣る。応用例の移植戦略ではc-index 0.561と実質無情報であり、**方法論の達成と、その応用モデルの臨床的価値は分けて評価する**。

本ページは原論文の要約・解説です。数値は原論文から転記していますが、引用の際は必ず原論文(上記DOI)をご確認ください。原著の図表は著作権のため本ページには掲載していません(本文の「図の解説」を参照)。作成: Claude Code(聖路加ICUジャーナルクラブ運用)。