



# 判断の質・診断エラー・AI Home

---

原題 Quality of judgment, diagnostic error and AI in the ICU — separating bias from noise

---

🔗 **共有ページ** (誰でもログイン不要): [クリックで開く] (<https://hiro-oka.github.io/jc-summaries/jc-14f3cd708b.html>) / 下の枠でURLをワンクリックコピー

<https://hiro-oka.github.io/jc-summaries/jc-14f3cd708b.html>



PDF: [開く / ダウンロード] (<https://hiro-oka.github.io/jc-summaries/jc-14f3cd708b.pdf>)

## 聖路加ICUでの実践への示唆

### 聖路加ICUでの実践

当院の「判断の質」をどう設計するか ① **まず「誰が診るかで結果が変わる判断」を名指しする。**判断誤りは **バイアス(一定方向のズレ)** と **ノイズ(方向の定まらないばらつき)** に分解できる。医学はバイアスばかり議論してきたが、**同じ幅だけ減らせば全体誤差への寄与は等価** である(ICUの判断の誤りはバイアスだけでなく「ノイズ」で起きる — レベル・パターン・機会ノイズと2つの低減策(Perspective・CritCare2025))。当院で「くじ引き(lottery)」になっている候補は、ICU入室可否・SDU振り分け、予後説明とDNAR提案、RRSコール後の「上げるか」判断、抜管可否、抗菌薬デエスカレーション。

② **ノイズ監査(noise audit)**は当院で1回やる価値がある。原著のパイロットは **ICU臨床医20名に同一の患者ケース50例の死亡確率(0~100%)を推定させ、うち症例3を「症例51」として気づかれないよう再提示** するだけの設計で、原著でも低リスクとして倫理審査免除だった。当院でやれば「医師間でどれだけ、同一医師内でどれだけばらつくか」を**分散の数字**として経営戦略会議やQIの議論に持ち込める。印象論と縁を切れる。

③ **重症度スコアは「予測精度」より先に「ノイズ除去装置」として売る。ただし個人には使わない。**APACHE は (a) 全員が同じ妥当な変数を集め、(b) 同じ式で統合する**二重の標準化装置**である。JIPAD で APACHE III-j / SOFA を日々入力している当院にとって、これは「学会提出のための入力作業」から「ばらつきを消す仕組み」への意味づけの転換になる。同時に **スコア40年の最大の教訓は「群を比較する道具であって、個人の予後を言い当てる道具ではない」**ことも忘れない(ICUスコアリングシステムの40年(Lasting Legacy・ICM2022))。この2つは緊張関係にある(→ 詳細 §9)。

④ **「独立した判断を平均する」を多職種カンファの設計思想に入れる。**平均化はノイズを判断数の平方根に比例して縮める(4人なら1/2、9人なら1/3)。ただし条件は**独立性**で、**先に部長や上級医が意見を言った時点で効果は大きく損なわれる**。朝カンファ・家族面談前カンファで意見を「せーの」で同時に出す(付箋・チャット同時投稿・Forms事前入力)だけで、追加コストほぼゼロでノイズが下がる。**岡本の立場(部長)は最も強い社会的影響源なので、「自分が最後に話す」ルールが最も費用対効果が高い介入**になる。

⑤ **見落としトップ6を、原因不明の増悪時のチェックリストにする。**ICU死亡例の剖検で主要な診断乖離は **18.5%**、うち治療を変えていたはずの class I が **7.5%**(ICUにおける臨床診断と剖検所見の乖離(記述研究))。見落としトップ6は**肺塞栓・肺炎・二次性腹膜炎・侵襲性アスペルギルス症・感染性心内膜炎・心筋梗塞**。「敗血症性ショックだが感染源不明」「原因不明の呼吸不全」でこの6つを**声に出して除外**する。

⑥ 症候群ラベルを貼った瞬間に鑑別が止まることを自覚する。重症患者の診断エラー — 剖検乖離 19%・認知バイアスと系のデザイン(解説・ICM2025) は、集中治療の**症候群アプローチ**(敗血症・ARDS・せん妄)そのものを診断エラーの原因に挙げる。感度も特異度も低い症候群が、異質な病態をひとまとめにして精度を落とす。当院の申し送りで「ARDSです」で終わらせない。これを症例レベルで裏づけるのが 重症患者における診断エラーの頻度と影響(CCM2019) の18件カタログで、**誤った作業診断の側に「敗血症／敗血症性ショック」が18件中7件現れ、最終診断は膿瘍・骨髄炎・穿孔・心内膜炎・化膿性関節炎というソースコントロールを要する病巣か、そもそも感染でない病態(右心不全・HFpEF・ループス心膜心筋炎)だった**。同研究の DEER 分類でも最多の失敗は **競合する診断に重みを置きすぎた(100%) と その診断を考えるのが遅れた(89%)** で、失敗は情報収集ではなく**推論の打ち切り側**に寄っている。申し送りで「敗血症です」と言われたら「**どこの感染か／感染でない可能性は何か**」を必ず言わせる。

⑥-b 予定外ICU入室そのものを「**診断を見直すトリガー**」として扱う。同研究は IHI Global Trigger Tool の発想を採り、**上位の治療レベルへの予定外転棟それ自体を有害事象の候補とみなす**。当院では **RRSコール後の入室・病棟からの予定外入室**がこれにあたる。RRSの事後検証に「入室前後で診断名が変わったか」の1欄を足し、翌朝カンファで前日入室例だけ「入室時の working diagnosis と今の診断は同じか」を1行確認する——これが **同研究で最も大きな穴(3件に2件は24時間以内に気づけていない)** を、追加コストほぼゼロで狙える設計になる。

⑦ 院内AI導入の審査項目に「**教師ラベルのノイズ**」を入れる。一貫性のない専門家判断でラベル付けされたデータで学習したモデルは、**そのノイズを取り込む**。バイタル自動収集・RRSの予測アラート・将来の院内AIを評価するとき、「精度が高いか」「差別的バイアスがないか」に加えて「**教師ラベルは誰がどれだけばらついて付けたか**」を必ず問う。

⑧ アラートは「**何%で鳴らすか**」が実装の成否を決める。AIによるICP上昇予測に臨床医はどう反応するか ICP-Aid国際調査(236名・ICM2025) では、80%確率のアラートで **84.7%** が行動する一方、60%では「**何もしない／診断的措置のみ**」が増えた。臨床医が望むトリガー閾値の中央値は**診断的介入 70%・治療的介入 80%**、先行警告は**30分**が最適。当院のRRS・バイタル自動収集の設計にそのまま使える。

⑨ **ただし「仮想シナリオでの受容」と「現場での実装」は別物**。実際に敗血症MLアラートを回した現場では、**アラート後に新たな臨床所見を認識したのは看護師24%・医療者13%にとどまり、大多数(看護師55%・医療者62%)は敗血症リスクの認識に変化なしと答えた**(敗血症予測の機械学習アラートは臨床医に響かなかった(EWS 2.0・CCM2019))。導入時の期待値はこちらを基準にする。

⑩ AIの監督責任を、導入の稟議に明文化する。臨床でAIを監督する教育戦略 — deskilling・never-skillingを防ぐ(NEJM2025) の4リスク(automation bias／deskilling／never-skilling／mis-skilling)のうち、**研修医にとって最も見えにくい害は never-skilling**(本来身につけるべき能力を最初から獲得しない)。**定型作業はオフロード可、臨床推論は要監督**という線引きを、導入文書に書く。

⑪ 心停止後の予後評価を「72時間で1回」から「3点測定」に組み替える。偽陽性は第1週に集中し、第2週の再評価で消える。初回値だけだと PLR+CR の FPR は 3.0%→18.2%、EEG は 0%→10.0% に悪化する。院内の PCAS カンファのフォーマットを「72時間で初回 → 7日前後 → 12~14日で最終」に変え、単発所見を家族面談の根拠にしない。家族説明の言葉は「不良マーカーが2つ以上そろったか」で揃え、0~1個のときは「まだ分からない」を維持する。そして 予後予測の会話と WLST の会話を同じ場で混ぜない(ERC/ESICM 2025 の明示的推奨)。これが当院でできる最も直接的な自己成就対策になる(→ 詳細 §13)。

⑫ プロトコル改訂の提案書に「低バイアスリスク試験に限った推定値」を必須項目にする。「メタ解析で有意だったから採用」という運びを止める。統合推定値と、低ROB試験に限った推定値が同じ向きなら採用の後押し、食い違うなら条件付き(対象を絞る・期間限定・効果測定を伴う)に留める。メラトニンは高リスク RR 0.46(0.29-0.73)/低リスク RR 0.86(0.70-1.05)で結論が反転した実例(→ 詳細 §14)。JIPAD などのレジストリ研究でも同型の問題が起きるので、主解析と、除外基準を厳しくした解析の両方を最初から出す設計にする。

⑬ 院内AIの設計図に「予測モデルの実装」だけでなく「ランダム化を埋め込んだ学習」を書く。必要なときだけランダム化する強化学習が集中治療AIの第3の波 — 臨床・RCT・実世界データをつなぐ 構想(What's New・ICM2026) は、集中治療AIの本命を予測でも生成でもなく「確信があるときは推奨し、不確実なときは妥当な選択肢の間でランダム化して学び、転帰から方針を更新する」オンライン強化学習を診療そのものに埋め込むことに置く。オフラインの観察データからの学習は適応による交絡・分布シフト・価値の過大評価という原理的な壁を越えられず、それを壊す道具がランダム化(ベイズ適応プラットフォーム試験の自然な延長)である。当院で今できるのは実装ではなく前提整備で、バイタル自動収集とRRSの出力を「アラートを出すもの」からどの時点で・誰が・どちらの選択肢を選び・その後どうなったかを欠損なく残すものへ位置づけ直すこと。記録が無ければ後からどんなAIも因果を推定できない。あわせて「業務効率用途だから低リスク」という分類は当院でも成り立たない(ベッド配分・優先順位づけ・ワークフロー変更は転帰に影響する)ので、RRSの起動優先順位づけに機械学習を使うなら臨床AIとして審査する。提言であり新規データはなく、RLに基づく治療推奨のベッドサイド運用は世界のどこでもまだ行われていない。責任著者はICU向けAI企業からのロイヤリティ、共著者はAI健康解析企業のアドバイザー報酬を開示している。

⑭ 予測モデル論文は、AUC より先に「検証セットの人数」と「主要変数の欠測率」を見る。二次性 HLHの機械学習予測は本物か — 167例で構築したHLH-Risk-Calculatorの到達点と、希少疾患のデータ律速(エディトリアル・ICM2026) は、AUC 0.845/平均 0.882 という数字の裏にホールドアウト32~43例と主要予測因子 sIL-2R の測定率40%(しかも欠測が重症度と相関する)があることを名指しする。希少疾患では性能指標より先に検証セットの人数と欠測率を見る——これは §5 の表の「AUCの大小より、どこで何人で検証されたかを先に見る」を、当院の抄読会・院内AI審査でそのまま使える形にした読み方の規則になる。HLH-Risk-Calculator は外部検証まで診療判断に使わない(診断は従来どおり HScore と HLH-2004 基準)。当院の貢献の仕方は「モデルを使う側」ではな

く「**検証コホートに乗る側**」で、HLH疑い症例の診断時検査(フェリチン・トリグリセリド・フィブリノゲン・AST・血算3系統・sIL-2R)を**欠測なく同じタイミングで揃える**ことが、そのまま偏りのない検証データを出せる立場につながる。予測モデルを読む会の題材としても、**n・ホールドアウトの人数・AUC・欠測率の4点だけでモデル論文の信用度をどこまで判定できるか**を訓練する好材料。

## POINT

グロービス(MBA)の意思決定論との接続

- 「**バイアス vs ノイズ**」は、**平均のズレ vs 分散の大きさ**。品質管理の正確度(accuracy)と精密度(precision)と完全に同じ構造。経営でも医療でも、**見えるバイアスばかり議論され、見えないノイズは残る**。
- **アルゴリズム vs 専門家判断**は Meehl(1954) 以来の「臨床的予測 vs 統計的予測」論争そのもの。原著は Dawes の 「**improper linear model(単位重み・ランダム重みという雑な線形モデル)ですら専門家を上回りうる**」を引き、その理由を**精度ではなく一貫性**に帰している。採用面接・与信・人事評価の設計にそのまま使える。
- **AIガバナンス**: 誰がAIの出力を検証するのか。院内AI審査の枠組みは「①予測AIか行動可能なAIか ②教師ラベルの質 ③外的妥当性(自施設データでの校正) ④アラート閾値 ⑤監督責任者と再教育計画」の5点セットで組める(→ 詳細 §12)。
- 振り返り・レポートで使えるフレーム: 「**この判断は、誰がやっても同じになるべきものか?(→ノイズ削減の対象) / 人によって違ってよいものか?(→価値判断の領域)**」の切り分け。





## このテーマの位置づけ(Known / Unknown / What's new)

### 補足

#### リサーチ・イン・コンテキスト

- **Known(既に分かっていること)**: ICUの判断誤りは転帰に直結する。認知バイアス(アンカリング・利用可能性・早期閉鎖・確証バイアス)は集中治療でも整理済み。**剖検との乖離**という物差しがあり、ICU死亡例の主要な診断乖離は **18.5%**(うち class I 7.5%) で、**25年間ほぼ横ばい**( $p=0.2997$ ) だった。文献上のレンジは入院患者全体 5~40%、ICU 患者 7~32%。重症度スコアは40年かけて「群のリスク調整」の中核になった。
- **Unknown(まだ分かっていないこと)**: ICUの判断誤りのうち**どれだけがノイズ(ランダム誤差)**由来かは測られていない。アルゴリズム出力を「複数の手がかりの1つ」として人間が統合する **holistic synthesis** が精度を上げるのか下げるのか。人間の判断のどの部分がモデルに価値を付加しているのか。一般ICUと専門ICUで**診断エラー頻度に差がある**かも未検証(ICM2025が明記)。予測モデルの多くは**外的妥当性が検証されていない**。
- **What's new(新しい潮流)**: (1) Kahneman らの **noise(level / stable pattern / occasion)** の分類がICU臨床判断に体系的に持ち込まれ、同一827例で **医師の院内死亡予測 AUC 0.68 vs APACHE IV 0.83** が示された。(2) AI論の重心が「予測AI」から「**行動可能なAI(actionable AI)**」=因果推論へ移った。(3) 心エコーAIで **初の盲検化ランダム化試験** が成立し、効果の正体が「AIが正しい」ではなく「**安定した初期値に人が引きずられる(アンカリング)**」だと示された。(4) LLM時代の論点が **deskilling / never-skilling** とAIの**監督責任**に移った。(5) 予測が結果を作る領域(心停止後の神経予後予測)で、**WLSTを設計・臨床文脈で統制した3コホート(本研究・KORHN・ProNeCA)**が独立に「**2剤併用で偽陽性ゼロ**」に収束した。(6) メタ解析の食い違いを「どちらが正しいか」ではなく「**なぜ食い違ったのか**」に分解する読み方が明文化された。(7) 議論の重心が「良いモデルをどう作るか」から「**学習をどう回すか**」へ移り、**不確実なときにだけベッドサイドで適応的にランダム化するオンライン強化学習**(=第3の波)が、RCTと実世界データの分断を埋める枠組みとして提案された(**構想段階で、臨床実装は世界のどこにも存在しない**)。

## 全体要約

### 要旨

ひとことで ICU の判断の誤りは、**バイアス(平均のズレ)** だけでなく **ノイズ(ばらつき)** で起きる。ノイズは「誰が担当するか」というくじ引きを診療に持ち込み、**打ち消し合わずに蓄積する**。低減策はアルゴリズムと独立判断の平均化の2つだが、どちらにも副作用がある。AIはこの文脈で「精度を上げる道具」ではなく「**一貫性を供給する道具**」として読むのが正しい。

- **判断誤り = バイアス + ノイズ**。同じ幅だけ減らせば効果は等価なのに、医学はバイアスばかり見てきた。
- **システムノイズは3つ**: level (医師ごとの平均水準の差) / stable pattern (患者特性への反応の個人差) / occasion (同一医師内の場面依存のばらつき)。
- **人 vs モデル**: SICS の同一827例で医師 **AUC 0.68 (0.63–0.73)** vs APACHE IV **AUC 0.83 (0.79–0.88)**。アルゴリズムの優位は精度そのものより **一貫性** で説明できる、というのが原著の主張(利用できる情報量の不均衡という限定つき)。
- **診断エラーの実測**: ICU死亡例の剖検乖離 **18.5%** (class I 7.5%)、25年横ばい。診断技術の進歩は見逃しの割合を減らしていない。ICM2025は剖検乖離の統合推定値 **19%**、うち **約1/3は生前に診断されていれば生存を変えた可能性** と引用する。剖検ではなくカルテレビューで測ると、生存例を含む予定外ICU入室の **7.0%** (Bergl 2019) で、**そのうち24時間以内に気づけたのは33.3%** にとどまる。測り方が変われば数字も意味も変わる(→ §6)。
- **ノイズ低減策の副作用**: プロトコル化・アルゴリズム化はばらつきを減らす**が個別化を損なう**。しかも人間は **アルゴリズムに例外を作りすぎ (identify too many exceptions)**、その結果**ノイズを増やして精度をむしろ下げる** という反直感的知見が他分野にある。
- **AIは3層に分けて読む**: ①予測AI (早期警告どまり / 「何をすべきか」は言えない) ②行動可能なAI (因果推論 / 観察データではバイアスを完全排除できない) ③生成AI・LLM (ハルシネーション・プライバシー・deskilling)。
- **予測が結果を作る**: 心停止後の神経予後予測では、死亡の大半が「予後不良」判断後のWLSTで起きるため、予測精度が**自分で作った結果**を当てているだけになりうる(自己成就的予言)。早期WLSTを除外した設計でも**14日以内に不良マーカー2つ以上なら良好転帰 0/16**だったが、**偽陽性は第1週に集中し、初回値だけで判断すると FPR は2桁%になる**(§13)。
- **統合の段階にもノイズが乗る**: 同じRCT群でも、**バイアスリスクの扱い・統計枠組みと閾値・巨大試験への依存**でメタ解析の結論は反転する(メラトニン: 高リスク RR 0.46 / 低リスク RR 0.86、交互作用  $P=0.01$ ) (§14)。

- **監督責任**: 誤ったモデルの出力を提示すると**臨床医の判断精度は下がる**。「アルゴリズムはブラックボックスだから信用できない」への返答は、**人間の意思決定も同じくブラックボックスで、しかも実験的に検証できない**。

---

## 詳細

### 1. 学習目標

この資料を読んだ後に、以下を説明・実践できることを目標とする。

- **判断誤り=バイアス+ノイズ**という分解を説明でき、両者の対策が違うことを言える
- **システムノイズの3分類**(level / stable pattern / occasion)を、自科の具体的な判断場面に当てはめられる
- **医師の主観的予測とモデルの性能差**が何によって生じているかを説明できる
- 予測モデルを **識別能(discrimination)**と**較正(calibration)**と**外的妥当性** の3点で読める
- **剖検乖離**という物差しの意味と限界を説明できる
- **プロトコル化がノイズを減らす一方で個別化を損なう**というトレードオフを言語化できる
- **予測AI／行動可能なAI／生成AI** を区別し、それぞれで問うべき審査項目を挙げられる
- 院内でAIを導入するときの **監督責任と教育設計**(deskilling / never-skilling)を構想できる

### 2. まず前提 — バイアスとノイズ(初めての人にも)🍀



## 要旨

5分で背景を掴む 的(まと)に矢を射ることを考える。矢が**全体として右上にずれている**なら、それが **バイアス(bias、系統誤差)**。矢が**あちこちに散らばっている**なら、それが **ノイズ(noise、ランダム誤差)**。的の中心からの平均的なズレを直すのがバイアス対策、散らばりを縮めるのがノイズ対策で、**やるべきことが違う**。医療では「アンカリングに気をつけよう」「無意識のバイアスをなくそう」というバイアス対策ばかりが語られてきた。しかし **同じ大きさだけ減らせば、全体の誤差への寄与は等価** である。にもかかわらずノイズは見えにくい。理由は簡単で、**バイアスは1人を追跡すれば見えるが、ノイズは複数の人が同じ症例を判断しないと見えない**から。ICUは暗黙に「臨床医は互換可能(interchangeable)」という前提で運営されている。当直交代も、担当替えも、その前提の上に成り立つ。ノイズはこの前提を裏切り、**似た状態の患者が「担当が誰か」というだけで異なる予後予測と異なる治療を受ける「くじ引き(lottery)」**を生む。

## 3. 判断誤りの分解 — 原著 Fig. 1 の構造

| 階層       | 用語                   | 定義                        | ICUでの具体例                                                                 |
|----------|----------------------|---------------------------|--------------------------------------------------------------------------|
| 判断誤り     | Judgment error       | 臨床医の予測と実際の転帰との差           | 死亡確率の見立てと実転帰のズレ                                                          |
| ト 系統誤差   | Bias                 | 一定方向に偏る誤差                 | 認知バイアス(アンカリング・利用可能性)／社会集団への差別的バイアス。例： <b>背が高い人の疼痛は一貫して過小評価される</b>        |
| └ ランダム誤差 | Noise                | 方向の定まらないばらつき              | 同一患者に対し臨床医ごとに異なる判断。咽頭炎・尿沈渣・画像読影など多領域で観察                                  |
| ノイズの総体   | System noise         | 本来同一であるべき判断における望ましくないばらつき | 「誰が担当するか」で死亡予測と治療が変わる＝ <b>lottery effect</b>                             |
| ト        | Level noise          | 臨床医個人の <b>平均判断</b> の差     | ある医師は常に手術寄り、別の医師は常に慎重                                                    |
| ト        | Stable pattern noise | 臨床医×患者特性の <b>安定した交互作用</b> | 特定の併存症をもつ患者に、自分の平均より・同僚より高い死亡確率を一貫して付ける。 <b>楽観／悲観の差ではなく、患者因子の重み付けの違い</b> |
| └        | Occasion noise       | 同一臨床医の <b>場面依存</b> のばらつき  | 気分・天候・疲労・時間帯。同じ症例を別の機会に見ると判断が変わる                                         |

#### 図の解説

ノイズは相殺されない 直感に反するが、**ノイズは個々の患者をまたいで打ち消し合うのではなく、蓄積していく(compounding)**。「平均すれば正しいから大丈夫」は成り立たない。患者にとって重要なのは自分の1回の判断だからである。

#### 当院の判断場面へのマッピング

| 当院の判断場面              | 想定されるノイズの型                | 現状の防波堤          |
|----------------------|---------------------------|-----------------|
| ICU入室可否・SDU振り分け      | レベルノイズ(医師ごとの閾値差)          | 明文化された入退室基準の運用度 |
| 予後説明・DNAR/治療制限の提案    | レベル+安定パターンノイズ             | 主治医裁量に依存しやすい    |
| RRSコール後の「ICUへ上げるか」判断 | 機会ノイズ(時間帯・当直の疲労)          | 深夜帯ほど検証が必要      |
| 抜管可否・SBT合否           | 安定パターンノイズ(COPD・肥満などへの反応差) | プロトコル化で低減済みの領域  |
| 抗菌薬デエスカレーション         | レベルノイズ                    | ASTラウンドが部分的に機能  |

## 4. 人 vs モデル — 一貫性という武器 🎯

なぜICUでは「直感的熟達(intuitive expertise)」が育ちにくいのか。Kahneman & Klein (2009) が挙げた成立条件は3つ ——①**明確かつタイムリーなフィードバック**、②**予測因子と転帰の安定した関係**、③**その関係を学習する機会**。ICU患者は変動が大きく、これらが満たされないことがある。傍証として原著は、**経験豊富な医師のICU死亡予測は医学生より有意に正確とはいえなかった** という Cox らの結果を引く。

アルゴリズムの利点は2つあり、原著は**後者をより重要**とする。

| 利点        | 内容                                                            |
|-----------|---------------------------------------------------------------|
| (1) 変数の選択 | 予測妥当性のある変数に適切な重みを与え、 <b>妥当性のない変数を見捨てる</b> 。人間は無関係な変数を見捨てるのが苦手 |
| (2) 一貫性   | <b>全症例に同じ重み付けを一貫して適用する</b> 。人間は症例ごとに重み付けを変え、それが精度向上ではなくノイズを生む |

この「一貫性」の威力は古典的に知られている。専門家の判断を模した線形モデル(judgmental bootstrapping)は元の専門家を上回り、**単体重み・ランダム重みといった「improper」なモデルですら、一貫性ゆえに専門家を上回りうる**(Dawes)。

#### △ 注意

この「一貫性」論は生成AI(LLM)には当てはまらない。ここで論じている一貫性は、予測モデル・スコア・線形モデルの話である。LLMは確率的生成器であり、同一の入力に同一の出力を返さない。温度設定・モデル更新・文脈の微差で答えが変わるため、「人間より一貫している」という前提が成り立たない。実際 ECMOについての家族の質問に4つのLLMはどう答えたか — 満足できる回答はGemini 95%対DeepSeek 61%(Correspondence・CritCare2026) は 各モデル1回照会しか行っており、再現性そのものが測られていない。§10 の3層でいえば、一貫性が武器になるのは①予測AI・②スコアであって、③生成AIではない。

同一データでの直接比較(SICS データセット、Cox et al. 2021 の 827例)

| 予測主体                                        | アウトカム | AUC         | 95% CI    |
|---------------------------------------------|-------|-------------|-----------|
| 医師の予測                                       | 院内死亡  | <b>0.68</b> | 0.63–0.73 |
| APACHE IV スコア(CritCare2025 著者らによる同一データの再解析) | 院内死亡  | <b>0.83</b> | 0.79–0.88 |

#### caution

著者自身が付した限定 医師と APACHE IV で利用できる情報量に不均衡があることを著者は認めている(APACHE IV は24時間分の最悪値を使う)。それでも「アルゴリズム的手法は人間の判断ノイズを消せる」点が要点だと主張している。**この数値は「AIが医者より賢い」の根拠ではなく、「一貫性はそれだけで効く」の根拠として読む。**

**APACHE に残るノイズ源**: 測定機器の不正確さ、および **GCS のような判断に依存する変数** の不整合。SOFA も同じ問題を抱え、SOFAスコアの開発・有用性・測定の課題 は多施設間の評価者間標準化が鍵と結論している。つまり「スコアを使えばノイズが消える」のではなく、**スコアの中の判断ベース変数にノイズは残る**。GCS・RASS の教育とダブルチェックが依然として効く理由もここにある。

## 5. 予測モデルの性能と外的妥当性 — 1枚の表 📊

予測モデルは3点で読む。**識別能(discrimination)**=死ぬ人と死なない人を順位づけできるか(AUC/AUROC)。**較正(calibration)**=「10%と言ったら本当に10%死ぬか」(Hosmer-Lemeshow、較

正プロット、Brier score、SMR)。外的妥当性＝開発した集団の外でも成り立つか。識別能と較正は独立に壊れる。



| # | モデル／予測主体                                  | 対象・症例数              | アウトカム  | 識別能 (AUC/AUROC)                             | 校正                                                                       | 外的妥当性                                                     |
|---|-------------------------------------------|---------------------|--------|---------------------------------------------|--------------------------------------------------------------------------|-----------------------------------------------------------|
| 1 | 医師の主観的予測                                  | SICS 827例           | 院内死亡   | <b>0.68</b> (0.63–0.73)                     | —                                                                        | 単一コホート。医師とコアで情報量が非対称                                      |
| 2 | APACHE IV                                 | 同一 SICS 827例        | 院内死亡   | <b>0.83</b> (0.79–0.88)                     | —                                                                        | 同上 (著者による再解析)                                             |
| 3 | APACHE III-j (元モデル)                       | JIPAD 33,557例 (日本)  | 院内死亡   | <b>0.915</b>                                | <b>壊滅</b> : 校正プロット切片 −1.32、 <b>SMR 0.48</b> (= 実測の2倍以上に過大評価)、Brier 0.062 | 日本集団での <b>校正のみ</b> 確認。識別能無傷                               |
| 4 | JROD (階層 GAM で再校正)                        | JIPAD 33,557例       | 院内死亡   | <b>0.917</b> (optimism 補正 0.916)            | 修正 H-L <b>p=0.84</b> 、Brier <b>0.047</b> 、 <b>SMR 1.00</b>               | 内部検証 (ブートストラップ) のみ。モデル性能が <b>良くても質指標として</b> はファネルロットで過分散  |
| 5 | APACHE II / SAPS II / APACHE III-j / JROD | JIPAD COVID-19 444例 | 院内死亡   | <b>0.704 / 0.696 / 0.707 / 0.718</b>        | H-L 検定 <b>すべて p&lt;0.001</b>                                             | <b>新規疾患集団で識別能校正とも不良</b> 。通常 IC 集団の APACHE III-j 0.915 と比較 |
| 6 | CISSS (15 変数・GCS と尿量)                     | 米国 VA 534,001       | 30 日死亡 | 検証データ <b>0.848</b> (0.844–0.852)。 <b>呼吸</b> | <b>SMR 1.00</b>                                                          | <b>外的検証あり</b> (VA コホート)                                   |

| #  | モデル／予測主体                      | 対象・症例数                                    | アウトカム                  | 識別能 (AUC/AUROC)                                          | 較正                                                        | 外的妥当性                      |
|----|-------------------------------|-------------------------------------------|------------------------|----------------------------------------------------------|-----------------------------------------------------------|----------------------------|
|    | とP/Fを使わない)                    | 入室                                        |                        | 器 <b>0.779</b> ・敗血症<br><b>0.754</b>                      | (0.98–1.02)、<br><b>Brier 0.058</b> 、リスク十分位の絶対差はすべて2.08%未満 | ートは95%以上が男性                |
| 7  | ANZROD                        | ANZICS 百寿者 460例                           | ICU死亡／院内死亡             | <b>0.90</b> (0.84–0.96)／<br><b>0.82</b> (0.77–0.87)      | —                                                         | すべて内部導出。外部検証が必要。著者が明記      |
| 8  | SOFA                          | 同上 460例                                   | ICU死亡／院内死亡             | <b>0.80</b> (0.66–0.93)／<br><b>0.71</b> (0.64–0.78)      | —                                                         | 同上                         |
| 9  | APACHE III                    | 同上 460例                                   | ICU死亡／院内死亡             | <b>0.78</b> (0.63–0.93)／<br><b>0.73</b> (0.66–0.81)      | —                                                         | 同上                         |
| 10 | PICS早期予測4因子スコア (0～291点)       | 90例・単施設・後ろ向き                              | ICU退室 2か月後のPICS (HADS) | <b>0.913</b> (開発コホートでの見かけの性能。<br><b>95%CI は本文に記載なし</b> ) | 本文に記載なし                                                   | 外部検証なし。90例・変数で楽観バイアスを強く疑うへ |
| 11 | AHRF経過アークタイプ予測 (12変数 XGBoost) | 導出 MIMIC-IV 3,938例／外部検証 6,480例 (英・蘭2コホート) | 4つの経過クラス               | <b>3日目までに平均 <math>\geq 0.78</math></b> (0.70–0.86)       | —                                                         | 本表で唯一の独立2コホートで外部検証済み       |
| 12 | 緊急非心臓手術後の生理学的異常 (因子解析)        | JIPAD 18,781例                             | 院内死亡 (実測 11.9%)        | <b>AUROC は算出されていない</b>                                   | 較正も評価されていない                                               | 「リスク層別に使える」前向き検証を要する仮      |

| #  | モデル／予測主体                                                                  | 対象・症例数                                                              | アウトカム                     | 識別能 (AUC/AUROC)                                                                   | 較正                                                             | 外的妥当性                                                                 |
|----|---------------------------------------------------------------------------|---------------------------------------------------------------------|---------------------------|-----------------------------------------------------------------------------------|----------------------------------------------------------------|-----------------------------------------------------------------------|
|    |                                                                           |                                                                     |                           |                                                                                   |                                                                | 説(著者明記)                                                               |
| 13 | qSOFA (vs SIRS / CURB-65 / PSI)                                           | 入院市中肺炎 1,049 例(単施設・後ろ向き。年齢中央値 77歳、28日死亡 5.5% =58例、ICU入室 7.9%=83 例)  | 28日死亡                     | 抄録段階のため AUC の数値が記載されていない。順位のみ: qSOFA は SIRS より優れたが、CURB-65・PSI など従来の肺炎重症度スコアには劣った | 記載なし                                                           | 単施設・後ろ向き。外的証なし                                                        |
| 14 | 急性膵炎の「高リスク軌道」予測(入室24時間の20変数ロジスティック回帰。最重要は APACHE III / P:F比 / 初日の侵襲的人工呼吸) | ANZICS-CORE 13,275例のうち モデル開発 n=542 (2017年以降)。3変数版 Model 5 は n=2,264 | ICU死亡または ICU滞在 > 7日(複合)   | 0.827 (Model 1 は 0.823)。正解率 79.5%・Cohen's $\kappa$ 0.49。ただし感度 0.54 / 特異度 0.916    | Brier 0.148。較正プロットは一貫した正確さを示すが 低リスク域で 95%CIが広い。H-L 検定・較正切片は未報告 | 外部検証なし(10分割交差検証のみ)。豪NZのみ・事前サンプルサイズ計算なし。著者が「外部証が重要な次のステップ」と明記          |
| 15 | 深層ニューラルネットワーク (DNN) + SHAP による特徴量抽出                                       | JIPAD(症例数はノートに記載なし)                                                 | ICU死亡 / 院内死亡(ICU退室からの日数別) | ICU死亡 0.94(0.93–0.95) / 院内死亡 0.91(0.90–0.92)。ICU退室後1年を通じて 0.91~0.95 を維持           | 本論文の主要な評価軸になっていない。著者自身が導入で「cAI の限界は外部検証の欠如と不十分な較正」と問題提起しているのに、 | 「SHAP上20変数のモデルを外部検証し従来の重症度スコアより高いAUCを得た」と記載。ただしこのコホートで外部検証したかがレポートの範囲 |

| #  | モデル／予測主体                                                                                  | 対象・症例数                                                            | アウトカム                                                                           | 識別能 (AUC/AUROC)                                                        | 較正                                                                                               | 外的妥当性                                                                                 |
|----|-------------------------------------------------------------------------------------------|-------------------------------------------------------------------|---------------------------------------------------------------------------------|------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
|    |                                                                                           |                                                                   |                                                                                 |                                                                        | 報告は<br>AUC 中心                                                                                    | では確認できない                                                                              |
| 16 | 長期ICU在室の<br>予測モデル<br>(APACHE II /<br>APACHE III /<br>SAPS II をそれぞれ用いた3つの<br>多変量ロジスティック回帰) | JIPAD<br>79,620例<br>(2015–<br>2019。<br>85,558例<br>から除外<br>後)      | ICU在室<br>>14日<br>(実測<br>2,364例<br>=<br><b>2.97%</b> 。<br>欧米の先行研究は<br>4～<br>11%) | <b>AUCの具体値が示されていない。</b> 本文は「これらのモデルは良好だった」と記述するのみ<br>(ROC曲線は Figure 4) | 記載なし                                                                                             | 内部のみ。<br>部検証なし<br>2015–<br>2019年= COVID-19<br>前のデータ                                   |
| 17 | SOFA(ロジスティック回帰で再較正したうえで評価)                                                                | JIPAD<br>128,134<br>例。 <b>末期腎不全 (ESKD)群 vs 非ESKD群</b>             | 院内死亡                                                                            | <b>ESKD 0.789 (0.774–0.804) vs 非ESKD 0.846 (0.841–0.850)</b>           | 較正プロットは <b>両群とも良好。ただし ESKD 群では院内死亡を過大評価</b>                                                      | 同一DB内サブグループ比較。 <b>再較正してもなお ESKD で識別能が低い</b><br>(腎ドメインが慢性の状態に固定され実質5ドメインになるため、と著者説明)   |
| 18 | GOSSIS-1 (機械学習ベースの国際モデル) vs<br>APACHE-II /<br>APACHE-III /<br>JROD                        | JIPAD<br>2015–<br>2022( <b>検証コホート。開発データより高齢・予定手術が多い・在室日数が長い</b> ) | 院内死亡                                                                            | <b>GOSSIS-1 0.908 / APACHE-III 0.908 / JROD 0.910 (4モデルでほぼ同一)</b>      | <b>SMR: APACHE-II 0.39 / APACHE-III 0.46 / GOSSIS-1 0.89 / JROD 0.97 (0.96–0.99)。同じコホートに当てると</b> | <b>本表で数少ない真の外部検証。</b> ただし疾患カテゴリー別では神経疾患、外傷で較正が不良、<br><b>2020年のパンデミック期に全カテゴリーで性能低下</b> |

| # | モデル／予測主体 | 対象・症例数 | アウトカム | 識別能 (AUC/AUROC) | 校正                    | 外的妥当性                             |
|---|----------|--------|-------|-----------------|-----------------------|-----------------------------------|
|   |          |        |       |                 | けで SMR<br>が4倍以上<br>開く | (APACH<br>III より<br>GOSSIS<br>顕著) |

## △ 注意

この表から読み取るべき5つのこと

- ① **識別能と較正は独立に壊れる**。#3 の APACHE III-j は AUROC 0.915 のまま SMR 0.48。「誰が危ないかは分かるが、死亡確率を2倍以上言いすぎる」。**較正のずれは再較正で直せるが、識別能の低下は係数の更新か新しい予測因子が要る。**
- ② **外的妥当性が検証されているモデルはごく少ない**。表18件のうち独立コホートでの外部検証を経ているのは **#11 と #18 の2件だけ**。#6・#7～9・#10・#13・#14・#16・#17 はいずれも内部検証(または単施設・同一DB内)にとどまり、#15 は「外部検証した」と述べているが検証コホートが特定できない。**AUCの大小より、どこで検証されたかを先に見る。希少疾患ではさらに「何人で検証したか」が効く**——二次性HLHの HLH-Risk-Calculator は AUC 0.845/平均0.882 だがホールドアウトは**32～43例**、主要予測因子 sIL-2R の**測定率は40%**で欠測が重症度と相関しうる(二次性HLHの機械学習予測は本物か — 167例で構築したHLH-Risk-Calculatorの到達点と、希少疾患のデータ律速(エディトリアル・ICM2026))。**律速は手法ではなくデータ量であり、外部検証まで診療判断に使わない**。**#14 は「AUROC 0.827」という見栄えのする数字の裏で感度が 0.54 しかない好例で、AUCは感度・特異度のトレードオフ全体の要約であって、実際に使う閾値での性能ではない。**
- ③ **単一疾患に絞ると AUROC は下がる(spectrum effect)**。#5 の 0.70前後を「モデルが壊れた」と読むか「集団が均質化しただけ」と読むかは分かれる。ノート側でもこの点を最大の論点として指摘している。**AUCは集団の異質性に依存する数字であって、モデルの絶対的な良さではない。**
- ④ **数字が「ない」ことも情報**。#12 は AUROC も較正も算出しておらず、#13(qSOFA)は抄録段階で AUC が記載されていない。**#16 に至っては「予測モデルを開発した」という論文でありながら AUC の具体値が示されていない。出所の確認できない数字を補って表を埋めない**。「SIRSより上、CURB-65/PSIより下」という順位だけが確定しているという書き方に留めるのが正しい。なお qSOFA はもともとベッドサイドで3項目を数えるだけのスクリーニング(=変数を固定してノイズを減らす装置)であり、精度で PSI に勝つことを狙った道具ではない。**#3～#4 の APACHE III-j → JROD と同じで、道具の目的を取り違えると性能比較そのものが的を外す。**
- ⑤ **同じモデルでも、切り出す集団を変えると較正は壊れる**。#17 は SOFA が ESKD 群で識別能低下(0.846 → 0.789)と死亡の過大評価を同時に起こし、#18 は GOSSIS-1 が神経疾患・外傷で較正不良になる。同じ現象は JROD を9つの臨床的サブグループに当てた検証(**大半で較正不良、再較正すると「out-of-control」信号が減った**:サブグループごとにモデルを再較正しないと質評価が誤作動する(JIPAD 14513例・9サブグループ・JClinEpi2023))や、中毒患者での APACHE III(**AUROC 0.895 と識別能は良好なのに SMR 0.426=約2.3倍の過大評価**：

ICUの成人中毒患者は向精神薬が58.5%・院内死亡4.5% — APACHE IIIは死亡を2倍過大評価(JIPAD 1930例・94ICU・ToxicolRep2026))でも報告されている。「**当院のSMRは〇〇です**」は、**モデル名と対象集団を書かなければ数字として意味を持たない**(#18 では同一コホートでSMR 0.39~0.97)。

## 6. 診断エラーの実測 — 剖検という物差し

Tejerina 2012(スペイン・25年・連続834剖検):ICU死亡例で主要な診断乖離 **154例(18.5%)**。Goldman 分類で **class I(治療を変えていたはずの誤診)63例(7.5%)**、**class II(重大だが治療は変わらなかった)95例(11.4%)**、剖検でも死因不明 **22例(2.6%)**。**25年間で乖離率は横ばい**(class I 中央値8.5%、class II 中央値 13%、Pearson  $\chi^2$  p=0.2997、Goodman-Kruskal  $\tau$ =0.0025)。

見逃しの内訳(剖検で判明した所見の件数):**肺塞栓 24**、**肺炎 23**、**二次性腹膜炎 12**、**侵襲性アスペルギルス症 8**、**感染性心内膜炎 8**、**心筋梗塞 8**。ただし **内訳は時代とともに入れ替わっている**。肺炎は直近6年で診断精度が明らかに低下(2001-03 で8例、2004-07 で11例)、心筋梗塞と腸間膜虚血は近年ほぼ消失、肺塞栓は一貫した変化なし。

なぜ見逃されるのか(同研究の考察)。

| 疾患           | 見逃しの構造                                                                                                                     |
|--------------|----------------------------------------------------------------------------------------------------------------------------|
| 肺塞栓          | 螺旋CTがあっても24例。著者は <b>末梢の塞栓が主体</b> だった可能性を指摘                                                                                 |
| 肺炎(人工呼吸中)    | 同グループの253剖検で、「X線浸潤影+3臨床基準のうち2つ」の <b>感度 64.8%・特異度 36%</b> 、3基準すべてを要求すると <b>感度 15.5%・特異度 91%</b> 。 <b>VAPを「否定した」つもりにならない</b> |
| ARDS         | 382剖検との比較で臨床定義の <b>感度 75%・特異度 84%</b> にとどまる                                                                                |
| 二次性腹膜炎       | 主因は <b>消化管穿孔</b> 。意識障害・麻薬使用・免疫抑制・人工呼吸が腹部所見をマスクする                                                                           |
| 感染性心内膜炎・心筋梗塞 | 重症患者では <b>心疾患への疑いの目が低い</b> 。Perkins らは <b>剖検を受けた患者のうちICU滞在中に一度でも心電図を取られていたのは55%のみ</b> と報告。心内膜炎は経食道心エコーでも見落としうる             |

ICM2025 の解説が引く数字:ICU転送または死亡した一般内科入院患者 **2,428例中550例(23%)**で診断エラー、**436例(17.8%)**で害または死亡に寄与。剖検乖離の系統的レビューでは主要な見落とし診断の統合推定値 **19%**、そのうち **約1/3は生前に診断されていれば生存を変えた可能性**。対比として一般内科入



院患者の有害な診断エラー率は約 **0.7%**。**モニタリング・画像・検査技術がこの数十年で進歩したにもかかわらず、率は変わっていない。**

**Bergl 2019 (CCM) — 剖検ではなくカルテレビューで測った1本:** 重症患者における診断エラーの頻度と影響 (CCM2019)。米国単施設の内科系ICU (26床・クローズド) で、**予定外入室 256例** (2,105件から無作為抽出した434件を除外基準でふるったもの) を**改変 Safer Dx による2段階カルテレビュー**にかけ、**18件 (7.0%)** を診断エラーと確定した。**この分母は「死亡かつ剖検された症例」ではなく生存例を含む連続入室例である** ため、上の 18.5% とは別のものを数えている。

この論文で実務に効くのは頻度そのものではなく、**時間軸と害の分布**である。

| 指標                     | 数値                                                                                                     |
|------------------------|--------------------------------------------------------------------------------------------------------|
| 診断エラー                  | 18/256 (7.0%)                                                                                          |
| ICUチームが入室24時間以内に気づけたもの | 6/18 (33.3%)                                                                                           |
| 害あり (6段階で1点 = 害なしが0件)  | 18/18 (100%)                                                                                           |
| うち「相当の害」以上 (4点以上)      | 6/18 (33.3%)                                                                                           |
| うち死亡に寄与                | 2/18 (11.1%)                                                                                           |
| 多変量で残った因子              | 女性 (入室時 OR 5.18, 1.34–20.08 / 24h OR 11.6, 1.37–98.6)、入室時 qSOFA ≥ 2 (OR 5.73, 1.72–19.01)              |
| DEER で最多の失敗            | 競合する診断に重みを置きすぎた <b>100%</b> / その診断を考えるのが遅れた <b>89%</b> / 最終診断への考慮不足 <b>83%</b> / 病歴の重み付けの失敗 <b>67%</b> |

#### △ 注意

「すべてで害があった」を単独で引用しない "All errors were associated with harm" は **6段階の害スケールで1点(害なし)が1件も無かった**という意味であり、内訳は **軽微な害が12件(66.7%)、相当の害以上は6件だけ**である。旧記述は「そのすべてで患者に害があった」で止まっており、害の重みの分布が抜けて過大に読めた(2026-08-15にPDF照合で訂正)。あわせて、**この研究は preventability(防ぎえたか)を判定していない**——判定したのは「機会損失があったか」と「害の程度」の2つだけで、Goldman 分類 class I のような反実仮想は含まない。**判定者間一致率( $\kappa$ ・ICC)も意図的に測られていない**ため、18件という数字の再現性は本論文からは分からない。

**当院への持ち込み方**: 本研究は **介入を一切検証していない**(著者も「認知的失敗を減らす介入の検証は今後の課題」と結ぶ)。引けるのは設計の含意ひとつだけで、**IHI Global Trigger Tool の発想=「予定外ICU入室そのものをトリガーとして扱う**」である。当院では **RRSコール後の入室・病棟からの予定外入室**がこれにあたり、事後検証に「入室前後で診断名が変わったか」の1欄を足せば同じ物差しが手に入る。誤った作業診断の側に「敗血症」が18件中7件現れ、最終診断は**膿瘍・骨髓炎・穿孔・心内膜炎・化膿性関節炎**というソースコントロール要件だった——これは §7 の「症候群アプローチが精度を落とす」を症例レベルで裏づける。

紹介者(内野先生)のコメントが本質を突いている —— 「人工呼吸器設定や栄養組成のような『集中治療っぽい』判断は、ある程度の知識があれば大外れはなく予後への影響も不明確なことが多い。しかし **診断は答えが一つしかなく、当てるか外すかが予後に直結する**。集中治療で最も重要なものは診断だが、研究対象になりにくく教えにくいので、情報量も個人の能力も向上しにくい」。**これは論文本文ではなく紹介者の言葉である**。

剖検は「診断の当て外れ」だけでなく「臨床では数えられていない合併症」も見せる。[COVID-19患者のECMO中の頭蓋内出血\(ドイツ剖検登録\)](#)(DeRegCOVID、29施設・確定COVID剖検 1,129例=ECMO 63例/非ECMO 1,066例)では、**何らかの出血が ECMO 56%(35例)vs 非ECMO 9%(100例)、頭蓋内出血(ICB)が 21%(13例)vs 3%(30例)**(いずれも  $p<0.0001$ )。しかも **ICBが直接死因または原死因とされたのは ECMO例の 78%(非ECMO 37%)**で、ECMO例の直接死因は多臓器不全 → DAD/ARDS → **頭蓋内出血** の順だった。

この数字が判断の質にとって重要なのは、**生前のデータでは同じ合併症がはるかに小さく見えている**からである。ELSO登録の7,579例(2007–2018)では**ICBは4.5%**にとどまり、他の後ろ向き研究のレンジは **6～35.4%**。**「臨床で拾えた頻度」と「体を開けて見た頻度」が5倍違う**ということは、ICU死亡例の剖検乖離18.5%と同じ構造の話で、**見ていないものは統計に載らない**。実務的な含意はひとつ —— 「ECMO中の意識変化を鎮静で説明しきらず、頭部画像の閾値を下げる」。

## caution

ただしこの21%を発生率として引用してはならない **これは「ECMO中に死亡した患者の剖検」であり、生存例を含むECMO患者全体の発生率ではない**。著者自身、致死例のみで構成されるため出血例が過剰に代表されうると明記している。逆向きのバイアスもあり、**第1波では職業曝露への懸念から脳の検索が省略され、ICBがむしろ過少報告された可能性も指摘されている**。加えて**抗凝固の方法と時期のデータが欠落しているため、この研究から抗凝固戦略の示唆は導けない**。§6 冒頭の「引用時は必ず分母を添える」がそのまま当てはまる。

## △ 注意

3つの数字が食い違って見えるのはなぜか **7%(Bergl, ICU入室256例) / 18.5%(Tejerina, ICU死亡剖検834例) / 23%(ICM2025が引く2,428例)** は、**分母も判定法も違う**。剖検乖離は「死亡例のうち剖検に回った症例」に限られ(本研究の剖検率30.3%)、カルテレビュー研究は「エラーと判定された症例」に限られる。**互いに検算できる数字ではないので**、引用時は必ず分母を添える。文献上のレンジは入院患者全体 5~40%、ICU患者 7~32% とされる。

## 7. なぜ見逃されるのか — 認知とシステムの両輪

認知的要因 (ICM2025 の整理)

- アンカリング・バイアス (初期印象への過度の依存)
- アベイラビリティ・バイアス (想起しやすい診断を優先)
- 早期閉鎖 (premature closure) (診断推論を早く打ち切る)
- 確証バイアス (疑っている診断を支持する情報を探し、矛盾する所見を割り引く)
- 個人レベルの過信と自覚されていない知識のギャップ
- **侵襲的手技・機械による治療が、病歴聴取・身体所見・診断推論という古典的だが有効な手法から注意を逸らす**
- これらは**高ストレス・過重労働・疲労**で増強される (=occasion noise の温床)

システム要因

- コミュニケーションの失敗、評価のフォローアップ・調整の不備、**電子カルテの設計・使用の最適化不足**
- **集中治療の「症候群アプローチ」自体**。敗血症・ARDS・せん妄といった症候群は感度も特異度も低く、**異質な病態をひとまとめにして診断・治療の精度を落とす**

土台の劣化も効いている：ベッドサイド診療を取り戻す戦略(NEJM2025) は、**現在の研修医が患者と直接接触している時間はわずか13%、外来の診断エラーの半数以上が不十分な病歴聴取と身体診察の誤りに帰属される** と指摘する。技能低下がテクノロジーへの過度な依存を生み、過剰検査とコスト上昇を招き、ベッドサイド技能を教えられる指導医自体が減って衰退が自己増殖している。

何を見て判断しているのか自体が怪しい：ショックの臨床徴候はどこまで使えるか — 10徴候の系統的レビュー(Letter・ICM2023) は、25研究・67,894名から **有効なショックの臨床指標として同定されたのは4つだけ**(末梢灌流／温度の低下、CRT延長、網状皮斑、ショック指数  $\geq 0.7 \sim 0.8$ )と報告した。**頻脈・頻呼吸・尿量低下を支持した研究はごく少数、意識状態の変化・発汗・末梢動脈の触知の質は報告が1件もなかった。**つまり日常的に使っている徴候の多くは、エビデンス上は裏づけがない。

同じ両輪を、既成のフレームで組み直したのが SEIPS の1本(ICM2026)。上の「認知的要因／システム要因」という並置に対し、SEIPS(Systems Engineering Initiative for Patient Safety)は診断プロセスを人・課題・道具技術・組織・物理環境の5要素が作る**作業システム**の産物として扱う。**違いは重心で、SEIPS 版は「認知バイアス教育」を主戦場から外し、非懲罰的文化・診断タイムアウト・構造化申し送り・診断スチュワードシップというシステム側の設計に寄せる。**もう1点、**過剰診断(overdiagnosis)を見落としと同等の診断エラーとして数える**のは ICM2025 側になかった視点で、当院の M&M の選定基準に直接効く。**ただし What's New の短報で新規データはなく、SEIPS を ICU に当てた効果は未検証。**

予防戦略(ICM2025)：認知面＝批判的思考の教育とモデリング、**認知バイアスを明示的に議論する**、症状ベースの診断ワークアップ。システム面＝**診断チェックリスト、標準化された申し送りプロトコル、多職種でのレビュー戦略**(いずれも診断エラー率の低減に有効)、**ICU後フォローアップ外来を診断の検証装置として使う**、標準化されたレビュー手法(Revised Safer Dx Instrument、修正 DEER taxonomy)、そして **非難しない安全文化(non-blaming safety culture)**。

#### 図の解説

「非難しない文化」は日本ではまだ空文 第二の犠牲者症候群の日米比較 — 日本の医療者は3倍「辞めたい」と考える(PSM・CritCare2026) は、職種・診療科・経験年数を1:1マッチした185ペアで、**日本の医療者は重大エラーへの関与報告が圧倒的に少ないのに(11.9% vs 73.0%)、罪責感(94.6% vs 61.6%)・不安(84.9% vs 55.7%)・訴訟への恐怖(76.2% vs 42.2%)がはるかに強い**ことを示した。**重大エラー後に離職を考える割合は 30.8% vs 8.6%** と3倍以上。しかも支援体制は高く評価しながら(83.8% vs 70.6%)実際には同僚に相談しない(48.6% vs 61.1%)。**診断エラーを測る前に、報告できる土壌があるかを問う必要がある。**著者の提言は「助けを求める負担を個人からシステムに移す」＝申請制をやめ、重大事例後のチームデブリーフィングを既定ルーチンにすること。

## 8. ノイズ低減策① アルゴリズム — と、その副作用

アルゴリズムは一貫性を供給する。しかし導入すれば済む話ではない。原著が挙げる残課題を全件。

| # | 課題                 | 内容                                                                                                                         |
|---|--------------------|----------------------------------------------------------------------------------------------------------------------------|
| 1 | 性能の検証              | 学習データ上の性能だけで有効性を仮定してはならない。 <b>誤ったモデルの出力を臨床医に提示すると判断精度が下がる</b> (Jabbour, JAMA 2023)                                         |
| 2 | 教師ラベルのノイズ          | 一貫性のない専門家判断に由来する診断ラベルで学習すると、 <b>モデルに誤差が持ち込まれる</b> (Sylolypavan, NPJ Digit Med 2023)                                        |
| 3 | アルゴリズム固有の弱点        | ハルシネーション、不整合、faithlessness (出力が根拠に忠実でない)、データ希少性への弱さ、複雑性への対処困難                                                              |
| 4 | 意図せぬ帰結             | 差別的なモデルは <b>社会的不平等を強化しうる</b>                                                                                               |
| 5 | holistic synthesis | 臨床医はアルゴリズム出力をそのまま使わず、広い判断過程の1つの手がかりとして統合する。モデルに入っていない要因に気づける点で有利とされるが、 <b>他分野では「人間は例外を作りすぎ、ノイズを増やして精度を下げる」という反直感的知見がある</b> |
| 6 | 出力の無視・不採用          | アルゴリズム出力がそもそも使われない。要因は <b>モデルや予測因子定義の透明性の欠如</b> による不信                                                                      |
| 7 | ブラックボックス論への反論      | <b>人間の意思決定もブラックボックスである</b> 。人は自分の意思決定過程を言語化できないことが多い。 <b>アルゴリズムは不透明でも厳密に検証・実験できるが、人間の意思決定でそれを行うのははるかに困難</b>                |

#### △ 注意

ノイズ低減策の副作用 — 個別化を損なう プロトコル化・アルゴリズム化は定義上、判断のばらつきを減らす。だからこそ本来必要だった個別化まで削る。当院の SBT プロトコル・輸液プロトコル・輸血トリガーから「この患者は特別だから」と外す判断は、例外を作りすぎている可能性と、正当な個別化である可能性の両方がある。区別する唯一の方法は 外した理由を記録して後で見返す 運用にすること。これで例外運用の妥当性が事後に検証可能になる。なお、この副作用の裏返しとして PEEP設定にAIとデジタルツインを使う準備はできているか(Correspondence・ICM2024) は「最適なPEEPとは単に肺にとって最良のもの」という考えは単純すぎる とし、目標は時間とともに変わり、目標に応じてターゲットも変わると述べる。同じ患者でも、単一臓器不全のときとAKI・右心不全・脳損傷を伴うときで最適値が違ふ。結語は明快 —— 「技術はモニタリング能力と潜在的な解決策を提供できるが、ケアのゴール (goals of care) は臨床医の専権事項である」。

## 9. ノイズ低減策② 独立した判断の平均化

| 論点     | 内容                                                        |
|--------|-----------------------------------------------------------|
| 原理     | 「wisdom of the crowd」。独立した判断はランダム誤差を含むが、平均すると誤差が相殺される     |
| 効果の大きさ | ノイズは平均する判断数の平方根に比例して減少する (4人で1/2、9人で1/3)                  |
| 限界(重要) | 平均化はノイズを減らす但バイアスには効かない                                    |
| 個人内平均化 | 同一臨床医が時間をおいて行った複数判断の平均も精度を上げうるが、非冗長(異なる視点・異なる情報に基づく)場合に限る |
| 独立性の条件 | 社会的影響や集団力学で独立性が損なわれると、効果は大きく削がれる                          |
| 提案     | 臨床医が独立に評価し、それを体系的に集約する仕組みを設計する                            |



## 重要

個人 vs 群 — この Home で最も鋭い緊張 ノイズ論文は「アルゴリズムを使って個々の判断のばらつきを消せ」と言う。一方で ICUスコアリングシステムの40年 (Lasting Legacy・ICM2022) は40年の教訓として「**スコアや予測を個人に適用することは、そのスコアの開発に内在するバイアスを永続させ、倒錯した行動 (perverse behavior) を引き起こしうる**」と警告し、重症度スコアは当初 個々の患者への適用のために開発されたが、臨床医はすぐに患者「群」のリスク調整済み転帰を比較するのに最も適していると学んだと述べる。両論併記：どちらも正しい。整理するとこうなる —— 「スコアで死亡確率を告げる (個人への数値の適用)」は避けるべきだが、「スコアが求める同じ変数を全員が同じ方法で集める (測定と記録の標準化)」はノイズ低減として有効。前者は倒錯した行動を招き、後者はくじ引きを減らす。**混同すると議論が噛み合わない。**

## 10. AIを3層に分けて読む 🤖

① 予測AI (predictive AI) —— 「起こる確率」を予報する。早期警告は与えられるが、「何をすべきか」は導けない。純粹に関連 (association) に依拠するため。集中治療における人工知能の未来 — 予測AIから行動可能なAIへ (What's New・ICM2023) の例が秀逸 —— 「緩和ケアコンサルトとノルアドレナリン投与はいずれも患者死亡を強く示唆するが、どちらかを中止すれば死亡確率が下がると結論するのは合理的でない」。

Vault内の予測AIの実例が 深層学習でICU退室後1年までの死亡を予測しSHAPで説明する (JIPAD・透明なcAI開発の枠組み・AnaesthCritCarePainMed2022) (→ §5 表 #15)。JIPAD で DNN を学習させ、ICU 死亡 AUC 0.94・院内死亡 0.91、**ICU退室からの日数によらず1年を通じて 0.91～0.95 を維持** した。説明可能性には SHAP (SHapley Additive exPlanations) —— ゲーム理論に基づき、モデルへの寄与度の順に変数を統計的に決定・抽出してブラックボックスの解釈を可能にする手法 —— を用い、**抽出した上位20変数のみのモデルでも従来の重症度スコアより高いAUCを得た**。実務的な含意は「**100項目を集めなくても、適切に選ばれた20項目で足りうる**」。ただしこの論文は、この Home の読み方をそのまま自分に返される構造になっている。著者自身が導入で「臨床AI (cAI) の限界は外部検証の欠如と不十分な校正」と問題提起しながら、報告されているのは **AUC (識別能) が中心で校正の評価が薄い**。ノート側は加えて「上位20変数の外部検証がどのコホートで行われたか明示されていない」「従来スコアとの比較が同一コホートでの head-to-head ではなく文献値との比較の可能性がある」「SHAP を使うこと自体は説明可能性の一手段にすぎず、『枠組み』と呼ぶには何をどう検証すべきかの規範が要る」と指摘している。「**ICU退室後1年の死亡を入室時データで当てられる**」という所見が治療の差し控えの根拠に使われうる、という倫理的含意が論じられていない点も、§13 の自己成就の議論と接続する論点として残る。

② 行動可能なAI (actionable AI) —— 代替的な治療判断から生じるアウトカムを予測し、比較して最適治療を助言する = **因果推論**。医学では伝統的にRCTが担ってきた。観察研究では**交絡バイアス**と**選択バイアス**



に加え、ICU特有の **時間依存性交絡 (time-varying confounding)** が立ちはだかる。ICUの治療は**逐次的な意思決定の連鎖**(レジーム)だからで、単純な回帰や傾向スコアマッチングでは足りない。事例は Shahn らの target trial emulation (周辺構造モデル・制限的輸液戦略)と Komorowski らの強化学習(輸液・昇圧薬の最適投与量)。しかし**両者とも観察データに依拠しており、統計手法もML手法も因果推論の成功を保証できない**。さらに **有効サンプルサイズ(effective sample size) = モデル化されたレジームと観察されたレジームが一致する患者履歴の数** が典型的に限られる。著者の現実的な見通しは、**汎用AIではなく「特定の患者群・臨床シナリオの特定の治療判断に限定された狭いAI(narrow AI)」**。

Vault内の事例が 強化学習で導いたバソプレシン開始ルール(JAMA2025)。モデルは臨床医より「**より多くの患者に、より早く、より低いノルアドレナリン用量で**」バソプレシンを開始することを提案した(開始割合 **87% vs 31%**、開始時間 中央値 **4時間 vs 5時間**、開始時NA用量 **0.20 vs 0.37 µg/kg/min**)。ルールに近い開始が行われた場合の院内死亡は **調整OR 0.81 (0.73–0.91)**。**ただし観察データに基づく因果推論であり、RCTではない**。「早く・低用量から」は、重症度の低い患者にバソプレシンが入りやすいという交絡と区別しにくい。プロトコル化の根拠にはならない、仮説として扱う。

③ **生成AI・LLM** —— ChatGPTは集中治療医の診療をどう変えるか — 応用・リスク・限界(エディトリアル・ICM2023) は応用5つ(臨床判断支援／診療記録の処理／医学教育／コミュニケーション／学術論文執筆)と限界5つ(ハルシネーション／誤用＝データ捏造・剽窃／バイアスの再生産／データプライバシー／職業の自動化と社会的リスク)を整理する。著者らの基本姿勢は「**現時点のChatGPTは(完全には)信頼できない**」。**存在しない文献・引用・PubMed IDを捏造する**。当院での実用的な線引きは、**誤りが致命的になりにくい領域(退院サマリー草案・記録の整形)から入り、臨床判断支援は最もハルシネーションのコストが高いと認識すること**。

その線引きを実務で検証したのが LLMがICU退院サマリーから治験候補を自動抽出する — 1,342入室から133例・PPV 72%・医師レビュー時間86%削減(CritCare2026)。**患者データを外部APIに出さないオンプレ運用**(オープンウェイトモデル+11回多数決)で、治験候補のスクリーニングを 1,342件 → 185件 に圧縮できた。ここで効いているのは診断ではなく **明示的に書かれた事実の抽出**(人工呼吸日数 F1 0.966・妊娠 1.000)で、症候群的判断(敗血症 0.698・心不全 0.759・神経筋疾患 0.500)は依然として人の仕事のまま残る。**ただしAIが弾いた側を誰も検証していないため患者単位の感度は不明**＝この型は「人に渡す候補を絞る」ところで止めるべきで、除外の根拠にはならない。

#### △ 注意

「家族向けの平易な言い換え＝低リスク」という線引きは成立しない(2026-08-07 訂正) 本Homeは以前、家族向けの言い換えを「誤りが致命的になりにくい領域」に含めていたが、ECMOについての家族の質問に4つのLLMはどう答えたか — 満足できる回答はGemini 95%対DeepSeek 61% (Correspondence・CritCare2026) が実測すると、**LLMは合併症率を実測の5～10倍に見積もり**(血管損傷 約1～5%→5～30%)、**VV-ECMO期間を短く言う**(19.6日→7～14日)。家族への**予後・合併症の説明は治療方針の意思決定に直結する**のだから、低リスク領域ではない。実務上の線引きは「誰向けか」ではなく **その出力が意思決定に入るか** で引く。なお同研究で弱点とされたのは **網羅性と共感 = 面談で臨床医が担うべき2つ**。LLMは面談の入口(家族が既に読んでいる前提での土台作り)には使えるが、説明そのものの代替にはならない。プライバシー面では **全てのプロンプトがデータベースに取り込まれ訓練に使われうる** ため、患者識別情報を汎用チャットに投入しない。

**著者性(authorship)という論点** —— AIは科学論文の執筆に使えるか — ChatGPTを共著者に立てた Perspective (CritCare2023) は、**著者リストの2番目に "ChatGPT" (所属: OpenAI) を記載した Perspective** である。本論文自身の主張は次の4点に尽きる —— (1) AIチャットボット、とりわけ ChatGPT は **資料の整理・初稿の作成・校正において研究者を助ける有用なツールとして立ち現れている** (本稿の時点で、このアプローチを用いて作成された集中治療医学領域の論文は存在しない、とも明記)。(2) **ChatGPT の出力は人間の判断の代替として使われるべきではなく、重要な意思決定や応用に使う前に必ず専門家がレビューすべき**。(3) **剽窃と不正確さのリスク、および ソフトウェアが有料化した場合の高所得国と低所得国のアクセスの不均衡** という倫理的問題が生じる。(4) **科学論文執筆におけるチャットボットの使用をどう規制するかについて、まもなく合意が必要になる**。

## 重要

共著者に立てておきながら「責任は移譲できない」と書いている 著者らの結論は「**チャットボットとAIは一般に、人間の研究者の専門性・判断・人格、そして最終的には『責任』を置き換えるべきではない**」である。**ChatGPT** を著者欄に置くという形式と、責任は人間に残るという主張が、同じ論文の中で同居している —— これがこの Perspective の構造そのものであり、この Home の主題に引きつけられれば §12 の審査項目 #6(監督責任者:出力を誰が検証するか)を、著者性の言葉で言い直したものに当たる。本Homeが扱う範囲はここまで。本稿は2023年初頭の記述であり、その後 ICMJE や各誌の著者性規範がどうなったかは本論文の射程外なので、この Home では扱わない(推測で補わない)。なお同稿には**バイアス (§3)の実例**も含まれている —— チャットボット生成文の特徴とされる「ニュアンス・文体・独創性の欠如」は **母語ではない言語で書かれたテキストにも同様に見出されうるため、AI 剽窃検出器が非ネイティブの英語論文を AI 生成テキストと判定してしまう可能性がある**。判定ツールの側に系統的なズレが載るという型で、日本から英語論文を投稿する当院にとっては実務的なリスクでもある。使いどころについての著者らの所感も実務的で、**最も有効なのは「生成」ではなく「編集」**(書式と言語の編集、複雑な文の平易化、全文からの抄録作成)。**AI は新しいアイデアを生成しないが、研究者のアイデアを整理・展開し初稿をつくることはできる**。文献検索については **要約がかなり一般的になりがちで、研究間の差を批判的に分析しない** ため、抄読会の準備を丸投げしない理由として具体的である。系統的レビュー・メタ解析には人間の介入が必須、とも明記されている。

聞き方を構造化する — TCEPFT — 生成AIの出力の質は、監督体制だけでなく**入力**の作り方でも決まる。

PICO原則を生成AIのプロンプトに組み込む — TCEPFTの6要素で聞き方を構造化する(コメンタリー・JMLA2025) の提案は、**EBMで毎日使っている PICO と同じ「問いを分解して組み立てる」思考を、そのままプロンプトに移す**というもので、**新しい技能をゼロから覚える話ではない**点が実務的な利点である。

| 要素      | 意味                                        |
|---------|-------------------------------------------|
| Task    | AIに何をさせるか(identify / summarize / compare) |
| Context | 誰について、どの条件で(PICO の P にあたる)                |
| Example | 出力の方向を示す具体例                               |
| Persona | 誰のための出力か(想定読者)                            |
| Format  | 箇条書きか、小見出し付きの段落か、表か                       |
| Tone    | 学術的か、平易か、簡潔か                              |

6行を埋めてから、論理的な流れで1本の文につなぐ。原著が挙げる利点は **精度・一貫性・柔軟性**の3つで、**最も実用的なのは3つめの「部品の入れ替え」**——Context の疾患名だけを差し替えれば(原著の例では "sleep disorders" → "drug abuse", "type 2 diabetes" → "chronic kidney disease")、**構造・想定読者・トーンを保ったまま別の問いに使い回せる**(出力が同一になることは決していないが、構造と提示形式は揃う)。JC の準備・カンファ資料・マニュアル改訂といった**反復業務**に効く。

#### caution

**この論文は有効性を検証していない COMMENTARY であり、実験・比較・評価は一切行っていない。**「PICO をプロンプトに組み込むと検索の精度・関連性が上がる」ことは本論文では検証されておらず、原著の記述も \*may enhance\*(高めうる)という留保付きである。原著自身が **「TCEPFT が唯一の方法ではない」「すべての場面でフル構造が必要とは限らない」とし、重要なのはどの枠組みを選ぶにせよ一貫して適用することだと明記する。**本Homeの文脈では、この**「一貫性」こそが §4 の主題(一貫性はそれだけでノイズを消す)と接続する点であって、「精度が上がる」の根拠ではない。**なお本論文はハルシネーション・出典の捏造に一切触れていないので、上の ICM2023 とセットで読む。

AIで「人」を代替する構想には、監督責任と別の問いが乗る —— 家族の声をAIで再現してICU患者を安心させる構想(コメント・CritCare2023) は、新生児・乳児・意識障害患者に**家族の声をAIで模倣した安心のメッセージ**を届ける構想(自然言語処理+音声クローニング+音声合成)である。①**メッセージのテキスト生成** → ②**医療者によるレビューと承認** → ③**音声模倣** → ④**音声合成**という4段のパイプラインで、**②が明示的に組み込まれている点は §12 の審査項目 #6(出力を誰が検証するか)を設計に織り込んだ例**として読める。

#### △ 注意

本Homeで書けるのは、原著が触れている範囲まで **COMMENT** であり、**患者を対象とした評価は行われていない。有効性・安全性を支持するデータは本文に存在しない**(「～しうる」に終始する構想段階の提案)。引用されているのは「家族の存在が有益」「情緒的支援が昏睡患者の覚醒に重要」という先行研究であって、**AIによる合成音声と同じ効果を持つ根拠にはならない。**倫理面についても、原著は「一定の課題と考慮事項に対処する必要がある」と述べるにとどまり、**家族の音声を使うことへの同意・なりすまし・患者が本人と誤認するリスク・データ保護**といった具体的な検討は本文で展開されていない。本Homeはこの「論じられていない」という事実までを記録し、原著にない倫理的結論を代わりに書かない。実務的には、**家族本人が録音した実際の音声メッセージなら合成なしで同じ目的を達しうる**(本論文はそれとの比較を行っていない)というのが、原ノートが置いた現実的な代替案である。

なぜ普及しないのか：AIがICUで普及しない3つの理由 は「致死の三要素」として ①データの質 (GIGO・公正なML・外部検証の事前計画) ②倫理的・法的側面 (学際的コラボ・データ共有の法整備・機器認可) ③教育 (研修医ロードマップ・統合された医療AI部門) を挙げる。外部検証の実現可能性を事前計画することがリソース配分に必須という指摘は、上の §5 の表がまさに示している通り。

## 11. AIと人の相互作用 — アンカリングと受容

Vault で最も方法論的に強いAI論文が AIによる心機能評価 vs 検査技師 (盲検化RCT, Nature 2023)。LVEFの初期評価をAIにするか技師にするかを盲検下で無作為化したワークフロー試験である。

- 主要アウトカム (初期→最終循環器医評価で5%超の変化) : AI **16.8%** (292/1,740) vs 技師 **27.2%** (478/1,755)、差 **-10.4%** (95%CI -13.2~-7.7)、非劣性・優越性ともに **P<0.001**
- 安全性副次 (最終評価 vs 過去の独立した循環器医評価の平均絶対差) : AI **6.29%** vs 技師 **7.23%**、差 **-0.94** (-1.34~-0.54)、**P<0.001**
- 盲検の質: **Bang's blinding index** はAI群 **0.088**・技師群 **0.075** ( $\pm 0.2$ 以内=良好な盲検)。判読医の予測は正解 32.3%/不正解 24.2%/判別不能 43.4%
- 時間: 技師の計測時間 中央値 **119秒** → **0秒** (差 -131秒)。循環器医の判読時間 **54秒 vs 64秒** (差 -8秒)
- 臨床閾値 (事後解析) : 初期→最終で **EF 35%** をまたいだ検査は AI **1.3%** (22/1,740) vs 技師 **3.1%** (54/1,755)、**P=0.0004**

### 重要

効果の正体は「AIが正しい」ではない 著者自身が指摘するとおり、勝因の一部は **初期値に人が引きずられる (アンカリング)** である。初期評価と最終評価の差 (2.79/3.77) は、最終評価と過去の循環器医評価の差 (6.29/7.23) より明らかに小さい。**良い初期値をワークフローの上流に置くと、下流の人間の出力が安定する**。これは §4 の「一貫性がノイズを消す」とまったく同じ構造で、当院の申し送り・レポート運用にも転用できる発想。サブグループも示唆的で、画質 **poor** では差が消え (**-0.05**、**95%CI -1.04~0.97**)、判読医が「AIだ」と気づいた検査ではむしろ差が消える (**-0.18**)、判別不能だった検査で差が最大 (**-1.72**)。気づくと人が介入して差が消えるという人-機械相互作用が読み取れる。そして最も重要な留保 —— 画質不良で左室をトレースできない274件 (3,769件の7.3%) はランダム化前に除外されている。AIは「撮れた画像の計測」を代替するが、「撮ること」と「使える画像かの判断」は代替していない。ICUの難しい体位・肥満・ドレーン留置患者では、ここが律速になる。



**アラート設計：AIによるICP上昇予測に臨床医はどう反応するか ICP-Ald国際調査(236名・ICM2025)**  
(236名開始、74%が両シナリオ完了)。

| 項目                  | 結果                         |
|---------------------|----------------------------|
| 80%確率のアラートで何らかの行動   | 84.7%(診断+治療の両方 68.8%)      |
| 60%確率               | 「何もしない／診断的措置のみ」が増加         |
| 診断的介入をトリガーする確率(中央値) | 70%(IQR 50–80%)            |
| 治療的介入をトリガーする確率(中央値) | 80%(IQR 70–90%)            |
| 予測してほしい最低ICP閾値(中央値) | 22 mmHg(IQR 20–25)         |
| 最適な先行警告時間           | 30分(45.5%が選択)              |
| 説明可能性より精度を選ぶ        | 58.7%( <b>著者らの予期に反した</b> ) |
| 「スタッフの助けになる」に同意     | 83%                        |
| 「最終的に患者転帰を改善する」に同意  | 51%(45%は中立)                |

#### △ 注意

仮想シナリオと実装現場は一致しない(両論併記) ICP-Ald は**仮想シナリオ**で 84.7% が動くと考えた。しかし実際に敗血症MLアラートを非ICU病棟で回した前向き観察研究(362アラート)では、**アラート後に新たな臨床所見を認識したのは看護師24%・医療者13%、大多数(看護師55%・医療者62%)が患者の敗血症リスク認識に変化なしと回答**、しかもアラート時点で「敗血症あり」との認識は看護師13%・医療者40%と職種間で乖離していた(敗血症予測の機械学習アラートは臨床医に響かなかった(EWS 2.0・CCM2019))。どちらが正しいという話ではない。**「導入前に聞けば動くと考え、導入後に測ればほとんど動かない」**のが実態で、当院で導入を検討するときは**期待値を後者に置き、実装後の行動変容を実測する**設計にする。なお ICP-Ald の「役に立つ 83% vs 転帰を改善する 51%」という乖離は、臨床医自身がこの落差を織り込んでいることの表れとも読める。

## 12. AIの監督責任 — 院内審査の枠組みへ

臨床でAIを監督する教育戦略 — deskilling・never-skillingを防ぐ (NEJM2025) は、LLMが知識生成と臨床推論を人間のような流暢さで模倣する点を、過去のIT革命(インターネット・電子カルテ)との決定的な違いとする。単純作業の認知的オフロードは有益だが、臨床推論や意思決定までオフロードすると4つの失敗が生じる。

| 用語              | 意味                        |
|-----------------|---------------------------|
| automation bias | 自動化システムへの過信と、それに伴うエラーのリスク |
| deskilling      | すでに獲得した技能の喪失              |
| never-skilling  | 本来身につけるべき能力を最初から獲得しないこと   |
| mis-skilling    | 誤った行動が強化されてしまうこと          |

当院でのAI導入審査に落とすと、こうなる。



| #  | 審査項目        | 何を問うか                                                                                                      | 出典                     |
|----|-------------|------------------------------------------------------------------------------------------------------------|------------------------|
| 1  | AIの型        | 予測AIか、行動可能なAIか、生成AIか。 <b>予測AIに「何をすべきか」を期待していないか</b>                                                        | 行動可能なAI・ICM2023        |
| 2  | 教師ラベルの質     | ラベルは誰が付けたか。 <b>評価者間のばらつきは測ったか</b>                                                                          | ノイズ・CritCare2025       |
| 3  | 外的妥当性       | 自施設データで <b>校正</b> を確認したか。開発集団と当院の患者像は違わないか                                                                 | §5の表・CISSS・JROD        |
| 4  | 上流工程        | AIが処理できる入力を、誰がどう選別しているか(例:画質不良の除外)                                                                         | Nature2023             |
| 5  | アラート閾値      | 何%で鳴らすか、何分前に鳴らすか。 <b>アラーム疲労の見積もりはあるか</b>                                                                   | ICP-Aid・ICM2025        |
| 6  | 監督責任者       | 出力を誰が検証するか。 <b>誤った出力が提示されたときに気づける人がいるか</b>                                                                 | Jabbour (Vault未収載)     |
| 7  | 教育設計        | 研修医の never-skilling をどう防ぐか。 <b>推論プロセスを本人に言語化させる仕組みはあるか</b>                                                 | NEJM2025               |
| 8  | プライバシー      | 患者識別情報がモデル提供者側に渡らない構成か                                                                                     | ChatGPT・ICM2023        |
| 9  | 撤退基準        | 性能劣化をどう検知し、いつ止めるか。 <b>スコアも15年で校正が劣化する</b>                                                                  | スコア40年・ICM2022         |
| 10 | バージョンと再評価周期 | 生成AIはどのモデル・どの版をいつ評価したか。 <b>LLMの評価結果は数か月で陳腐化する</b> (実例:評価2025年5月・論文受理2026年6月の13か月差でモデルの序列は引用不可)。再評価の周期を決めたか | LLMと家族の質問・CritCare2026 |

データの上流も審査対象になる。[AKIバイオマーカー研究は報告が壊れている](#) — [STARD準拠率54.5%とSTARDaki拡張\(デルファイ合意・ICM2026\)](#) や [重症治療のデータ共有・ハーモナイゼーション24原則](#) — [SCCM Data Science Campaignの系統的レビューと修正Delphi\(CCM2025\)](#) が扱うのは、モデルに入る前のデータと報告の質。**報告が壊れているデータで学習したモデルは、その壊れ方を学習する。**

### 13. 予測の精度と自己成就 — 心停止後の神経予後予測 🧠

§5 では予測モデルを「識別能・校正・外的妥当性」の3点で読んだ。心停止後の神経予後予測は、**その3点をどれだけ丁寧に測っても足りない領域**である。理由は単純で、**予測が結果を作ってしまう**からだ。この Home の主題(判断がどう誤るか)を、最も純度の高い形で見せてくれる題材になる。

### 13-1 自己成就的予言(self-fulfilling prophecy)という構造

心停止後の死亡の大半は脳死ではなく、「予後不良」という判断を受けての **WLST(生命維持治療の中止)** の後に起きる。すると「マーカーが不良 → WLST → 死亡」という経路が成立し、**マーカーの予測精度は、自分が作った結果を当てているだけ** になりうる。

これは §5 の枠組みに収まらない誤り方である。識別能も校正も「アウトカムが予測から独立している」ことを暗黙の前提に置いているが、ここではその前提そのものが崩れている。**予測因子がアウトカムの原因の一部になっている**。AIの文脈でいえば §12 の審査項目 #2(教師ラベルの質)の極限形で、**ラベルが「予測の結果として付けられた」** 状態にあたる。

### 13-2 設計で自己成就を外したらどうなったか

早期WLSTを除外した心停止後の神経予後予測(不良マーカー2つ以上で偽陽性ゼロ・CritCare2026) は、ドイツ8施設の前向き観察研究(2014–2017)で、**心停止後4週間(28日)以内にWLSTへ移行した患者を解析から丸ごと除外し、101例だけを解析した。**

| 結果                     | 数値                                                                |
|------------------------|-------------------------------------------------------------------|
| 12か月転帰                 | 不良(mRS 4–6) <b>68例 67.3%</b> (うち死亡43例＝全体の42.6%)／良好 33例 32.7%      |
| 14日以内に不良マーカー ≥2 個      | 良好転帰は <b>0/16</b> 。年齢調整OR <b>34.7</b> (95%CI 4.11–4578、p=0.00010) |
| 感度                     | 2剤併用は <b>0.00～0.19</b> (14日窓)。単独で最も感度が高いのは EEG 0.44               |
| 7日以内だと                 | 偽陽性が残る(1マーカー群 5例、≥2マーカー群 1例)                                      |
| 初回値だけで判断すると            | FPR が <b>PLR+CR 3.0%→18.2%、EEG 0%→10.0%</b> に悪化                   |
| CRS-R(14日以内ベストスコア)の上乗せ | 交差検証AUC <b>0.888 → 0.925</b> (尤度比検定 p=0.011)。効くのはマーカー0～1個の判定保留群のみ |

**自己成就バイアスの検証**が本研究の核心である。除外したWLST患者39例は、入室時点では良好群とも不良群とも臨床的に区別できなかった(Bonferroni補正後すべて p≥0.07)。ところが2週間でプロフィールが分岐

した。

| 指標(14日以内)     | WLST患者 | 不良転帰(治療継続) | 良好転帰(治療継続) |
|---------------|--------|------------|------------|
| NSE 中央値(μg/L) | 81.6   | 29.6       | 20.3       |
| SEP N20 両側消失  | 48%    | 7%         | 0%         |
| ベスト CRS-R     | 1.0    | 4.0        | 17.0       |

自己成就が主因なら、WLST患者の中に**良好転帰群に似たプロファイルの患者がまとまって存在するはず**だった。実際にはどのマーカーでもWLST患者は良好群に似ていなかった ——「早まった治療中止が結果を作った」という仮説が予測する像の、ちょうど反対である。

重要

この論文の価値は「バイアスをゼロにした」ことではない 著者自身が「観察研究である以上、自己成就予言バイアスを完全には排除できない」と繰り返し明記している。**示されたのは「バイアスの向きが逆でないこと」であって、「マーカーが判断に影響しなかったこと」ではない。**NSE 81.6 vs 29.6 vs 20.3 という差は、「マーカーが重い患者ほどWLSTが選ばれた」という説明とも完全に整合する。**論理の射程を読み違えない**——これは §8 の「アルゴリズムはブラックボックスだが厳密に検証できる／人間の判断は検証がはるかに難しい」という論点と同じ地平にある。なお 14日 ≥2マーカーの **OR 34.7 の95%CI上限は 4578**。準完全分離が起きているため、**この点推定に臨床的意味はほとんどない。報告すべきは「16例中0例が良好転帰」という素の数字のほう**である(§5 の「AUCの大小より、どこで検証されたかを先に見る」と同じ作法)。

13-3 「2つ以上」は単一指標のノイズを減らす設計

心停止後ケアガイドライン2025 ERC・ESICM — 発熱予防は37.5℃以下、予後予測は2つ以上の指標で(Resuscitation2025) は、**単独で100%正確な予測因子は存在しない**と明記したうえで、ROSC後72時間以降・覚醒せず命令に従わない(GCS運動反応 <6)患者で、交絡(残存鎮静など)を除外し、次の6項目のうち **2つ以上** がそろえば不良転帰の可能性が高いとする。

- 1 ≥72時間で瞳孔対光反射・角膜反射がともに消失
- 2 ≥24時間で N20 SSEP 波が両側消失
- 3 >24時間で highly malignant EEG
- 4 NSE > 60 μg/L(48時間および／または72時間)

5 ≤72時間の status myoclonus

6 頭部CT/MRI でびまん性かつ広範な無酸素性障害

この「2つ以上」という要求は、§9 の「独立した判断を平均する」と同じ構造のノイズ低減策である。単一指標には測定・判読・タイミングに由来するばらつき(=ノイズ)が必ず乗る。CritCare2026 が示した「初回値だけだと PLR+CR の FPR が 18.2% に跳ね上がる」という現象は、**機会ノイズ(occasion noise)が偽陽性として現れた実例** にほかならない。だから対策は2つ —— **指標を増やす(横方向の平均化)** と **繰り返し測る(時間方向の平均化)**。**繰り返し測定が特異度を作っている** のであって、指標そのものが特異的なのではない。

さらにガイドラインは運用面で2つの分離を要求する。**予後予測と WLST の判断を分けて行う**(WLSTは年齢・併存症・全身の臓器機能・患者の意向も考慮する)、そして **予後の結論は72時間以降の臨床的予後評価の時点でのみ下す**(多くの所見はそれ以前に得られてよい)。前者は自己成就の連鎖を**運用で断つ**設計であり、後者は「情報が出そう前に結論を固定する」= **アンカリング**(§7)への予防線である。2025年版はまた、**不良転帰の予測と良好転帰の予測を非対称に扱う**ことを明示した —— 不良を予測するときは偽悲観を避けるため高い特異度が要るが、良好を予測するときは偽陽性の帰結が軽いため検査性能の要求はそれほど厳しくない。**同じ検査でも「何のために使うか」で要求される性能が変わる** という、この Home の中心的な作法である。

#### 13-4 それでも研究間で数字は食い違う(両論併記)

心停止蘇生後昏睡の神経予後予測 システマティックレビュー(ICM2020) を並べると、同じ指標の性能評価が一致していないことがわかる。**どちらかに寄せず、対立として持っておく。**

| 指標                        | ICM2020(SR)                                          | CritCare2026(WLST統制コホート)                                                              | ERC/ESICM 2025(GL)                                |
|---------------------------|------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------|
| SEP<br>N20<br>両側消<br>失    | 特異度高、感度 約<br>50%。ただし 2研<br>究で偽陽性率<br>25~50%          | 感度 0.07(14日窓、TP 3/FP 0)。偽陽<br>性ゼロだが不良所見の絶対数が極めて少な<br>く頑健性に限界。系統的再評価で11例・<br>14記録が判読不能 | ≥24時間の両側消失を6項<br>目の1つに採用                          |
| NSE の<br>カットオ<br>フ        | 偽陽性率0%とな<br>るカットオフ値は<br>一定しない                        | ≥90 µg/L を採用(特異度優先)。60<br>µg/L では残余の偽陽性が生じるとする多<br>施設研究に依拠                            | >60 µg/L(48h および/<br>または72h) +<br>24→48/72hの上昇を併用 |
| 瞳孔+<br>角膜反<br>射           | ROSC 72時間後<br>でも 偽陽性率<br>6~7%、4日目以<br>降で最も低い<br>(0%) | 14日窓の最終値で FPR 3.0%、初回値だ<br>と 18.2%                                                    | ≥72時間の両側消失                                        |
| 運動反<br>応<br>(GCS-<br>M=1) | どの病期でも 感度<br>は高いが特異度は<br>高くない                        | (PLR+CR は FOUR score の一部として<br>評価。個別評価していないと限界に明記)                                    | 予後予測の開始条件(GCS<br>M<6)であって不良転帰の<br>判定項目ではない        |

読み方の指針: SEP の感度が 50% と 0.07 で桁違いなのは、**集団(3日目も昏睡が続く層に絞ったか)と、WLSTを統制したかどうか、判読の品質基準の厳しさ** が違うためで、どちらかが誤りという話ではない。NSE の閾値差 (60 vs 90) は、**「偽悲観を避ける」重みをどれだけ置くかという価値判断** が数値に化けたものである。**同じ検査でも、目的(拾い上げか、言い当てか)が変われば正しい閾値は変わる**(§11 のアラート閾値の議論とまったく同じ構造)。

### 13-5 この Home の主題への接続

- **感度と目的**: 14日窓の2剤併用の感度は 0.00~0.19。不良転帰の8割はこの基準では拾えない。「**治療の手を緩める根拠**」としてなら感度が低いことは安全側だが、「**早期にリハビリリソースを集中させる対象を選ぶ**」目的にはまったく足りない。**何のための予測かを先に決めないと、この数値は評価できない。**
- **測定のノイズは残る**: §4 で見た「APACHE の中の GCS のような判断依存変数にノイズが残る」のと同じことが、PLR+CR(用手的評価。定量的瞳孔計は偽陽性を減らすとの報告)と EEG(判読の厳格さに依存)で起きている。
- **CRS-R の位置づけ**: 著者は CRS-R を独立した予後バイオマーカーとしてではなく、**多モーダル検査後も予後が定まらない0~1マーカー群での補完的指標**と位置づける。**「判定保留」を判定保留のまま扱う道具**を持つこと自体が、早期閉鎖 (§7) への対策になる。

## 14. エビデンス統合のノイズ — 同じ試験群から違う結論が出るとき

ノイズは臨床医の頭の中だけで起きるのではない。**同じRCT群を入力にしても、レビューする人が違えば結論が変わる** — これは「誰が担当するか」で治療が変わる lottery effect (§3) の、エビデンス統合版である。ここでは Vault にある2つの実例で、その発生源を分解する。

### 14-1 メラトニン — バイアスリスクの扱いが結論を作っていた

メタ解析が食い違うとき — 統合推定値の先を読む (バイアスリスク層別でメラトニンの効果は消える・CritCare2026) (Lakbar & Poole の Editorial) は、ICUせん妄予防のメラトニン作動薬について、**肯定的な結論のレビュー (Chaves ら) と「推奨するには不十分」とするレビュー (Lakbar ら自身)** がなぜ食い違ったのかを分解した。

| 候補                          | 検証結果                                                                                                                                                                                   |
|-----------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ① 組入れ基準の違い (臨床的異質性)         | Chaves はメラトニン+ラメルテオン、Lakbar はメラトニンのみ。しかし Chaves のメラトニン限定サブグループは RR 0.77 (0.62–0.97) で、Lakbar の RR 0.86 (0.71–1.04) と大きく重なる。 <b>これでは説明しきれない</b>                                         |
| ② バイアスリスクの扱い (方法論的異質性) = 主因 | Chaves の含めたメラトニン試験を著者らが ROB-2 で層別し直すと、 <b>高リスク RR 0.46 (0.29–0.73) / 低リスク RR 0.86 (0.70–1.05)、交互作用 P=0.01。見かけの効果は高バイアスリスク試験に偏っていた。</b> 低リスク層の推定値は Lakbar 自身の RR 0.89 (0.73–1.09) とほぼ一致 |
| ③ 一つの試験への依存                 | leave-one-out は両データセットで一致。Yin と Shi を順に外すと効果は減弱、PRO-MEDIC (Wibrow) を外すと逆方向に動く                                                                                                          |

著者らの主張は、**統合推定値は文献から抽出されるものではなく、前提の置き方によって構築される** こと、そして **バイアスリスク層別解析は「主解析を追認する感度解析」ではなく、同じエビデンスに対する対等な視点** だということ。**食い違いそのものが所見であり、不確実性を上げる方向に読む。**

### 14-2 ハロペリドール — 同じ2試験、3通りの読み方

同じ MIND-USA と AID-ICU を材料に、Vault の2つのノートが**逆向きの結論**に至っている。



|                                 |                                                                                                                              |        |
|---------------------------------|------------------------------------------------------------------------------------------------------------------------------|--------|
| 手<br>法                          | 2試験の post hoc な突き合わせ(論説)                                                                                                     | 12 RCT |
| 死<br>亡<br>の<br>扱<br>い           | MIND-USA 調整HR 1.02(0.79–1.30) vs AID-ICU 調整RR 0.84(0.72–0.98)。 <b>どちらの試験も死亡を検出する検出力を持たない</b>                                 | 治療パー   |
| 食<br>い<br>違<br>い<br>の<br>説<br>明 | ベースライン差(AID-ICU はより高齢・過活動型が多い・人工呼吸が少ない/MIND-USA は人工呼吸率95%で早期登録=より深い鎮静)とオープンラベル抗精神病薬曝露差(ランダム化前 7% vs 10%、後 13% vs 20%)で説明を試みる | 説明せず   |
| 結<br>論                          | AID-ICU の死亡低下を根拠にハロペリドールを推進するのは行き過ぎ(副次アウトカム・検出力なし)。ただし「害がある」証拠でもない                                                           | 成人ICU  |

予防については両者とも一致して否定的である。CritCare2025 の予防パートは 死亡 CIB 12%、せん妄発生 CIB 34%、SAE CIB 0%、そして **QTc延長で CIH 65%(RR 1.21、95%CrI 0.70–2.16) = 本解析で最も高い害の確率**。頻度論では予防のすべてのアウトカムで有意差なし。利益の確率が低く、害の確率が最も高い唯一のアウトカムが QTc という組み合わせは、予防的定期投与を明確に否定する方向に働く。

方法論の側から見た食い違いの発生源は3つ。

- ① バイアスリスク: 治療パートで低ROB は死亡で 4/7試験、SAEで 6試験中4試験。**2試験はせん妄評価ツールを提示しておらず高バイアスリスクと判定された。メラトニンで主因だったのと同じ変数がここでも効いている。**
- ② 統計枠組みと閾値の選択: CIB の閾値は  $RD < -0.02$  (絶対2%) /  $RR < 0.9$  と事前規定されているが、2%という値の臨床的正当化は本文にない。閾値を厳しくすれば CIB 確率は大きく下がる —— **閾値の選択が結論を作っている**。同じことは指標選択でも起きていて、予防のQTcは RD で見れば CIH 26%、RR で見れば 65%。RD 0.01 (絶対1%) が比では 1.21 になるだけとも読める。
- ③ 一つの巨大試験への依存: AID-ICU (n=1000) が治療パート1,767例の56% を占める。実質的に「AID-ICU の結果にベイズの衣を着せた解析」になっている可能性がある。**メラトニンの leave-one-out (PRO-MEDIC を外すと逆方向) とまったく同じ脆弱性。**

## 重要

両論併記 — この Home としての整理 **どちらのノートも「正しい」**。ICM2023 は「検出力のない副次アウトカムを結論に使うな」と言い、CritCare2025 は「有意/非有意の二分をやめ、利益と害の確率として提示せよ」と言う。**争点は数値ではなく、「不確実性をどう表現するか」**である。**実務上の帰結は一致していて動かない**——せん妄には多要素の非薬物的介入が第一、抗精神病薬のルーチン使用は推奨されない、予防的定期投与はしない、過活動型で安全が脅かされる場面での対症使用は許容（ハロペリドールは概ね安全で、レスキューBZDを減らす方向に働く：CIB 78%、頻度論でも唯一の有意所見 RD -0.05、95%CI -0.09~-0.00、 $I^2=0\%$ ）。**結論の言い方が割れても運用が割れないなら、それは「決着していない」ではなく「決着する必要がない」論点である。**

### 14-3 抄読会と院内プロトコル改訂の運用ルールへ

メラトニンノートが提案する3点は、そのまま当院の作法にできる。**統合推定値を読み上げて終わりにしない。**

| 確認事項                               | 見るべき場所                       |
|------------------------------------|------------------------------|
| バイアスリスク層別の結果があるか。あるなら層間で結論が変わるか    | フォレストプロットのサブグループ、付録の Figure  |
| 統合推定値を動かしている試験はどれか (leave-one-out) | 感度解析。なければ重みの大きい試験と極端な試験を目で確認 |
| 最大かつ最も質の高い試験は何を示しているか              | 重み最大の行が縦線のどちら側にあるか           |

そして **プロトコル改訂を提案する側に「低バイアスリスク試験に限った推定値」を必ず併記させる**。両者が同じ向きなら採用の後押しになり、食い違うなら条件付き（対象を絞る・期間限定・効果測定を伴う）に留める。**これは §8 の「アルゴリズムから例外を作った理由を記録して事後検証する」と同じ思想 —— 判断の根拠を後から検算できる形で残す** ということである。

### 15. 分類とコンセンサスは不確実性をどう表現するか 📁

## 図の解説

この節の範囲 以下の3本は **主題が循環器(心原性ショック)であって、この Home の主題ではない。**  
ここで扱うのは臨床内容ではなく、**不確実性をどう表現するか** という一点に限る。心原性ショックの診療そのものは各ノートを参照する。

### ① 合意しないことを、結果として報告する —— 心不全に伴う心原性ショック(HF-CS)の管理 — 34声明の国際RANDコンセンサス、20が適切・14が不確実(CritCare2024)

16名の多職種・国際専門家パネルが34声明を **1～9 の匿名スケール**で評価した修正 RAND/UCLA 適切性手法。判定基準は **中央値 <3.5 で不適切、≥3.5 かつ <6.5 で不確実、≥6.5 で適切**。結果は **20が適切、14が不確実、不適切はゼロ**。原著の設計思想が明快で、**合意(consensus)は追求されなかった —— 不確実性は妥当な結果だから**と明記されている。

- **ばらつきを数値として報告する装置**: 検証済みの不一致指数(DI)を算出し、**DI ≥ 1 でパネリスト間の不一致と定義**。不一致が見出されたシナリオは中央値にかかわらず「**不確実**」に採点される。DI > 1 だったのは **1声明のみ**——HF-CS の即時管理におけるポイントオブケア胸部超音波(中央値5、DI 1.27、IPR 4.00)。その内訳は **欧州パネリストの中央値6 vs 北米の臨床医3**で、理由として「北米で訓練不足のため普及が限られている」が挙げられている。**エビデンスではなく訓練環境の差が判断を系統的にずらしている** = §3 の**レベルノイズ**を、専門家集団のレベルで可視化した例にあたる。当院で**ノイズ監査**(→ 📱 ②)を設計するときのひな型として、そのまま使える。
- §9 の結論に、別分野の専門家パネルが独立に到達している:**IHVI・CardShock などの確立した予後スコアリングシステムを管理とエスカレーションの判断に用いることは「不確実」(中央値4)**。理由は「**よくても modest な識別能であり、HF-CS コホートでの特異度と妥当性検証を欠く**」。ところが同じスコアが「**臨床試験への登録の層別化を支援し、ケアの国内ベンチマークを促進するためには推奨**」された。「**個人の治療判断には使えないが、群の比較には使える**」という §9 の整理と完全に同じ結論である。

### ② 連続量を、意図して段階に切る —— 心原性ショック管理の進歩 — SCAI分類・表現型・出口戦略で個別化する(Concise Definitive Review・CCM2023)

**SCAI Shock Classification(A～E の5段階)** は、CS の患者・リスク患者をショック重症度で分類し死亡を予測する。本レビューの主張は、CS 集団が **心室機能・血行動態プロファイル・バイオマーカー等で定義される多様な表現型の混合体**である以上、**ショック重症度と CS 表現型を、修飾できない死亡リスク因子と統合すること**が臨床判断と予後予測を導きうる、というもの。

- **判断の質の観点**: 段階分類は §4 の「**変数と重みを固定して一貫性を供給する**」装置であり、ノイズ低減側の道具である。同時に §8 の副作用(**個別化を損なう**)を必ず伴う。本レビューがステージ単独ではなく**表現型と出口戦略(exit strategy)**を並べて置くのは、この副作用を補うための設計と読める。

- **数値の引用制限**: 本ノートは PDF の1～2ページ(抄録・KEY POINTS・Introduction・疫学と定義)からの抽出にとどまり、**各ステージ(A～E)の具体的な定義と段階別死亡率は反映されていない**。原文に明記された数値は **入院死亡 >30%、30日後 40～50%、収縮期血圧 <90 mmHg** のみ。**段階別の数字をこの Home 経由で引用しない**。

③ 段階に切った境界が、データより強く主張される —— 心原性ショックではHbが低いほど死ぬ — Hb 11 未満で1年死亡2.53倍 (FRENSHOCK 754例・JIntensiveCare2025)

| 見た数字                  | 内容                                                                          |
|-----------------------|-----------------------------------------------------------------------------|
| 四分位比較(Q4 >14 g/dL 基準) | Q1(<11)は 1か月 HR 1.64(1.09–2.47) / 1年 HR 2.53(1.84–3.49)。調整後 aHR 1.76 / 2.13 |
| だが Q2(11–12.6)も同程度に悪い | 1か月 HR 1.65(1.10–2.48) / 1年 HR 2.01(1.44–2.79)、aHR 1.72 / 1.83              |
| 制限付き3次スプライン           | <b>関係は単調で非線形性なし</b> (非線形性の p は 0.05 超)。最適カットオフは 1か月 12.6 g/dL・1年 12.7 g/dL  |
| 結論の書きぶり               | <b>「とくに Hb が 11 g/dL を下回るとき」</b> と書かれている(ノート側は「データよりやや強い表現」と指摘)             |

- **判断の質の観点(①②とは逆向きの型)**: 連続量を四分位に切った瞬間に、**存在しない閾値(11 g/dL)が読み手の頭に生まれる**。SCAI が不確実性を意図して段階に畳んでいるのに対し、こちらは **解析上の区切りが臨床上の閾値として誤読される** 型である。
- **予測の最適カットオフを、介入の閾値と読んではならない**: 著者自身が **「本知見から正式な輸血閾値を推論するのは不適切であると考える」**と明記し、多変量 Cox で輸血を共変量に入れると 1か月 aHR 0.79(0.50–1.26) / 1年 aHR 1.06(0.75–1.50) といずれも有意でない。**「Hbが低いと死ぬ」は言えても「輸血すれば助かる」は言えていない**。§5 の「AUC は実際に使う閾値での性能ではない」と同じ誤読の型である。
- **ラベルが治療の結果から逆算されている**: 本研究の SCAI ステージは **入院中の昇圧薬・強心薬・aMCSの総使用から後ろ向きに最大ステージを判定** している。分類ラベルそのものが「何をしたか」の関数であり、§12 の審査項目 #2(教師ラベルの質)と §13-1(ラベルが予測の結果として付く)に直接つながる。

## 重要

3本を並べて見えるもの 同じ「分類」でも、不確実性に対する働きが3通りに分かれる。

- ①(RAND パネル) : **不確実性を数値にして報告する**(14/34 が不確実、DI 1.27)。隠さない設計。
- ②(SCAI) : **不確実性を段階に畳んで共通言語にする**。ノイズは減るが、個別化を削る副作用を承知で使う。
- ③(FRENSHOCK の四分位) : **段階が不確実性を隠してしまう**。単調な連続関係の上に、データにない閾値が生まれる。

本Homeとしての作法: 分類を見たら「これは①②③のどれか」を先に判定する。**①なら不確実の項目を数える。②なら目的(拾い上げか、言い当てか)を確認する。③なら元の連続量に戻して見る。**

## 16. 対立点の整理(両論併記)✕

このテーマは既存ノート間で結論が割れる箇所が多い。**どちらにも寄せず、対立点を明示しておく。**

| # | 論点                 | A の立場                                                                                                   | B の立場                                                                    | 当院での扱い                                                                                                                                                        |
|---|--------------------|---------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1 | 経験は判断精度を上げるか       | ノイズ論文が引く Cox ら: <b>経験豊富な医師の ICU 死亡予測は医学生より有意に正確とはいえなかった</b> 。ICU は直感的熟達の成立条件(フィードバック・安定した関係・学習機会)を満たさない | ICM2025: 予防戦略の柱は批判的思考の教育とモデリング、認知バイアスを明示的に議論すること                         | 両立する。経験は知識と鑑別の幅を広げるが、一貫性は保証しない。教育の目標を「当てる力」から「同じ手順を踏む力」に置き換える                                                                                                 |
| 2 | スコアを個人に使ってよいか      | ノイズ論文: APACHE は二重の標準化装置。アルゴリズムでノイズを消せ                                                                   | スコア40年: <b>スコアを個人に適用すると開発時のバイアスを永続させ、倒錯した行動を招く</b> 。群の比較に使え              | 測定と記録の標準化は個人にも適用、死亡確率の数値提示は群にとどめる (§9)。 <b>HF-CS の国際 RAND パネルも独立に同じ結論に達している</b> ——予後スコアを管理・エスカレーション判断に使うのは「不確実」(中央値4)だが、 <b>試験登録の層別化と国内ベンチマークには推奨 (§15 ①)</b> |
| 3 | 説明可能性 vs 精度        | ノイズ論文: 出力が使われない主因は <b>モデルや予測因子定義の透明性の欠如</b> による不信                                                       | ICP-Ald: <b>58.7% が「基礎となるパラメータが不明でも精度の高いモデル」を好んだ</b>                     | 「説明不要」ではなく「 <b>精度が前提</b> 」と読む。院内導入では精度の検証を先に、説明可能性を運用でカバー                                                                                                     |
| 4 | 仮想シナリオでの受容 vs 実装現場 | ICP-Ald: 80%アラートで <b>84.7%</b> が行動                                                                      | 敗血症MLアラート実装: <b>大多数(55%・62%)が認識に変化なし</b>                                 | 期待値は <b>後者</b> に置く。実装後の行動変容を実測する (§11)                                                                                                                        |
| 5 | 診断技術の進歩は見逃しを減らすか   | Tejerina 2012: <b>25年間ほぼ横ばい</b> (p=0.2997)。ICM2025 も「率は変わっていない」                                         | 同研究が引く先行研究: Veress ら、Sonderegger-Iselli ら、Shojania らは <b>近年有意に低下</b> と報告 | 原著の解釈は「 <b>治療対象となる患者像そのものが変化したため見かけ上安定</b> 」。当院では <b>絶対値でなく内訳の変化を追う</b>                                                                                       |



| #  | 論点                  | A の立場                                               | B の立場                                                                                                   | 当院での扱い                                                                                                          |
|----|---------------------|-----------------------------------------------------|---------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------|
| 6  | 診断エラー頻度の数字          | Bergl:ICU入室256例中 <b>7%</b> (すべて害あり)                 | ICM2025が引く:2,428例中 <b>23%</b> 、剖検乖離の統合推定 <b>19%</b> 、Tejerina <b>18.5%</b>                              | <b>分母も判定法も違い、互いに検算できない。</b> 引用時は必ず分母を添える (§6)                                                                   |
| 7  | アルゴリズムへの「例外」        | ノイズ論文: <b>人間は例外を作りすぎ、ノイズを増やして精度を下げる</b> (他分野の知見)    | PEEP-AI<br>Correspondence: <b>「肺にとって最良」は単純すぎる。目標は時間とともに変わる。</b><br>goals of care は臨床医の専権事項              | 例外を作ること自体は否定しない。作った理由を記録して事後検証する運用にする (§8)                                                                      |
| 8  | AUC 0.70 をどう読むか     | COVID検証ノート:識別能が壊れている(通常集団の0.915と比較)                 | 同ノートの留保: <b>単一疾患に絞れば集団の均質性が上がり AUROC が下がるのは統計的に当然 (spectrum effect)</b>                                 | JCの最大の論点になりうる。AUCは集団の異質性に依存する数字だと明示してから議論する                                                                     |
| 9  | SEP N20 両側消失の性能     | ICM2020 SR:感度 約 <b>50%</b> 、 <b>2研究で偽陽性率 25~50%</b> | CritCare2026:感度 <b>0.07</b> (14日窓)、偽陽性ゼロ。ただし不良所見は3例のみで頑健性に限界、11例・14記録が判読不能                              | <b>集団・WLST統制・判読の品質基準が違い、互いに検算できない。</b> SEPを予後判定に使うなら <b>品質基準(両側の電位再現・ノイズ&lt;0.25 μV)</b> を検査依頼票に明記するのが先 (§13-4) |
| 10 | NSE のカットオフ          | ERC/ESICM 2025: <b>&gt;60 μg/L</b> (48h および/または72h) | CritCare2026: <b>≥90 μg/L</b> (60では残余の偽陽性が生じるとする多施設研究に依拠)。ICM2020 SR は <b>FPR 0% となるカットオフは一定しない</b> と明記 | どちらの水準の測定系・カットオフを使っているか院内で確認する。 <b>閾値差は技術差ではなく「偽悲観をどれだけ避けたいか」という価値判断</b>                                        |
| 11 | ハロペリドールを「治療」に支持できるか | ICM2023 論説: AID-ICU の死亡低下は副次アウトカムで検出力なし。推進は行き過ぎ     | CritCare2025 メタ解析: 死亡 <b>CIB 68%</b> ・SAE <b>CIH 2%</b> ・レスキューBZD <b>CIB 78%</b> → 治療での使用を支持する          | <b>争点は数値でなく「不確実性の表現法」。</b> 予防投与はしない/対症使用は許容という運用はどちらでも変わらない (§14-2)                                             |

## 17. Vault未収載の重要論文

この Home の議論の土台になっているが Vault にノートがないもの。 取り込み候補(対になる論文で Vault未収載) にも追記した。

| 位置づけ              | 文献                                                                                                     | なぜ要るか                                                     |
|-------------------|--------------------------------------------------------------------------------------------------------|-----------------------------------------------------------|
| 枠組みの原典            | Kahneman D, Sibony O, Sunstein CR. *Noise: A Flaw in Human Judgment*. 2021 (書籍・邦訳『NOISE 組織はなぜ判断を誤るのか』) | 本Homeの背骨そのもの。level / stable pattern / occasion noise の定義元 |
| 医師 AUC 0.68 の原データ | Cox EGM ら, 2021 (SICS コホート、医師の死亡予測)                                                                    | §5 の表 #1 の一次情報。CritCare2025 経由の孫引きになっている                  |
| 誤モデルの害            | Jabbour S ら. JAMA. 2023 (AIの診断支援が入院患者の診断精度に与える影響)                                                      | 誤ったモデル出力の提示は精度を下げる。院内審査 #6 の根拠                            |
| 教師ラベルのノイズ         | Syloypavan A ら. NPJ Digit Med. 2023 (人間アノテーションの不整合がAI判断に与える影響)                                         | 院内審査 #2 の根拠                                               |
| 臨床的予測 vs 統計的予測    | Meehl PE. *Clinical versus Statistical Prediction*. 1954 / Dawes RM. improper linear models, 1979      | MBA意思決定論との接続点。一貫性が精度に勝る の原典                               |
| 直感的熟達の条件          | Kahneman D, Klein G. *Conditions for intuitive expertise*. Am Psychol. 2009                            | §4 の3条件の出典                                                |
| 診断エラー疫学           | ICM2025 が引く「ICU転送または死亡した内科入院 2,428例・23%」の原著                                                            | 本文中の主要数値が孫引き。書誌は ICM2025の引用リストで要確認                        |
| 剖検乖離SR            | ICM2025 が引く「主要な見落とし診断の統合推定 19%」の系統的レビュー                                                                | 同上。書誌未確認                                                  |
| Goldman 分類の原典     | Goldman L ら. N Engl J Med. 1983                                                                        | class I / II の定義元。剖検研究を読むのに必須                             |
| 行動可能なAIの実例        | Komorowski M ら (AI Clinician・強化学習) / Shahn Z ら (target trial emulation・輸液戦略)                           | ICM2023 が引く2本。Vaultには解説だけがあり主論文がない                        |
| AI普及の系統的レビュー      | van de Sande D ら (集中治療におけるAI利用の系統的レビュー)                                                                | <u>AIがICUで普及しない3つの理由</u> はこれへのコメント。主論文が欠落                 |
| SOFA-2 原著         | Ranzani OT ら. JAMA. 2025 / Moreno R ら. JAMA Netw Open. 2025                                            | 既に取り込み候補に登録済み (#6・#7)。判断ベース変数のノイズを論じるのに要る                 |

## ✓ Take home

### TAKE HOME

#### 結論 — 判断の質を上げる7原則


- **判断誤り = バイアス(平均のズレ) + ノイズ(ばらつき)**。同じ幅だけ減らせば効果は等価なのに、医学はバイアスばかり見てきた
- **システムノイズは level / stable pattern / occasion の3つ**。結果として、似た患者が「誰が担当するか」というくじ引きで違う予後予測と違う治療を受ける。しかも**ノイズは相殺されず蓄積する**
- **アルゴリズムの優位は「賢さ」ではなく「一貫性」**。SICS の同一827例で **医師 AUC 0.68 vs APACHE IV 0.83**。improper な線形モデルですら一貫性ゆえに専門家を上回る
- **予測モデルは AUC の大小より「どこで検証されたか」を先に見る**。識別能と較正は独立に壊れる (APACHE III-j は AUROC 0.915 のまま SMR 0.48)。本Homeの表18件中、独立コホートで外部検証されているのは2件だけ。**同じコホートに4つのモデルを当てただけで SMR は 0.39～0.97 まで動く** (GOSSIS-1 の JIPAD 外部検証) ので、SMR はモデル名と対象集団とセットでなければ意味を持たない
- **予測が結果を作る領域がある**。心停止後の神経予後予測は、早期WLSTを設計で外しても「14日以内に不良マーカー2つ以上 → 良好転帰 0/16」と特異度が保たれた。**ただし示されたのは「バイアスがゼロ」ではなく「バイアスの向きが逆でない」こと。偽陽性は第1週に集中し、初回値だけだと PLR+CR の FPR は 3.0%→18.2%**。ガイドラインの「2つ以上」「72時間以降」「予後予測とWLSTの判断を分離」は、いずれも単一指標のノイズと早期閉鎖への対策として読む
- **同じ試験群からでも、レビューする人が違えば結論は変わる**。メラトニンは ROB-2 層別で **高リスク RR 0.46 / 低リスク RR 0.86 (交互作用 P=0.01)**、ハロペリドールは同じ2試験を「検出力なし」と読むか「CIB 68%」と読むかで結論が反転する。**統合推定値は抽出されるものではなく前提の置き方で構築される**。プロトコル改訂の提案には**低バイアスリスク試験に限った推定値を必ず併記させる**
- **診断エラーは技術では減っていない**。ICU死亡例の剖検乖離 18.5% (class I 7.5%) が25年横ばい。見逃しトップ6は肺塞栓・肺炎・二次性腹膜炎・侵襲性アスペルギルス症・感染性心内膜炎・心筋梗塞
- **ノイズ低減策には副作用がある**。プロトコル化は個別化を削り、人は例外を作りすぎる。**例外を作った理由を記録して事後検証するのが唯一の解**
- **AIは3層に分けて読む**。予測AIは早期警告どまり。行動可能なAIは観察データではバイアスを排除しきれない。生成AIはハルシネーションとプライバシー。そして**誰が出力を検証するのか**を導入前に

決める。**ChatGPT を共著者に立てた Perspective ですら「AIは人間の専門性・判断・人格、そして最終的には『責任』を置き換えるべきではない」と書いている**

- **次の設計課題は「予測モデルをどう実装するか」ではなく「学習をどう回すか」**。確信があるときは推奨し、不確実なときは妥当な選択肢の間で**ランダム化**して転帰から方針を更新する——観察データだけのオフライン学習では**適応による交絡・分布シフト・価値の過大評価**を越えられず、それを壊す道具がランダム化だから。当院で今やるべきは実装ではなく、**意思決定(誰が・いつ・どちらを選んだか)とその後の転帰を欠損なく記録すること**。記録が無ければ後からどんな手法でも因果は取り出せない
- **分類を見たら「不確実性に対して何をしている分類か」を先に判定する**。①**数値にして報告する**(RANDパネル:34声明中14が不確実、DI 1.27)／②**段階に畳んで共通言語にする**(SCAI A～E)／③**段階が不確実性を隠す**(四分位で切った Hb に、単調な連続関係しかないのに「11 g/dL 未満」という閾値が生まれる)。③**のときは元の連続量に戻して見る**

#### POINT

明日からできる、いちばん安い介入 **部長が最後に話す**。平均化によるノイズ低減はコストゼロだが、**独立性が崩れた瞬間に効果も崩れる**。最も強い社会的影響源が先に意見を言わないだけで、朝カンファと家族面談前カンファのノイズは下がる。



本ページは原論文の要約・解説です。数値は原論文から転記していますが、引用の際は必ず原論文(上記DOI)をご確認ください。原著の図表は著作権のため本ページには掲載していません(本文の「図の解説」を参照)。作成: Claude Code(聖路加ICUジャーナルクラブ運用)。