

強化早期離床は「誰に効くか」で真逆になる — 機械学習が示した死亡 −8.35%対+14.63% の異質性 (TEAM二次解析・ICM2025)

出典 Hodgson CL, Spicer AB, Broadley T, Bailey M, Bellomo R, et al. Individualised treatment effects of enhanced early mobilisation in mechanically ventilated patients: a secondary analysis of the TEAM trial. Intensive Care Med. 2025 (print: 2026;52(1):11–21). DOI: 10.1007/s00134-025-08217-0

掲載誌 Intensive Care Medicine (2025)

原著 doi.org/10.1007/s00134-025-08217-0 (本文PDFは別途)

原題 Individualised treatment effects of enhanced early mobilisation in mechanically ventilated patients: a secondary analysis of the TEAM trial



聖路加ICUでの実践への示唆

聖路加ICUでの実践

病棟プロトコルへの落とし込み(試案) ■ この論文で明日から変わるもの(結論から)

- この論文は「早期離床をやめる」とは言っていない。言っているのは「**同じ強度を全員に一律に当てる**」の一点。当院の離床プロトコルを「全員 21分/日を目指す」型から「**強度を患者背景で決める**」型に読み替える材料になる
- ただし本解析は二次解析であり、モデルそのものはまだ**臨床に実装できる完成品ではない**。使うのは「予測値」ではなく「予測を作った3つの変数の向き」

■ 今日からコストゼロで始められるもの

- **ラウンドで3つだけ声に出す**: ①昇圧薬を使っているか ②RASSはいくつか ③糖尿病があるか。この3つが本研究のモデルで重要度1〜3位だった変数で、いずれも当院の電子カルテに既にある
- **「強化してよい人」の言語化**: 予定手術後・術後心血管外科・WHODAS低値(もともと障害が少ない)・併存疾患指数が低い患者は、モデル上ベネフィット側に強く寄っていた。この層には**遠慮なく強度を上げる**方向で申し送る
- **「今日は強度を上げない」を許容する文化**: 昇圧薬あり・深鎮静・糖尿病が重なる患者で理学療法士が「今日は座位まで」と判断したとき、それを**プロトコル違反ではなく妥当な個別化**として扱う。ここが実務上いちばん変わる点

■ プロトコル化を検討するもの

- **時間軸の扱い**: ベネフィット側の患者はICU入室から無作為化までの時間が中央値 69.6時間と長く、ハーム側は 47.9時間と短かった。「入室早々の不安定期に強度を上げにいかない」という当院の実感と方向が一致する。**離床強化のトリガーを『ICU day 1』ではなく『昇圧薬とRASSが安定してから』に置き換える**案を離床ワーキングで議論したい
- **糖尿病の扱い**: TEAMの先行二次解析(Serpa Neto, AJRCCM 2024)でも糖尿病患者で高用量離床が不利だった。本解析はそれを再現しつつ「糖尿病の中にもベネフィット側が少数いる」ことを示した。**糖尿病を除外基準にするのではなく、血行動態と鎮静深度と併せて判断する運用が妥当**
- Hotel ICU の文脈では、離床は患者体験と回復を支える中核施策のひとつ。「**一律に増やす**」ではなく「**その人に合った量を届ける**」という表現に、院内向けの説明を変える価値がある

■ データで検証するもの(バイタル自動収集・JIPADとの接続)

- 当院のICUで「昇圧薬あり × RASS ≤ -3 × 糖尿病あり」がどれくらいの割合を占めるか、まず記述統計を取る。この層が多ければ、一律強化プロトコルは当院では逆効果になり得る
- 離床の実施強度 (IMSレベルごとの滞在時間) を記録できていない場合、本研究と同じ検証はできない。**IMSの日次記録を構造化データとして残す**ことが前提条件になる
- 発展形: JIPADや院内データでの個別化治療効果モデルの再現 (RRTの効果は患者によって真逆だった — 機械学習で見えた「効く群」と「害になる群」(JIPADレジストリ・CCM2026) と同じ枠組みが使える)



この論文の位置づけ (Known / Unknown / What's new)

補足

リサーチ・イン・コンテキスト

- **Known (既に分かっていたこと)**: ICU-acquired weakness (ICU獲得性筋力低下) は長期ICU滞在の最も障害的な帰結のひとつで、回復・QOL・生存を制限する。早期離床 (EM) は筋力と機能回復を高めうると複数のRCTが示してきた。一方、最大規模のRCTである TEAM trial (N Engl J Med 2022;387:1747-1758) は、強化早期離床が主要評価項目を改善せず、有害事象はむしろ多かったと報告した。EMの最適なタイミング・強度・「誰に効くのか」は不明のまま残されていた。
- **Unknown (分かっていなかったこと)**: RCTが報告するのは**平均治療効果 (ATE)**である。平均がゼロであっても、その内訳は「全員に効かない」かもしれないし「半分に効き半分に害がある」かもしれない。従来のサブグループ解析は事前定義のカテゴリに依存し、検出力が低く、連続変数や変数どうしの相互作用を扱えないため、この二つを区別できなかった。強化EMに**治療効果の異質性 (HTE)**が実在するのか、実在するならどの患者背景がそれを決めるのかは分かっていなかった。
- **What's new (本研究の新規性・意義)**: TEAM trial の 687例を用い、機械学習 (X-learner + BART、略して X-BART) で**個別化治療効果 (ITE)**を推定した。施設単位でデータを半分に割り、片方で学習してもう片方の施設群で外部検証するという厳格な設計をとった。検証コホートで予測されたITEは **死亡の絶対 34.0% 減少から 39.3% 増加までの幅に広がり**、治療割付との交互作用は有意 ($p = 0.006$) だった。三分位ごとに観察された絶対リスク差は **-8.35% → -2.59% → +14.63%** と単調に増加した。ハーム側の患者は昇圧薬使用・糖尿病・低いRASSが多かった。**TEAMの先行post hoc解析は害と無効しか示せなかったが、「ベネフィットがありうる集団」を同定したのは本研究が初めて**である。著者らはあくまで仮説生成的と位置づけ、前向き検証を求めている。

全体要約

要旨

ひとことで「早期離床の強化は効果なし」と結論づけられた TEAM trial を、機械学習で個人単位に解きほぐした二次解析。平均はゼロでも中身は真逆で、**ベネフィット側は死亡が 8.35% 下がり、ハーム側は 14.63% 上がる**方向だった。効かない・害になる側を決めていたのは、昇圧薬・深い鎮静・糖尿病という「不安定さ」の指標だった。ただし信頼区間は広く、著者ら自身が仮説生成的と明記している。

内容	
問い	強化早期離床の効果は、患者背景によってどれだけ違うのか。誰が得をし、誰が損をするのか
区分	TEAM RCT(多施設・6か国・49施設)の二次解析。効果ベース(effect-based)のHTE解析。 PATH statement 準拠
対象	侵襲的人工呼吸中の成人 687例／40施設。英国症例は第三国へのデータ移送に同意がなく除外
介入・比較	強化EM(平均 21分／日・最大週7日、安全かつ耐えられる範囲で最高レベルの離床を長く) 346例 対 通常EM(各施設の標準・平均 9分／日・週5日) 341例
主要アウトカム	180日死亡(原試験の事前設定された副次アウトカム)
手法	施設単位で train(345例／20施設)と test(342例／20施設)に無作為分割。訓練データで5分割交差検証により6つの機械学習アルゴリズムを比較し、判別能が最も高い X-BART を採用。5つの乱数種で走らせ予測を平均
全体のATE	2.03%(95%CI -4.02, 8.08) = 原試験どおり有意差なし。180日死亡は全体で 141例(20.5%)
ITEの幅	検証コホートで 絶対 34.0% 減少 ~ 39.3% 増加 (パーセントポイント)
三分位のATE	下位三分位(ベネフィット予測) -8.35% (-21.48, 4.77)／中位(差なし予測) -2.59% (-18.20, 13.03)／上位(ハーム予測) +14.63% (-1.53, 30.79)
異質性の検定	治療割付 × モデル予測の交互作用について尤度比検定 p = 0.006
判別能	Qini係数 2.50 ／C-for-benefit 0.60 (95%CI 0.53-0.69)
ハーム側の特徴	昇圧薬 89.5%(対 47.4%)／糖尿病 39.5%(対 5.3%)／RASS 中央値 -4(対 -2)／予定手術後入室 8.8%(対 49.1%)
重要変数上位3	① 昇圧薬投与 ② RASS ③ 糖尿病
限界	二次解析・null trial 内でのHTE解析(PATH statement が偽陽性リスクを警告している状況)・信頼区間が広い・介入を二値として扱い用量/時間/期間を無視・英国除外による選択バイアス・ITEに信頼区間なし

押さえるべき7点

- ① 平均ゼロは「効果なし」ではない。TEAMの 2.03% (−4.02, 8.08) という平均の下に、−34.0% から +39.3% までの個人差が隠れていた
- ② 単調増加が最重要の所見。下位 → 中位 → 上位 で観察されたATEが −8.35 → −2.59 → +14.63 と一方向に並んだこと自体が、モデルの判別能と校正の証拠になる
- ③ ハーム側を決めていたのは「不安定さ」：昇圧薬・深鎮静・糖尿病。臨床的にきわめて納得しやすい方向であり、これが本研究の説得力の源泉
- ④ 糖尿病の扱いが更新された。先行のTEAM二次解析は「糖尿病＝高用量離床で不利」までしか言えなかったが、本解析は糖尿病の中にも少数のベネフィット側がいることを示した
- ⑤ 治療の「量」の違いではない。IMSレベルごとの滞在時間は三分位間で有意差がなく、モデルは「実施された離床時間の差」を拾っていたのではない
- ⑥ 時間軸の示唆：ベネフィット側はICU入室から無作為化まで 69.6時間、ハーム側は 47.9時間。早く入るほど良いとは限らない
- ⑦ ⚠️ 三分位のATEはいずれも **95%CIが0をまたいでおり、単独では有意でない**。有意なのは「三分位をまたぐ傾き(交互作用)」の方である

詳細

1. まず前提 — この病態・治療の基礎(初めての人にも)🧩

要旨

5分で背景を掴む ■ **ICU獲得性筋力低下 (ICU-acquired weakness, ICU-AW)**とは 重症疾患そのもの、人工呼吸、鎮静、不動、炎症、栄養不良が重なることで、ICU入室後 数日で全身の骨格筋が急速に痩せ、力が入らなくなる状態を指す。筋そのものが壊れる筋症 (myopathy) と、末梢神経が傷む多発神経障害 (polyneuropathy) が混在する。人工呼吸離脱の遅れ、退院後の歩行障害、QOL低下、長期死亡に結びつく。ICU退室後も年単位で残ることがあり、集中治療後症候群 (PICS) の身体領域の中核をなす。

■ **早期離床 (early mobilisation, EM)**とは 「早期」は多くの試験でICU入室から48～72時間以内を指す。「離床」は寝返り・端座位・立位・歩行という段階的な運動を、人工呼吸中であっても安全に行うことを意味する。到達レベルの指標として **ICU Mobility Scale (IMS)** がよく使われる (0=ベッド上で何もしない、10=介助なし歩行、の11段階)。理屈としては、筋の廃用を防ぎ、インスリン感受性や心肺機能を保ち、せん妄を減らして回復を早めることが期待される。

■ **本研究の親試験 TEAM trial** とは 6か国49施設で行われた大規模RCT (N Engl J Med 2022)。侵襲的人工呼吸中の成人を、①強化早期離床群 (安全かつ耐えられる範囲で「その日到達する最高レベルの離床」を長く行う。実際には平均 21分/日、最大で週7日) と、②通常ケア群 (各施設の標準的な離床。実際には平均 9分/日、週5日) に割り付けた。結果として、主要評価項目 (180日時点で生存かつ入院していない日数) に差はつかず、有害事象は強化群で多かった。すなわち「もっと動かせばもっと良くなる」という素朴な仮説は否定された。

■ 略語・スコアの一言定義

- **RASS** (Richmond Agitation-Sedation Scale) : 鎮静・興奮の深さの尺度。+4 が最も興奮、0 が覚醒安静、-5 が刺激に無反応。**本研究では数字が小さい (深く鎮静されている) ほど不利側だった**
- **APACHE II** : 入室24時間の重症度スコア。高いほど重症
- **WHODAS 2.0** (WHO Disability Assessment Schedule) : 入院前の生活障害の程度。高いほど障害が大きい
- **Functional Comorbidity Index (FCI)** : 機能予後との関連が強い併存疾患を数える指数。高いほど併存疾患が多い
- **Clinical Frailty Scale (CFS)** : フレイル度。1 (非常に健常) ～9 (終末期)

■ **そして本題 — 個別化治療効果 (individualised treatment effect, ITE) とは何か** ここが本論文の核心なので、丁寧に説明する。

ある患者について、「強化EMを受けたときの結果」と「受けなかったときの結果」を**両方**知ることができれば、その差がその人にとっての治療効果である。これを潜在アウトカム (potential outcomes) の枠組

みという。しかし現実には、その人はどちらか一方しか経験できない。もう一方は永久に観測できない。これを **因果推論の根本問題(fundamental problem of causal inference)** と呼ぶ。

だから通常のRCTは、個人ではなく**集団の平均**を求める。無作為化によって両群の背景が確率的に揃うので、群間の差＝**平均治療効果(average treatment effect, ATE)**が推定できる。TEAMが出した「差がない」はこのATEの話である。

ところが、平均がゼロであることには二通りの内訳がありうる。

内訳	意味	平均
全員に効かない	誰に対しても効果ゼロ	ゼロ
半分に効き半分に害	効果が個人で真逆に分かれる	ゼロ

この二つを平均だけで区別することはできない。区別しようとする試みが **治療効果の異質性(heterogeneity of treatment effect, HTE)** の解析であり、個人ごとの効果の推定値が **ITE** である。

■ **従来のサブグループ解析ではなぜ足りないのか** 従来法は「65歳以上か未満か」「糖尿病あり/なし」のように、事前に決めた1つの軸で切って群間差を見る。これには3つの弱点がある。①切る軸を人間が先に決めなければならない ②各サブグループの人数が減って検出力が落ちる ③複数の因子が同時に絡む状況(例：糖尿病があり、かつ昇圧薬を使っており、かつ深く鎮静されている)を表現できない。機械学習は、多数の変数を同時に考慮して個人ごとの効果を出力できるため、この3つを一度に緩和しうる。

■ **ただし、ここに落とし穴がある** ITEは「観測できない量」の推定値である。正解ラベルが存在しないので、通常の予測モデルのように「予測 対 実測」で精度を測ることができない。そのため、**似た予測値の患者をまとめて群にし、その群の中で治療群と対照群を比べる**という間接的な検証をとる。本論文が三分位に分けて各群のATEを描いているのは、まさにこの理由による。ここを理解しておくで、以降のFigure 1の読み方が一段深くなる。

2. 背景と目的 🏃

■ 論文が置いた前提

重症疾患と長期ICU滞在は、筋力低下・機能障害・回復の遷延といった合併症をもたらす。なかでもICU-AWは、回復・QOL・生存を著しく制限する最も障害的な帰結のひとつである。早期リハビリテーション・離床(EM)はこれを緩和し、機能回復を促し長期の障害を減らす手段として提唱されてきた。

しかし、ICUでEMプロトコルが広く使われているにもかかわらず、**最適なタイミング・強度、そして「どんな患者背景がベネフィットを予測するのか」**は依然として不明である、と著者らは述べる。

■ なぜ平均では足りないのか(著者らの論建て)

RCTはEMが筋力と機能回復を高めうることを示してきたが、これらの研究が報告するのはATEであり、個人の反応のばらつきを覆い隠しうる。試験のサブグループ解析は、EMの有効性を左右しうる複数の患者特性の複雑な相互作用を扱えないことが多い。年齢、併存疾患、鎮静レベル、重症度はいずれもEMへの反応を修飾しうる。

従来のサブグループ手法は次の3点で制約される。

- 1 事前定義されたカテゴリへの依存
- 2 統計的検出力の低さ
- 3 連続変数・交互作用する変数をモデル化できないこと

したがって、HTEの全体像を捉えるには不十分である。機械学習は複数の因子を同時に考慮することでこの問題に有望な解を与える。実際にRCTの文脈で、機械学習モデルが**酸素目標**(Buell KG, et al. JAMA 2024)や**ブジーを用いた気管挿管**(Seitz KP, et al. AJRCCM 2023)について、ベネフィットが予測される患者とハームが予測される患者を同定してきた。

■ 目的

TEAM RCT において、個々の患者特性が、強化EM対通常ケアEMの効果にどう影響するかを機械学習で検討すること。

3. 方法(Methods)

- **デザイン**: TEAM trial(多施設RCT)の二次解析。因果推論の枠組みで ITE を推定する **効果ベース(effect-based)のHTE解析**(eFigure 1にフロー)。**PATH statement**(Kent DM, et al. Ann Intern Med 2020)のガイダンスに従った
- **母集団**: 侵襲的人工呼吸中の成人。TEAM trial は 6か国 49施設で **2018年2月～2021年11月**に登録。本解析には **687例／40施設**が含まれた
- **強化EM 346例 対 通常ケアEM 341例**
- **英国の症例は除外**。英国の同意書が第三国(解析を担う University of Wisconsin-Madison)へのデータ移送を認めていなかったため
- 各国の施設内倫理委員会の承認と、データ移送に関するインフォームドコンセントの適用免除を得ている
- **介入・比較**:

- **強化EM群**: 毎日の理学療法セッション。安全かつ耐えられる範囲で、その患者にとって最高レベルの離床を、より長い時間行うことを目指す。実際には **平均 21分/日、最大で週7日**
 - **通常ケアEM群**: 各施設の標準プロトコルに従う。実際には **平均 9分/日、週5日**
 - **主要アウトカム**: **180日死亡**。これは原試験の**事前設定された副次アウトカム**であり、原試験との比較可能性と事前規定された統計解析計画との整合を保つために選ばれた
 - **予測変数**: 原著の Table 1 と Table S1–S5 に載る全ベースライン変数を候補とした。以下で絞り込む
 - **欠測率 35% 超**の変数を除外
 - **Pearson相関係数 |0.7| 超**の高相関変数を除外
 - **10% 未満の小カテゴリ**は統合、または統合が臨床的に意味をなさない場合は削除
 - **最終的な変数群**: 人口統計、フレイルと機能スコア、Functional Comorbidity Index に含まれる疾患、ICU入室の特徴、無作為化前の治療、選択されたバイタルサインと検査値(eTable 1)
 - **欠測補完**: 訓練データ上で bagged trees を構築し(R の caret パッケージの preProcess 関数)、訓練・検証の両データを補完
 - **データ分割**: TEAMのデータセットを、**施設単位で無作為に2分割**(train / test)。訓練に含まれない施設で厳格な外部検証を行うため
 - **訓練コホート**: **345例/20施設**
 - **検証コホート**: **342例/20施設**
 - **モデル導出**: 訓練データで **5分割交差検証**により、先行研究(酸素目標のITE解析)に基づいて選ばれた **6つの候補機械学習アルゴリズム**を比較。判別能が最も高かった **X-learner + Bayesian additive regression tree(X-BART)** を、訓練データ全体を用いて最終モデルとした
 - ハイパーパラメータは `causaltoolbox` パッケージの既定値
 - 先行研究と同様に、**5つの異なる乱数種**でモデルを走らせ、予測を平均して安定性を高めた
 - **感度分析**: 3種類
- 1 train と test を入れ替えて再解析(eTable 3)
 - 2 AIPW(augmented inverse propensity weights)とブートストラップにより Qini係数の95%CIを算出し有意性を検定
 - 3 全データを使った10分割交差検証(訓練のサンプルサイズを増やすため)

△ 注意

「事前設定」の範囲に注意 著者らは本解析を **pre-specified(事前規定)** と述べている。一方で結論部では **hypothesis-generating**、考察では **exploratory nature of this secondary analysis** とも書いており、**「事前に計画された探索的解析」であって、確証的な検証ではない**。PATH statement 自身が「null trial における予測的HTE解析は、強力な事前正当化がない限り偽陽性所見が特に生じやすい」と警告しており、著者らはこの警告を本文に明記したうえで慎重な解釈を求めている。

4. 手法の中身 — X-BART は何をしているのか 🧠

この節は原文の記述を、初めてこの手法を見る集中治療医向けに展開したものである。原文の記述は Methods の "Model derivation" に対応する。

■ メタラーナーという考え方

X-learner は「メタラーナー (meta-learner)」と呼ばれる戦略の一種である。メタラーナーとは、**既存の予測アルゴリズムを部品として組み合わせ、治療効果そのものを推定する枠組み**を指す。アルゴリズムそのものの名前ではなく、「どう組み合わせるか」の設計図だと考えるとよい。

■ X-learner の3段階(原文の記述に沿って)

原文は「X-learner はアウトカムモデルを構築し、続いて治療群と対照群それぞれについて疑似治療効果モデル (pseudo-treatment effect models) を別々に構築し、両群のモデルから得られた予測を等しく重みづけて最終予測を作る」と説明している。順を追うと次のようになる。

段階	やっていること	直感的な意味
① アウトカムモデル	治療群・対照群それぞれで「この背景ならどれくらい死ぬか」を学習する	各群での結果予測を作る
② 疑似治療効果	治療群の患者に「もし対照だったら」を当てはめ、その差を計算する。対照群にも逆を行う	観測できない反実仮想を、相手側のモデルで埋める
③ 重みづけ統合	両群から得られた治療効果の推定を等しく重みづけて平均する	片側のモデルの癖に引きずられないようにする

②で作られる差が「疑似 (pseudo)」と呼ばれるのは、それが実測された効果ではなく、**片側が予測値で埋められた差**だからである。X-learner の名は、治療群と対照群の情報を交差 (cross) させることに由来する。

■ BART とは

BART (Bayesian additive regression trees) は、原文の説明では「決定木の集合であり、各木が前の木の性能を改善するように構築される点で勾配ブースティングに似ているが、**過学習を減らすために木にランダムな変化が加えられる**」ものである。

- **決定木**: 「昇圧薬あり? → はい → $RASS < -3$? → はい → …」と条件分岐で予測を出す木
- **加法的 (additive)**: 1 本の木では表現力が足りないので、多数の木の予測を足し合わせる
- **ブースティング的**: 各木は前の木が説明しきれなかった残差を担当する
- **ベイズ的正則化**: ここが勾配ブースティングとの違い。事前分布によって各木を「浅く・弱く」保ち、加えてランダムな変更を挟むことで、**訓練データに合わせすぎることを構造的に抑える**

■ なぜ5つの乱数種で平均するのか

BARTは推定にMCMC (マルコフ連鎖モンテカルロ) を用いるため、乱数の初期値によって出力がわずかに揺れる。著者らは先行研究と同様に **5つの異なる seed** でモデルを走らせ、予測を平均することで**推定の安定性**を上げた。これは臨床試験の再現性の観点から重要な一手であり、単一seedの結果だけを報告する解析より一段慎重である。

■ なぜ「施設単位」で分割したのか

これは本研究の設計上、最も評価されるべき点のひとつである。患者単位で無作為に分割すると、同じ施設の患者が train と test の両方に入る。施設ごとの離床文化・鎮静方針・患者構成といった「施設の癖」をモデルが覚えてしまい、検証コホートでも同じ癖が通用してしまう。結果として性能が過大評価される。**施設単位で割れば、検証は「学習に一度も現れなかった20施設」で行われる**ため、外部妥当性の検証としてはるかに厳しい。著者ら自身、感度分析③の10分割交差検証で性能が上がったことについて「訓練サンプルサイズの増加と、無作為分割が施設分割より厳格でないことによる可能性が高い」と述べている。

5. モデルをどう検証したのか — 正解がない量の検証法

■ 根本問題ふたたび

原文は明快に述べている。「因果推論の根本問題は、ある個人について治療された状態と治療されなかった状態のアウトカムを同時に観測することが決してできないことである。したがってモデル性能の評価には、**似た患者をグループ化し、そのグループ内で治療群と非治療群を比較することが必要になる**」。

■ 三分位に分ける手続き

検証データの患者を、**最もベネフィットが期待される順 (ITEが -1 に最も近い) から、最もハームが期待される順 (ITEが $+1$ に最も近い) に並べ、等しい大きさの3群に分けた**(各 114例)。そして各群について、実際に

観察された治療群 対 対照群の絶対リスク差(=サブグループATE)をプロットする。

■ 何を見れば「良いモデル」なのか

原文いわく、「三分位を通じた単調な増加(monotonic increase)」が、判別能と較正が高いモデルであることを示す。ここが直感的に重要な点で、個々の点推定が有意かどうかではなく、3点が一方向に並ぶかどうかを見ている。

■ 3つの検証指標

指標	何を測るか	判定基準	本研究の値
尤度比検定 (交互作用)	治療割付とモデル予測を独立変数としたロジスティック回帰に交互作用項を入れることの有意性	$p < 0.05$ で偶然以上	$p = 0.006$
Qini係数	Qini曲線の下面積。予測ITEに基づいて優先順位をつけて治療した場合の180日生存の累積的上乗せ(uptake)を、無作為割付と比較したもの	0 超で偶然以上の判別能	2.50
C-for-benefit	予測されたベネフィットと観察されたベネフィットの一致確率。リスク予測モデルのC統計量に相当する概念をベネフィットに拡張したもの	0.5 超で偶然以上	0.60 (0.53–0.69)

Qini曲線の考え方は「もし限られた資源で一部の患者にだけ治療を届けるとしたら、モデルの予測順に届けたときと、くじ引きで届けたときで、救える命はどれだけ違うか」を累積で描いたものである。臨床の言葉に直せば「トリアージの道具としての有用性」を測る指標といえる。C-for-benefit は「2組の患者ペアを取ったとき、モデルがベネフィットの大小関係を正しく順序づけられる確率」に相当する。

■ 交絡の可能性を潰す2つの追加解析

- 1 治療強度の差ではないことの確認: モデルが同定した反応の違いが、実施された離床量の違いを反映しているだけではないかを検討するため、IMSの各レベルで過ごした時間(分)を、三分位ごとに治療群間で比較した
- 2 在院期間の確認: 副次的なLOSアウトカムを、180日死亡の有無で層別して三分位ごとに要約した

■ モデルの説明(variable importance)

変数重要度は次の方法で算出した。訓練セットの各患者について、ある予測変数を訓練データ集団の中央値に置き換え、他はすべて固定したときの予測値と、元の予測値との絶対差を取り、その大きさを各変数の影響を定量化した。これは Molnar の *Interpretable machine learning* に基づく手法である。加えて、変数と

予測ITEの関係を **ICEプロット (individual conditional expectation plot)** で可視化した(eFigure 5)。

6. 結果① — 患者背景とモデル性能

■ 解析対象

- 最終解析：**687例／40施設** (英国症例は二次利用の同意がないため除外)
- 早期離床(強化EM)を受けたのは **346例(50.4%)**
- 180日までに死亡したのは **141例(20.5%)**
- 原試験と同様、180日死亡について治療群間に有意差なし：**ATE 2.03%(95%CI -4.02, 8.08)**
- 施設単位の無作為分割後：訓練 **345例／20施設**、検証 **342例／20施設**

■ 訓練コホートと検証コホートの違い(eTable 2)

著者らは両コホートの差を正直に記載している。

	訓練コホートに多い	検証コホートに多い
入室経路	一般病棟からのICU入室	予定手術後のICU入室
主診断	非手術・呼吸器	手術・心血管
検査値	—	PaO ₂ が高い

つまり**検証コホートの方が予定手術後・術後心血管の比率が高い**。この構成の違いは、後述する「ベネフィット側は予定手術後が多い」という所見の解釈に影響しうる。

■ モデル選択とITEの分布

訓練コホートでは **X-BART が最も良い性能**を示し、これを訓練データ全体で構築して最終モデルとした。検証コホートにおける予測ITEは、**強化EMによる死亡の 34.0パーセントポイント減少から 39.3パーセントポイント増加までの幅**を持っていた。

■ 判別能

- 尤度比検定(治療 × ITE予測の交互作用)：**p = 0.006**。モデルの判別能が偶然より有意に良いことを示す
- Qini係数：**2.50**(eFigure 2)
- C-for-benefit：**0.60(95%CI 0.53, 0.69)**
- 検証セットの較正は eFigure 3 に示されている

■ 交絡の否定

- IMSの各レベルで過ごした時間(分)の平均差は、三分位間で有意差なし(eFigure 4)。モデルが「実施された治療時間の違い」を拾っていたのではないことを確認
- アウトカムを経験した患者において、無作為化からICU退室までの日数中央値、無作為化から退院までの日数中央値に有意差なし(eTable 4)

7. 結果② — 三分位ごとの観察された治療効果(Figure 1)

図の解説

Figure 1. 検証セットにおける予測個別化治療効果の分布(原図・無改変。© 出典) **上段のヒストグラム**。横軸は「予測された個別化治療効果(%)」で -40 から +40 まで。縦軸は患者数(0~40超)。バーは三分位に応じて3色に塗り分けられている。左側の**青**が「強化EMからベネフィットを受ける」と予測された下位三分位、中央の**灰色**が「ベネフィットもハームもない」と予測された中位三分位、右側の**赤(濃い臙脂)**が「強化EMからハームを受ける」と予測された上位三分位。分布の山は -10 前後と +5~+15 のあたりに二つの盛り上がりを持ち、全体としては中央付近に厚く、両裾に薄く広がる形をしている。最も高いバーは青の領域(-10 付近)で 40例超に達する。横軸の下には両向きの矢印があり、左が「Benefit from enhanced EM」、右が「Harm from enhanced EM」と注記される。 **下段のポイント推定図**。横軸は三分位(下位・中位・上位)、縦軸は絶対リスク差(%)で -40 から +40。3つの点とエラーバー(95%信頼区間)が並ぶ。左端の青い点が下位三分位で **-8.35%**、エラーバーは -21.48 から 4.77 まで伸びて 0 をまたぐ。中央の灰色の点が中位三分位で **-2.59%**(-18.20 から 13.03)でこれも 0 をまたぐ。右端の赤い点が上位三分位で **+14.63%**(-1.53 から 30.79)で、下端がわずかに 0 を下回る。0 の高さに水平の点線が引かれている。図の右側には縦の矢印があり、上向きが「Harm from enhanced EM」、下向きが「Benefit from enhanced EM」を示す。 **読み方**: 3点が左から右へ一方向に上がっていること(単調増加)が、モデルが患者を治療反応の順に並べられていることの視覚的な証拠である。各点のエラーバーが 0 をまたいでいる点は、次節の批判的吟味で扱う。

Table 1 (抜粋). 三分位ごとの患者背景とアウトカム(原表を日本語化)

各群 N = 114。値は n(%), 中央値[IQR]、または平均(SD)。

項目	下位三分位 (ベネフィット予測)	中位三分位 (差なし予測)	上位三分位 (ハーム予測)
年齢(歳、平均)	60(17)	61(14)	61(14)
BMI(kg/m ² 、平均)	28.9(7.6)	29.8(7.2)	31.1(7.0)
女性	46(40.4%)	40(35.1%)	36(31.6%)
パートナーと同居	78(68.4%)	73(64.0%)	59(51.8%)
Clinical Frailty Scale	3[2, 4]	3[2, 4]	3[2, 4]
Functional Comorbidity Index	1[1, 2]	2[1, 3]	2[1, 3]
ICU入室前週の最高IMS	10[10, 10]	10[10, 10]	10[10, 10]
WHODAS 2.0	6.2[0.0, 15.6]	10.4[2.1, 22.9]	10.4[2.1, 31.2]
不安・パニック障害・うつ	8(7.0%)	16(14.0%)	23(20.2%)
喘息	10(8.8%)	15(13.2%)	17(14.9%)
うっ血性心不全・心疾患	25(21.9%)	22(19.3%)	19(16.7%)
糖尿病(1型および/または2型)	6(5.3%)	26(22.8%)	45(39.5%)
上部消化管疾患	12(10.5%)	15(13.2%)	11(9.6%)
ICU入室から無作為化までの時間	69.6[43.8, 116.0]	50.2[29.4, 85.6]	47.9[25.6, 79.5]
入院から無作為化までの時間	108.3[74.5, 171.8]	76.6[50.3, 160.9]	65.3[41.4, 120.2]
診断:非手術・呼吸器	30(26.3%)	27(23.7%)	18(15.8%)

項目	下位三分位(ベネフィット予測)	中位三分位(差なし予測)	上位三分位(ハーム予測)
診断:非手術・敗血症	4(3.5%)	16(14.0%)	24(21.1%)
診断:非手術・その他	12(10.5%)	16(14.0%)	33(28.9%)
診断:手術・心血管	43(37.7%)	29(25.4%)	17(14.9%)
診断:手術・消化管	8(7.0%)	5(4.4%)	13(11.4%)
診断:手術・その他	17(14.9%)	21(18.4%)	9(7.9%)
入室経路:予定手術後	56(49.1%)	32(28.1%)	10(8.8%)
入室経路:緊急手術・他院/他ICUから	19(16.7%)	28(24.6%)	62(54.4%)
入室経路:救急外来から	21(18.4%)	31(27.2%)	34(29.8%)
入室経路:一般病棟から	18(15.8%)	23(20.2%)	8(7.0%)
無作為化前 ステロイド	48(42.1%)	51(44.7%)	56(49.1%)
無作為化前 腎代替療法	24(21.1%)	23(20.2%)	33(28.9%)
無作為化前 昇圧薬持続投与	54(47.4%)	76(66.7%)	102(89.5%)
APACHE II	15[12, 19]	17[13, 21]	18[14, 24]
クレアチニン	106[73, 130]	107[74, 158]	108[78, 173]
GCS	15[15, 15]	15[15, 15]	15[14, 15]
PEEP(平均)	8.6(2.9)	8.7(3.1)	8.8(2.8)
P/F比(平均)	247.8(95.7)	234.8(79.9)	242.7(81.9)

項目	下位三分位(ベネフィット予測)	中位三分位(差なし予測)	上位三分位(ハーム予測)
PaO ₂ (平均)	85.5(20.5)	91.3(45.9)	89.3(27.1)
RASS	-2[-4, -1]	-4[-5, -2]	-4[-5, -3]
実際に強化EMに割付	53(46.5%)	58(50.9%)	60(52.6%)
180日死亡(全体)	18(15.8%)	27(23.7%)	32(28.1%)
180日死亡(強化EM群)	6(11.3%)	13(22.4%)	21(35.0%)
180日死亡(通常ケア群)	12(19.7%)	14(25.0%)	11(20.4%)
平均治療効果 ATE (95%CI)	-8.35%(-21.48, 4.77)	-2.59%(-18.20, 13.03)	+14.63%(-1.53, 30.79)

■ この表から読み取るべきこと

- 1 年齢・フレイル・GCS・PEEP・P/F比・クレアチニンは三分位間でほぼ同じ。つまりモデルは「重症度が高い＝ハーム」という単純な軸を引いているわけではない。APACHE II は 15 → 17 → 18 と緩やかに上がるだけである
- 2 勾配が急なのは3つ。昇圧薬(47.4 → 66.7 → 89.5%)、糖尿病(5.3 → 22.8 → 39.5%)、予定手術後入室(49.1 → 28.1 → 8.8%)。この3本が実質的にモデルの背骨をなす
- 3 RASSは -2 → -4 → -4。下位三分位だけが浅く、中位と上位は同じ中央値で四分位範囲が異なる(-5,-2 対 -5,-3)
- 4 入室から無作為化までの時間は逆向き。69.6 → 50.2 → 47.9時間。ベネフィット側の方が「遅れて入った」
- 5 各三分位のATEは、単純にその群内の粗リスク差である。上位三分位なら 35.0% - 20.4% = 14.6%。ここは調整済みの推定値ではなく、素の観察値である点を押さえておく
- 6 上位三分位の通常ケア群の死亡率は 20.4% で、実は全体平均(20.5%)とほぼ同じ。つまり「ハーム側の患者がもともと死にやすい」のではなく、強化EMを当てられたときにだけ 35.0% へ跳ねている。この非対称性が本研究の主張の核心にあたる

8. 結果③ — 何がITEを決めたのか(Figure 2)🔍

図の解説

Figure 2. 変数重要度と、3変数で層別した個別化治療効果の予測分布(原図・無改変。© 出典) 4つのパネルからなる。**パネルA(左上) — 相対的変数重要度の横棒グラフ。**横軸は相対重要度(%)で 0 から 100。縦軸に上位10変数が重要度の高い順に並ぶ。上から順に、Vasopressor infusion(昇圧薬持続投与)が最長で 100%、RASS が約 50%、Diabetes(糖尿病)が約 50%、Source: unplanned from ward(入室経路: 予定外・一般病棟から)が約 35%、Anxiety or depression(不安またはうつ)が約 27%、Source: unplanned from emergency surgery or from another hospital or ICU(緊急手術・他院/他ICUから)が約 26%、Diagnosis non-operative: other(非手術・その他の診断)が約 22%、WHODAS 2.0 が約 20%、Functional comorbidity index が約 18%、Diagnosis non-operative: sepsis(非手術・敗血症)が約 17%。1位の昇圧薬が2位以下のおよそ2倍の高さを持ち、突出しているのが一目で分かる。**パネルB(右上) — 昇圧薬の有無で層別した予測ITEの積み上げヒストグラム。**横軸は予測ITE(%)で -40 から 40、縦軸は患者数(0~25)。紫が「昇圧薬あり」、黄が「昇圧薬なし」。三分位の境界に2本の縦点線が引かれ、上部に Lower third / Middle third / Upper third のラベルがある。黄(昇圧薬なし)は左側(ベネフィット側)に厚く分布し -20 付近に山を持つ。紫(昇圧薬あり)は 0 より右側に大きく張り出し、+5~+15 に厚い山を作り、右裾は +40 近くまで伸びる。**パネルC(左下) — RASS別の予測ITEの箱ひげ図。**縦軸にRASSの値が上から「2~4」「1」「0」「-1」「-2」「-3」「-4」「-5」と並び、横軸は予測ITE(%)で -40 から 40。三分位境界の縦点線が2本。RASS が 0 以上の行では箱が明らかに左(ベネフィット側)に寄り、中央値は -10 前後。RASS が -3、-4、-5 と深くなるにつれて箱が右へ移動し、-4 と -5 の行では箱の大半が 0 より右(ハーム側)に位置する。外れ値の点が -1 の行に1つ(-33付近)、-2 と -4 の行に右外れ値が数点(+35~+40付近)ある。**パネルD(右下) — 糖尿病の有無で層別した予測ITEの積み上げヒストグラム。**軸はパネルBと同じ。紫が「糖尿病あり」、黄が「糖尿病なし」。黄(糖尿病なし)は -10 付近に非常に高い山(35例超)を作り、全体として左寄り。紫(糖尿病あり)は 0 より右に集中し、+5~+20 に分布して右裾が +40 まで伸びる。ただし紫のバーは左側(-20 付近まで)にもわずかに存在しており、これが「糖尿病があってもベネフィット側に来る少数」の視覚的な根拠になっている。

■ 図から言えること(本文の記述と対応)

- 最終モデルにおける**重要変数の上位3つは、昇圧薬持続投与・RASS・ベースラインの糖尿病**であった
- **ベネフィット側の患者像**: WHODAS中央値が低い(障害が少ない)、Functional Comorbidity Index が低い(併存疾患が少ない)、予定手術後の入室が予定外入室に比べて多い

- **ハーム側の患者像**: RASS中央値が低い(深く鎮静されている)、昇圧薬投与を受けている割合が高い、ベースラインで糖尿病と診断されている割合が高い
- 変数と予測ITEの関係のトレンドは ICEプロット (eFigure 5) に示されている

9. 結果④ — 3つの感度分析

感度分析	内容	結果
① train/test 入れ替え	訓練データと検証データを入れ替えて全解析を再実行 (eTable 3)	Qini係数 2.14 。主解析 (2.50) と同程度の判別能。糖尿病、予定外入室「緊急手術・他院/他ICUから」、Functional Comorbidity Index、主診断「非手術・その他」「非手術・敗血症」が 両モデルで上位10変数に共通して出現
② AIPW による Qini の区間推定	augmented inverse propensity weights とブートストラップで Qini の95%CIを算出	主解析 (train/test分割) で 2.67 (95%CI 0.37–5.00) 、入れ替え解析で 2.40 (95%CI 0.21–4.59) 。いずれも下限が 0 を超えており、判別能が偶然より統計学的に有意に良いことの根拠になる
③ 10分割交差検証	全データを用いた10分割交差検証 (訓練サンプルサイズを増やすため)	除外フォールドにおける Qini係数の中央値 3.71 。主解析の50/50施設分割よりやや良好。著者らはこれを「訓練サンプルサイズの増加と、無作為分割が施設分割より厳格でないことによる可能性が高い」と説明。主解析の検証セット予測と10分割交差検証の予測との相関は Pearson r = 0.82 と高い

■ 感度分析の読み方

3つとも「結果が壊れないか」を別角度から確かめている。とくに②は重要で、主解析で報告された Qini係数 2.50 には信頼区間が付いていない。②はそこを補い、**区間推定でも 0 を上回る**ことを示した。③の「無作為分割の方が性能が良く見える」という結果は、本研究が採用した施設分割がいかに厳しい検証だったかを逆説的に裏づけている。

10. 考察 — 著者らの解釈

■ 患者像の対比

強化EMからベネフィットを受けやすい患者は、予定手術での入室が多く、ベースラインで身体状態が良好で、障害が少なく機能的併存疾患が少なかった。対照的にハームを受けると予測された患者は、ベースラインの RASSが低く、昇圧薬サポートを要し、糖尿病を有する傾向にあった。著者らは、**鎮静レベル・昇圧薬サポート**

の必要性・糖尿病のような併存疾患が、患者が強化EMを安全に耐えられるか、あるいはそこから利益を得られるかに影響しうると述べる。

■ 異質性の大きさ

検証コホートの予測ITEは 34.0パーセントポイントの減少から 39.3パーセントポイントの増加まで広がっていた。著者らは「強化EMは一部には有益で、他には有害でありうることを示唆する。ただし**我々の信頼区間は広がった**」と自ら留保を付けている。原試験は180日死亡に群間差を示さなかったが、個別化解析は、ATEでは捉えられなかった重要なベースライン変数が存在しうることを明らかにした、という位置づけである。

■ 有害事象を主要な軸にしなかった理由

著者らは、有害事象の件数が少なく、かつ先行報告で死亡との関連が示されていないため、層別した有害事象解析は検出力が不足し追加の知見をもたらしそうにない、と判断した。したがって**死亡に基づく異質性に焦点を絞った**と明記している。

■ 3変数の生物学的妥当性(著者らの推論)

- **糖尿病**:TEAMの先行二次解析は糖尿病患者で死亡増加を示していた。本解析は、糖尿病患者の多くが強化EMで害を受ける一方、**少数は利益を得うる**ことを示した。著者らはこの個人差を「合併症の重症度の違い」に帰す仮説を提示する
- 害の側:微小血管障害と灌流不良、昇圧薬を要する状態、自律神経障害による低血圧や不整脈が、死亡を増やしうる
- 利益の側:合併症が少ない患者は、血糖コントロールの改善、ICU-AWの軽減、心血管機能の改善を介して生存が改善しうる
- **昇圧薬・低RASS**:生理学的不安定性、血行動態の破綻、能動的参加能力の低下により、EMによる害のリスクが高まりうる。この状態で離床させると、**低血圧を増悪させ、心筋酸素需要を増やし、不整脈などの有害事象を招きうる**

■ 「個別化」という言葉の二つの意味(著者らが明確に区別している点)

ここは本論文の考察で最も重要な整理である。

	TEAM試験での個別化	本解析が言う個別化
何に基づくか	その瞬間の臨床状態、安全性パラメータ、筋力、患者のその場の耐容性	患者レベルの特性（併存疾患負荷、鎮静レベル、臓器サポート）
時間スケール	瞬間ごと（moment-to-moment）	より長期（longer term）
何を決めるか	そのセッションをどこまでやるか	リハビリテーションの用量・強度・軌道そのものの

TEAM試験でも個々のセッションは個別化されていた。しかし本解析が提起しているのは、**より広い概念としての個別化**、すなわち患者背景に基づいて長期的な用量と軌道を設計するという発想である。著者らは、明らかになったHTEが「ICUにおけるEMの one-size-fits-all アプローチの限界を浮き彫りにする」と述べる。

■ タイミングについての考察

ICUにおけるEMのタイミングは主要な研究テーマであり、内科系ICU集団を対象とした複数の小規模研究は、ICU入室後できるだけ早く離床を開始することの利益を示唆してきた。TEAM試験では **ICU入室から中央値60時間後に登録され、80%が無作為化当日に理学療法を受けた**。本解析の所見は、混合ICU（内科系・外科系・外傷）において、**強化EMから利益を得る患者はICU入室から無作為化までの間隔が長い傾向にあった**ことを示す。

著者らはこう述べる。ICU滞在の早期に無作為化された患者の一部は、より生理学的に不安定で、鎮静が深く、昇圧薬を要し、臓器サポートが継続しているために、強化された離床を耐えたり、そこから利益を得たりする可能性が低いかもしれない。この曝露タイミングの時間的な変動が、EMの実施可能性と有効性の両方に影響し、観察されたITEの異質性を部分的に説明しうる。**今後の解析では無作為化までの時間を共変量または層別因子として組み込むべきである。**

■ 手法上の強みについての著者らの主張

- 従来の固定サブグループ解析は個々の患者特性の複雑さを考慮できない。実例として、TEAMの先行二次解析は「糖尿病患者では高用量離床で死亡が増える」ことは示せたが、①糖尿病がない患者での害は示せず、②糖尿病患者内部のHTEも示せなかった
- 本解析は、**強化EMによるベネフィットの可能性を同定した初めての研究**である。先行のpost hoc解析は害または無効しか同定していなかった
- X-BART のような機械学習は、複数因子を同時に評価し個別化されたベネフィット予測を作れる
- train/test 入れ替えの感度分析が結果の頑健性を補強した

- Qini係数と C-for-benefit は、モデルが患者を予測ベネフィット順に判別・順位づけする能力を示す。**Qini 2.50 は意味のある判別を示唆**し、感度分析でも同程度の値(2.14)が観察された。**C-for-benefit 0.60(0.53–0.69)は中等度の判別**を示し、偶然の閾値 0.5 を超えている。著者らは「これらの指標のベンチマークは文脈によって異なるが、C-for-benefit が 0.5 超、Qini が正であることは、HTE解析において有用な予測性能を示すと一般に考えられる」と述べる

11. 限界 — 著者らの留保をそのままに

著者らは限界を長く、率直に列挙している。原文の慎重さを保って再現する。

■ 因果としての解釈に必要な4つの仮定

X-BARTモデルから導かれたITE推定値は因果効果として枠づけられているが、妥当な因果解釈にはいくつかの重要な仮定が必要である。

仮定	内容	本研究での状況(著者らの記述)
① 交換可能性 (exchangeability)	観測共変量で条件づけたとき、強化EM群と通常ケアEM群が比較可能であること	TEAM試験の無作為化デザインによって支持され、交絡が緩和される
② 正值性(positivity)	すべての患者がどちらの治療も受ける非ゼロの確率を持つこと	RCTでは一般に満たされるが、施設固有の診療慣行や除外基準によって脅かされうる
③ 一致性 (consistency)	受けた治療が解析で定義された治療と正確に対応すること	施設間のEM実施のばらつきによって影響を受ける
④ 正しいモデル特定	機械学習ベースの因果推論において決定的	モデルの誤特定や過学習はITE推定にバイアスをもたらしうる

交差検証、ホールドアウト検証セット、感度分析の使用は頑健性を高めるが、**モデルの複雑さと本解析の二次的の性質から慎重さが求められる**、と著者らは書いている。

■ null trial における予測的HTE解析という問題

原試験 TEAM は強化離床による全体的な死亡ベネフィットを報告しなかった。PATH statement によれば、**null trial の文脈で行われる予測的HTE解析は、強力な事前の正当化がない限り、偽の所見(spurious findings)が特に生じやすい**。本解析は事前規定され、外部検証と感度分析を含む厳格な方法論的基準に従ったものの、**二次解析としての探索的性質ゆえに、所見は慎重に解釈されるべきである**。

■ 絶対リスク減少という要約指標の問題

絶対リスク減少 (ARR) はベースラインリスクによって変動しうるため、サブグループ効果の要約にARRを用いた本研究の方法は、**治療効力の真の異質性ではなく、基礎にあるリスクの違いを反映している可能性がある**。リスク比のような相対効果指標の方がサブグループ間でより一貫した比較を与えうるので、今後の解析では検討すべきである。

■ 介入を二値として扱ったこと

無作為化の完全性を保つため、強化EMは二値の介入として扱われた。この方法は**実際の曝露の用量・タイミング・期間を考慮しない**ため、観察された治療効果に影響した可能性があり、個人レベルの反応性についての推論を制限する。

■ 英国データの事後的除外

同意の欠如という必要性によるものではあるが、**選択バイアスを導入し、統計的検出力を減じ、異なる国際的医療環境をまたいだ一般化可能性を制限した**可能性がある。

■ 180日という時間枠

原試験との整合のために選ばれたが、**この長い時間枠でのアウトカムは、本解析で捕捉されていないICU退室後の共介入 (co-interventions) に影響される可能性がある**。

■ 臨床応用について

モデルは強い予測性能を示すものの、**臨床適用性には慎重な検討が必要**であり、臨床現場でこれらの所見を検証するさらなる前向き研究が必要である。今後の研究では、モデルの不確実性をさらに定量化するためにITEに対する**ブートストラップベースの信頼区間**を組み込むことが考えられる。

12. 結論(原文) 🎯

本研究は仮説生成的な解析であり、重症ICU患者におけるEMの用量の個別化された効果のさらなる探索を支持する。機械学習を用いて治療効果の異質性を探索することにより、EMの用量への反応に影響しうる主要な患者特性が同定された。これらの所見は、ICUにおけるより個別化された離床アプローチ、すなわち患者固有の因子が「強化EM介入を行うかどうか、いつ行うか」の判断を導くようなアプローチを支持する。今後の研究は、これらの個別化された予測の臨床適用性を探索し、患者アウトカムを最適化するために日常のICUケアに統合されるべきかを評価すべきである。

批判的吟味 — ジャーナルクラブでの論点

■ 論点1:これは「二次解析」である、という重みをどう置くか

- 主要アウトカム(180日死亡)は**原試験の副次アウトカム**である。原試験の主要評価項目ではない
- 原試験は null であり、PATH statement 自身が「null trial での予測的HTE解析は偽陽性が出やすい」と警告している。著者らはこの警告を引用したうえで解析を行っている。**警告を引用することは、警告を無効化しない**
- 事前規定(pre-specified)と探索的(exploratory)が同じ論文に併記されている。JCでは「どの部分が事前規定で、どの部分が事後的か」を確認する価値がある。統計解析計画の公開先や登録番号は本文に明示されていない
- 議論の型:この論文の主張は「強化EMには異質性がある」までであり、「この3変数で振り分けよ」ではない。この線引きを共有してから議論に入るとよい

■ 論点2:過学習をどこまで潰せているか

擁護できる点と、なお残る懸念を分けて考える。

過学習対策として評価できる点	なお残る懸念
施設単位での train/test 分割(患者単位より格段に厳しい)	訓練 345例・検証 342例、イベントは全体で 141件。ITE推定としてはかなり小さい
BART のベイズ的正則化とランダムな木の変更	候補変数が多く(人口統計・併存疾患・入室特徴・治療・バイタル・検査)、イベント数に対して変数が多い
5つの seed による予測の平均化	ハイパーパラメータは既定値のまま。チューニングの余地と、その未探索が性能をどちらに歪めるかは不明
6アルゴリズムを5分割交差検証で比較して選択	「最良のものを選ぶ」行為自体が楽観バイアスを生む(選択後の性能は訓練データ上での勝者バイアスを含む)
train/test 入れ替えでも Qini 2.14 と再現	入れ替え解析は 同じ687例 を使っており、真の外部集団ではない
AIPW による Qini の区間推定で下限が 0 超	区間下限は 0.37 と 0.21 で、0 からの距離は小さい

■ 論点3:ITE推定は原理的に検証できるのか

- 個人の治療効果には正解ラベルが存在しない。だから検証は「三分位に分けて群レベルで比べる」という間接的な形をとらざるをえない
- ここには循環の危うさがある。**モデルが作った並び順で群を作り、その群で差が出たことをモデルの性能の証拠とする**という構造だからである。尤度比検定 ($p = 0.006$) はこの構造の中での検定であり、独立した外部データでの検証ではない
- 三分位のATE **3点はいずれも 95%CI が 0 をまたぐ**。有意なのは「傾き」であって「各点」ではない。JCでこの点を明示しないと、聴衆は「ハーム側で有意に死亡が増えた」と誤読する
- C-for-benefit 0.60 (0.53–0.69) は著者ら自身が「中等度 (moderate)」と書いている。**リスク予測モデルの C統計量 0.60 が実装に足るかを考えれば、この値の位置づけは自ずと見える**

■ 論点4: 因果の4仮定のうち、いちばん怪しいのはどれか

- 交換可能性は無作為化に守られている。ここは強い
- **一致性が最も脆い**。「強化EM」は各施設で実際にどう実施されたかが揃っていない。平均 21 分／日という数字は集団平均であり、施設間・患者間のばらつきは吸収されていない
- **正直性**も、施設ごとの離床文化を考えると自明ではない。ある施設では実質的に強化EMが行われなかった可能性を否定できない
- 二値として扱ったことの代償は著者ら自身が認めている。**用量反応関係が本題なのに、解析上は用量が消えているのは構造的な弱点である**

■ 論点5: 3変数の解釈は「効果修飾」か「予後」か

- 昇圧薬・低RASS・糖尿病は、いずれも**予後不良の指標**でもある。効果修飾因子 (treatment effect modifier) なのか、単なる予後因子 (prognostic factor) なのかは、本デザインでは完全には切り分けられない
- ただし前述のとおり、**上位三分位の通常ケア群の死亡率 20.4% は全体平均とほぼ同じ**であり、「もともと死にやすい群」では説明しにくい。ここは著者らの主張を支持する材料になる
- 著者ら自身、ARRを使ったことでベースラインリスクの違いを異質性と取り違えている可能性を挙げ、**相対指標(リスク比)での再解析を今後の課題**としている。JCでは「では相対指標で見たらどうなるか」を問う価値がある

■ 論点6: 糖尿病は本当に「離床の適否」を決めているのか

- 先行のTEAM二次解析 (Serpa Neto A, et al. AJRCCM 2024) が既に「糖尿病患者で高用量離床は不利」と報告しており、本解析はそれを再現した形になる。同じデータからの再現は、独立した検証ではない
- 糖尿病は微小血管障害・自律神経障害・血糖変動という複数の経路を束ねた粗い代理変数である。**HbA1cも血糖値も、入院前の管理状況もモデルに入っていない**。臨床実装を考えるなら、糖尿病という二

値ではなく「何が糖尿病の代わりに測られていたのか」を問うべきである

- 変数重要度の算出法(中央値への置換)は、相関のある変数群の中で重要度を不安定にすることが知られている。**上位10変数の順位そのものを強く受け取らない方がよい**

■ 論点7: タイミングの所見をどう読むか

- ベネフィット側は入室から無作為化まで 69.6時間、ハーム側は 47.9時間。「早ければ早いほどよい」という通念と逆向きに見える
- ただしこれは**因果ではなく、単に「早く入った患者は不安定だった」ことの反映**である可能性が高い。著者ら自身がその解釈を採っている
- JCでの問い: 当院で離床開始を早めることの是非を、この所見から直接論じることができるか。おそらくできない。**論じられるのは「安定するまで強度を上げない」という運用の妥当性までである**

■ 論点8: 実装可能性

- モデルは公開されていない。ノモグラムもスコアも本文には示されていない。**今日ベッドサイドで使える形にはなっていない**
- 使えるのは「昇圧薬・鎮静深度・糖尿病を見て強度を決める」という定性的な方向のみ。これは多くの臨床家が既に暗黙にやっていることでもある
- 著者らが求めているのは **prospective testing of a personalised approach**、すなわち「個別化戦略そのものをRCTで検証する」ことである。JCの締めくくりとしては、「**この論文は次の試験のデザインを提案した論文である**」と位置づけるのが最も誠実だろう

△ 注意

JCで最も誤読されやすい2点

- **三分位のATEはいずれも 95%CI が 0 をまたぐ。「ハーム側で死亡が有意に増えた」と言うてはいけない。**有意なのは治療 × 予測の交互作用($p = 0.006$)であって、各群の点推定ではない
- **この論文は「昇圧薬中・深鎮静・糖尿病の患者を離床させるな」とは言っていない。**言っているのは「一律の強化は適さないかもしれず、前向きの検証が必要である」まで。安全性を確認しながら行う通常の離床を否定する根拠にはならない

✓ Take home message

TAKE HOME

結論 ==TEAM試験の「差なし」という平均の下には、死亡を 34.0% 下げる患者から 39.3% 上げる患者までの幅が隠れていた(交互作用 $p = 0.006$)。**ハーム側を決めていたのは昇圧薬・深い鎮静・糖尿病という「不安定さ」の三点セットで、ベネフィット側は予定手術後・障害が少ない・併存疾患が少ない患者だった。**ただし三分位のATEはいずれも有意ではなく、本解析は仮説生成にとどまる。実装すべきは「モデル」ではなく「一律の強化をやめて患者背景で強度を決める」という発想の方である==。

判断の流れ

状況	確認すること	次の一手
人工呼吸中で離床の強度を決めたい	昇圧薬の有無・RASS・糖尿病の3点	3つとも該当しなければ強度を上げる方向で計画する
昇圧薬を持続投与中	用量の趨勢、低血圧の誘発リスク、直近の血行動態の安定性	本研究で最も重要度が高かった変数。強度を上げる判断を保留し、安定化を優先する
RASS が -3 以下 (深い鎮静)	鎮静を浅くできるか、能動的参加が可能か	離床の強化より先に鎮静の見直しを議論する。受動的介入にとどめる選択も妥当
糖尿病がある	微小血管障害・自律神経障害の所見、血行動態の安定性、他の2因子との重なり	糖尿病単独では除外理由にしない。昇圧薬・深鎮静と重なるときに強度を抑える
予定手術後・術後心血管外科で状態が安定	WHODAS・併存疾患の少なさ、入室前のIMS	モデル上ベネフィットが最も期待される層。積極的に強度と頻度を上げる
ICU入室から24～48時間以内で不安定	昇圧薬・鎮静・臓器サポートの継続状況	「早期＝強化」ではない。安定化を待ってから強度を上げる運用を検討する
有害事象(低血圧・不整脈)が離床中に出た	血行動態の余力、心筋酸素需要、参加度	中止し、翌日の強度設定を下げて再評価する。本研究の生物学的仮説と整合する

主要な引用文献

#	内容	著者・雑誌・年
19	親試験。人工呼吸中の成人への強化早期離床のRCT。本解析の元データ	TEAM Study Investigators, the ANZICS CTG, Hodgson CL, et al. Early active mobilization during mechanical ventilation in the ICU. *N Engl J Med* 2022;387:1747–1758
20	PATH statement。治療効果の異質性を予測的に扱う際の報告・実施指針。本解析が準拠	Kent DM, Paulus JK, van Klaveren D, et al. The predictive approaches to treatment effect heterogeneity (PATH) statement. *Ann Intern Med* 2020;172:35–45
22	X-learner の原典。異質治療効果推定のためのメタラーナ	Künzel SR, Sekhon JS, Bickel PJ, Yu B. Metalearners for estimating heterogeneous treatment effects using machine learning. *Proc Natl Acad Sci USA* 2019;116:4156–4165
23	Qini係数の理論的背景。治療優先順位づけルールの評価法	Yadlowsky S, Fleming S, Shah N, Brunskill E, Wager S. Evaluating treatment prioritization rules via rank-weighted average treatment effects. *J Am Stat Assoc* 2025;120:38–51
24	C-for-benefit の提案論文	van Klaveren D, Steyerberg EW, Serruys PW, Kent DM. The proposed "concordance-statistic for benefit" provided a useful metric when modeling heterogeneous treatment effects. *J Clin Epidemiol* 2018;94:59–68
16	同じ手法で酸素目標のITEを推定した先行研究。本解析のアルゴリズム選択の根拠	Buell KG, Spicer AB, Casey JD, et al. Individualized treatment effects of oxygen targets in mechanically ventilated critically ill adults. *JAMA* 2024;331:1195–1204
17	同じ手法でブジー対スタイルットのITEを推定した先行研究	Seitz KP, Spicer AB, Casey JD, et al. Individualized treatment effects of bougie versus stylet for tracheal intubation in critical illness. *Am J Respir Crit Care Med* 2023;207:1602–1611
27	TEAMの先行二次解析。糖尿病患者で高用量離床が不利であることを報告	Serpa Neto A, Bailey M, Seller D, et al. Impact of high-dose early mobilization on outcomes for patients with diabetes:

#	内容	著者・雑誌・年
		a secondary analysis of the TEAM trial. *Am J Respir Crit Care Med* 2024;210:779–787
13	TEAMの有害事象に関する post hoc解析。本解析が有害事象を主軸にしなかった根拠	Broadley T, Serpa Neto A, Bailey M, et al. Adverse events during and after early mobilisation: a post hoc analysis of the TEAM trial. *Aust Crit Care* 2025;38:101156
14	個別化学習によるICU患者のクラスタリングと離床用量の最適化	Fuest KE, Ulm B, Daum N, et al. Clustering of critically ill patients using an individualized learning approach enables dose optimization of mobilization in the ICU. *Crit Care* 2023;27:1
26	ノルアドレナリン投与中患者の離床の後方視コホート	Lindholz M, Schellenberg CM, Grunow JJ, et al. Mobilisation of critically ill patients receiving norepinephrine: a retrospective cohort study. *Crit Care* 2022;26:362
15	機械学習による治療効果の個別化推定 — 課題と機会	Curth A, Peck RW, McKinney E, Weatherall J, van der Schaar M. Using machine learning to individualize treatment effect estimation: challenges and opportunities. *Clin Pharmacol Ther* 2024;115:710–719
21	R の caret パッケージ (bagged trees による欠測補完に使用)	Kuhn M. Building predictive models in R using the caret package. *J Stat Softw* 2008;28:1–26
25	変数重要度の算出法(中央値置換)の出典	Molnar C. *Interpretable machine learning*. Leanpub, 2020

本ページは原論文の要約・解説です。数値は原論文から転記していますが、引用の際は必ず原論文(上記DOI)をご確認ください。原著の図表は著作権のため本ページには掲載していません(本文の「図の解説」を参照)。作成: Claude Code(聖路加ICUジャーナルクラブ運用)。