

STARDaki: 急性腎障害における診断精度の標準化された報告のための、合意に基づくSTARD拡張

出典 Yu H, Li Y, Mo GP, et al. Intensive Care Medicine. 2026. doi:10.1007/s00134-026-08549-5

掲載誌 Intensive Care Medicine (2026)

原著 doi.org/10.1007/s00134-026-08549-5 (本文PDFは別途)

原題 STARDaki: a consensus-based STARD extension for standardized reporting of diagnostic accuracy in acute kidney injury

 共有ページ (リンクを知る人は誰でも閲覧可): <https://hiro-oka.github.io/jc-summaries/s00134-026-08549-5.html>



聖路加ICUでの実践への示唆

聖路加ICUでの実践

病棟プロトコルへの落とし込み ① 当院で TIMP-2×IGFBP7 や NGAL を導入検討するときの「読み方の物差し」ができた。業者が持ってくる論文の感度・特異度をそのまま信じない。同じ u[TIMP-2]×[IGFBP7] でも、研究によって感度 23～92%・特異度 39～96% とほぼ全域にばらつく。この幅はバイオマーカーの欠陥ではなく、集団・AKI定義・採取タイミングがバラバラなまま固定カットオフを当てた結果である。「その数字はどの集団の、どのAKI定義の、採取から何時間以内の話か」を最初に聞く。② 最低限の5つのチェック項目。論文・製品資料を評価するとき、これが書かれていなければ数字を採用しない — (a) ベースライン腎機能(約70%の研究が欠く)、(b) AKIの重症度別(KDIGO stage別)の成績、(c) 採取からAKI診断までの時間窓、(d) アッセイが研究用か臨床用か(FDA/CE 認証の有無)、(e) 参照基準(AKI判定)を評価する人がバイオマーカー値を知らされていたか(documentedなのはわずか 5%)。③ 当院のAKI診療の記録の型に直結する。STARDaki が要求する項目は、そのまま当院のAKI症例の記録テンプレートに使える — ベースラインCr の決め方(過去値か、eGFR 75 からの逆算か、入院時値か)、尿量測定の間隔と測定期間、腎毒性薬剤の曝露、輸液バランス。これを日常的に残しておけば、当院データで診断研究ができるようになる。④ 「予測モデル」と「診断精度」を混同しない。機械学習でAKIを予測するモデルは、AUCを出していても STARDaki ではなく TRIPOD(+AI) に従うべきである。バイオマーカーを複数組み合わせたり臨床データと合わせてリスク予測する研究は、本ガイドラインの範囲外と明記されている。院内のAI/予測モデル案件(RRS・バイタル自動収集の予測アラート)は TRIPOD 側である。⑤ 現時点で臨床導入を支持できるのは2つだけ。専門家パネルが早期AKI検出のエビデンスが最も頑健と支持したのは u[TIMP-2]×[IGFBP7] と NGAL のみ。それも「バイオマーカー未使用コホートでの前向き検証が必要」という留保つきである。それ以外のマーカーは、当院の意思決定に組み込む段階にない。



この論文の位置づけ (Known / Unknown / What's new)

補足

リサーチ・イン・コンテキスト

- **Known (既に分かっていたこと)**: AKI は入院患者の5~12%、ICU患者の50%以上に生じ、重症 AKIの死亡率は50%を超えうる。診断の基準は KDIGO の血清クレアチニン上昇と尿量減少だが、これらは**構造的な傷害ではなく機能低下**を映すもので、24~36時間(時に48時間)の検出遅れと、筋肉量・輸液バランス・肝疾患・薬剤・RRT といった腎外因子の影響を受ける。そこで NGAL や TIMP-2×IGFBP7 のような**傷害マーカー**が開発され、後者は2014年にFDA承認された。診断精度研究の報告基準としては **STARD 2015 (25項目)**が存在し、認知症(STARDdem)などの領域別拡張も作られてきた。
- **Unknown (分かっていなかったこと)**: AKIバイオマーカー研究は結果が異質で相互に矛盾しており、**その異質性がバイオマーカー自体の性能差なのか、研究の報告・方法の質の低さによるものなのか**が区別できていなかった。また、AKI領域には**腎生検という組織学的な参照基準が事実上使えない**という固有の問題があり、STARD をそのまま適用してよいのかが整理されていなかった。
- **What's new (本研究の新規性・意義)**: 122件のDTA (diagnostic test accuracy) 研究を系統的に評価し、**STARD項目の平均準拠率がわずか 54.5% (範囲 14.7~76.5%)、異質性が大きすぎてメタ解析が実行不能**という事実を突きつけた。そのうえで10か国17名の国際専門家パネルによる修正デルファイ法で **STARDaki** (STARD 2015 に AKI 固有の要件を上乗せした拡張) を策定した。核心は「性能のばらつきは個々のバイオマーカーの欠点ではなく、**異質な集団に固定カットオフを当て、異なるAKI定義を使い、可変の採取窓を用いたことの予測可能な帰結である**」という診断である。

全体要約

要旨

ひとことで AKI バイオマーカーの診断精度研究 122 件を調べたところ、**STARD 2015 の項目を平均 54.5% しか報告しておらず、異質性が大きすぎてメタ解析すら実行できなかった。**17 名の国際専門家パネルが修正デルファイ法で、STARD 2015 に AKI 固有の要件（ベースライン腎機能・アッセイ検証・採取時間窓・重症度層別・輸液/腎毒性薬曝露）を上乗せした **STARDaki** を策定した。

- 系統的レビュー：PubMed・Embase・Cochrane・Web of Science を 2025 年 2 月 1 日まで検索し **13,075 件** をヒット。重複 4,563 件を除外、タイトル・抄録で 8,372 件を除外し、**122 件** の全文を精査した。
- 採取から AKI 診断までの時間枠が 48 時間を超えるもの、ベースライン腎機能・正確な時間枠・アッセイ手法の情報を欠くものはメタ解析・記述解析から除外。**48 時間** という窓は、腎傷害後の血清クレアチニン上昇が **24~36 時間遅れ**、GFR 低下に伴いクレアチニンの半減期が延びて AKI 検出がさらに最大 48 時間まで遅れるという生理学的根拠に基づく。
- 結果、**107 件** が質評価の対象となり、そのうち採取後 48 時間以内の AKI を報告したのは **28 件 (27%)**。さらに十分な方法論的記載（ベースライン腎機能、AKI 定義と病期分類、採取とイベントのタイミング、アッセイ手法）があったのは **19 件**。この 19 件のうち **QUADAS-2 の最高評点 (7 点)** に達したのは **11 件**。
- **STARD 準拠の実態**：各論文が適切に報告していた **STARD 項目は平均 54.5% (範囲 14.7~76.5%)**。**19 件中 STARD 準拠 70% の閾値を満たしたのは 10 件のみで、完全準拠はゼロ。**
- 特に欠落が激しかった項目：item 13b (参照基準の評価者が臨床情報と指標検査の結果を知りうる状態だったか) はわずか 5%、item 15 (判定不能の結果の扱い) 4%、item 18 (サンプルサイズの根拠) 17%、item 12a/b (指標検査のカットオフの定義と根拠) は 34~74% が不完全。一方、構造化抄録と研究目的 (core items) は 97~100% とほぼ完璧だった。
- QUADAS-2 では、患者選択・指標検査・フロー/タイミングの各ドメインで一部の研究に中等度のバイアスリスク (非代表的サンプリング、一貫しない検査プロトコル)。適用可能性の懸念はおおむね小さいが **15~20%** は臨床文脈との部分的不整合を示した。**参照検査の実施は堅牢で 85% が低バイアス。**
- バイオマーカー性能 (19 件・48 時間以内)：最も多く評価されたのは **u[TIMP-2] × [IGFBP7]** (10 研究・728 例、感度 23~92%、特異度 39~96%)、次いで **sNGAL** (3 研究・542 例、感度 45~93%、特異度 69~88%)。感度 23% という下限は、混合 ICU 集団で $0.3 \text{ (ng/mL)}^2 / 1000$ のカットオフを stage 2-3 AKI の 48 時間検出に適用した研究に由来し、**FDA 承認の適応 (12 時間以内の中等度~重症 AKI の予測)** とは大きく異なる文脈だった。**any-stage AKI かつ短い採取窓に限れば感度は 70% を超えた。**

- 専門家パネルが同定した現行研究の限界は3つ：①**時間的な曖昧さ**（大半の研究が採取・AKIリスク曝露期間・診断確定のタイムラインの関係を定義していない）、②**臨床的粒度の不足**（多くがAKI重症度層別を省き、約70%がベースライン腎機能データを欠く）、③**非標準的なアウトカム判定**（独立委員会による検証を記録した研究がごく少数）。加えて**研究用グレードのアッセイを臨床グレードの検証なしに使用する技術的問題**。
- 修正デルファイ (RAND/UCLA法)：17項目を2ラウンドで評価。**第1ラウンドは16名参加、全項目平均 4.66 (4.44–4.94)、SD 0.54 (0.24–0.87)、平均一致率 (AR) 95.40% (81.30–100%)**で既に合意基準を満たしたが、コメントに基づき改訂して第2ラウンドを実施。**17名全員参加、平均 4.54、AR 94%**で合意を確認した。
- パネルが早期AKI検出のエビデンスが最も頑健と支持したのは **[TIMP-2]×[IGFBP7]** と **NGAL** のみで、**バイオマーカー未使用 (biomarker-naïve) コホートでの前向き検証**を強く求めた。
- 適用範囲の線引きが明確：**KDIGO** を参照基準とする診断精度研究は **STARDaki**、リスク予測モデルの**開発は TRIPOD**。バイオマーカーの組み合わせや臨床データと合わせた予測モデリングは本文書の範囲外で、TRIPOD 型の枠組みを要する。将来的に **TRIPOD-AKI 拡張**の開発が必要かもしれない、とする。

詳細

1. まず前提 — AKIバイオマーカーと診断精度研究の基礎(初めての人にも)

要旨

5分で背景を掴む **AKI(acute kidney injury／急性腎障害)**は、腎機能が急に落ちる状態である。ICUでは半数以上に起こり、重症になると死亡率が50%を超える。生き延びても慢性腎臓病(CKD)や心血管イベントのリスクが上がる。診断は **KDIGO 基準**(Kidney Disease: Improving Global Outcomes、国際的な腎臓病ガイドライン組織)で行う。中身は **血清クレアチニン(Cr)の上昇**と**尿量の減少**の2本柱である。しかしここに根本的な問題がある。**クレアチニンも尿量も「腎臓が壊れたこと」ではなく「腎臓の動きが落ちたこと」を映す指標である**。腎臓が傷ついてもクレアチニンが上がるまで**24～36時間**かかり、GFR(糸球体濾過量)が落ちるとクレアチニンの半減期が延びるので、検出はさらに遅れて最大48時間になる。しかも筋肉量、輸液バランス、肝疾患、よく使う薬剤、そしてRRT(腎代替療法)そのものがクレアチニン値を狂わせる。そこで **バイオマーカー**が探された。**NGAL**(neutrophil gelatinase-associated lipocalin／好中球ゼラチナーゼ関連リポカリン)と、**TIMP-2 × IGFBP7**(メタロプロテアーゼ組織阻害因子2 × インスリン様成長因子結合蛋白7)が代表格で、後者は「細胞周期停止マーカー」と呼ばれ、傷ついた尿細管細胞が分裂を止めるときに出す蛋白質を尿中で捉える。どちらも欧米で規制当局の承認を受けている。これらの性能を評価する研究を **DTA研究(diagnostic test accuracy／診断精度研究)**という。新しい検査(**指標検査 index test**)と、正解とみなす基準(**参照基準 reference standard**)を突き合わせ、**感度**(病気の人を陽性と言えるか)と**特異度**(病気でない人を陰性と言えるか)を出す。AKIに固有の難しさがここにある。ふつうの病気なら参照基準は組織診断(生検)や画像だが、**AKIでは腎生検がほぼ実施不能で、参照基準のKDIGO自体が遅れて出てくる機能的な代用指標である**。だから「バイオマーカーがクレアチニン上昇より先に尿細管ストレスを検出する」現象は「予測」と呼ばれがちだが、正確には**参照基準が遅いせいで先に見えているだけ**である。著者らはこれを「設計上の欠陥ではなく、遅延した機能シグナルに依存する参照基準の帰結」と整理する。最後に報告ガイドラインの用語。**STARD**(Standards for Reporting Diagnostic Accuracy)は2003年に始まり、2015年改訂で**25項目**のチェックリストになった。**QUADAS-2**は診断精度研究のバイアスリスクを4ドメイン(患者選択・指標検査・参照基準・フローとタイミング)で評価する道具。**デルファイ法**は専門家に匿名で繰り返し評価させて合意を形成する手法で、本研究は**RAND/UCLA 適切性評価法**(デルファイ調査に司会付きの討議を組み合わせる)を用いた。

2. 背景と目的 🌟

AKIバイオマーカー研究には、**異質で結果がばらばら**という問題が長く指摘されてきた。臨床的有用性が不完全にしか定義されていない。

STARD 2015 は透明性と比較可能性を高めるために作られ、バイアス評価と適用可能性を強調する25項目に整理された。以後、領域別の拡張がいくつか公表されている — 認知症の **STARDdem**(2014)、ベイズ潜

在クラスモデルの **STARD-BLCM** (2017)、反芻動物のパラ結核の **STRADAS-paraTB** (2011)。いずれも STARD の基本原則を保ちつつ、専門技術や臨床設定に固有の方法論的ニュアンスに対応する。

本研究の目的は4つ：

- 1 既存のAKIバイオマーカー研究の **報告の質(STARD基準)**と方法論的質(**QUADAS-2**)を評価する
- 2 **異質性の源**を同定する
- 3 候補バイオマーカーの**診断・予後性能**を要約し臨床的有用性の判断材料にする
- 4 **STARDaki** を開発する

設計は STARDdem (系統的レビュー+デルファイの枠組み) に倣った。著者ら自身が本研究の性格を「**AKIバイオマーカー研究に対する領域特異的なSTARD拡張を提案する合意声明**」と位置づけている。

図の解説

Visual abstract (原著・無改変。© The Author(s) 2026, CC BY-NC) 論文冒頭のビジュアルアブストラクト。**濃青と白の2カラム構成**で、左が「Systematic Review: STARD Adherence」、右が「Delphi Process: STARDaki Development」。**左上**：ドーナツ型のリングチャートの中央に大きく **54.5%**。右に「Mean proportion of STARD items properly reported per article」、その下に斜体で **Range: 14.7%–76.5%**。リングは半分弱が濃青で塗られている。**左下**：濃青の見出し帯「Main Reporting gaps」の下に、報告率とSTARD項目の対応表が4行。**4% — 15: Indeterminate results / 5% — 13b: Assessors blinding / 17% — 18: Sample size justification / 34%–74% — 12a/12b: Test cutoffs**。左端に報告率の大きさを示す小さな青いバーが並び、最下行だけは幅のある帯(範囲を表す)になっている。**右上**：見出し帯「Modified Delphi」の下に、人型アイコンと **17 Experts**、チェックリストアイコンと **17 Items**。その下に丸囲みの ROUND 1 (n=16、Mean Score 4.66、AR 95.4%) と ROUND 2 (n=17、Mean Score 4.54、AR 94.0%) が縦に並び、最下段に握手アイコンつきで **"Consensus confirmed"**。**右下**：見出し帯「Final STARDaki elaboration」の下に、5つの番号つき追加要件が縦に並ぶ — ① Baseline kidney function/CKD/etiology、② Assay platform + validation、③ Sampling time window、④ AKI severity stratification、⑤ Fluid status/nephrotoxins/missing data。最下段に文書アイコンつきで **"STARD 2015 + AKI-specific requirements"**。**読み方**：**この1枚が論文の全論旨である**。**左が「現状は壊れている」、右が「だから何を足したか」**。実務的には**右下の5項目**が、論文を読むときの最短のチェックリストになる。

3. 方法(Methods)

系統的レビュー

- **デザイン**: 系統的レビュー (PRISMA 準拠) + 修正デルファイによる合意形成
- **事前登録**: PROSPERO CRD42024590896
- **データベース**: PubMed、Embase、Cochrane Library、Web of Science
- **検索期間**: 各データベースの開始時点から **2025年2月1日**まで
- **組み入れ**: AKIバイオマーカーの診断結果を報告した研究すべてを検討対象とした
- **除外(メタ解析・記述解析から)**: ①採取からAKI診断までの時間枠が **48時間超**、②ベースライン腎機能の情報なし、③正確な時間枠の情報なし、④アッセイ手法の情報なし
- **48時間の根拠**: 腎傷害後のクレアチニン上昇が **24～36時間**遅れ、GFR低下に伴いクレアチニンの半減期が延びることで検出がさらに **最大48時間**まで遅れる。したがってこの窓内で検出されたバイオマーカーは、クレアチニン上昇が確立する前の尿細管傷害を捉えている可能性がある
- **評価ツール**: 報告の質は **STARD 2015**、方法論の質は **QUADAS-2** (4ドメイン: 患者選択・指標検査・参照基準・フローとタイミング)
- **担当**: スクリーニングと質評価は2名 (HY、GPM) が独立に実施、不一致は第三の専門家 (ZP) が調停

△ 注意

事前登録したメタ解析は「実行しない」と決断された PROSPERO プロトコルでは、**5件以上の報告があるバイオマーカーについて診断精度指標のメタ解析**を事前規定していた。しかし組み入れ研究を精査した結果、**患者集団・バイオマーカーアッセイ・測定タイミング・診断閾値・参照基準の実装の差が大きく、階層的サマリーROCモデルの前提を破る**と判断され、**定量的統合は実施されなかった**。結果は感度・特異度の**範囲**として、バイオマーカー種別・臨床文脈(心臓手術関連AKI/敗血症関連AKI)・ベースラインクレアチニン値で層別して記述的に提示された。これは本論文の主張の中核でもある — 「**メタ解析できなかった**」こと自体が**最大の所見**である。

専門家パネルと修正デルファイ

- **専門家の選定**: Expertscape.com の引用指標で定量化されたAKI領域の学術的インパクトに基づいて同定。バイオマーカーと臨床生物統計の専門家が十分に含まれるよう、また性別・キャリア段階・専門科・診療地域の多様性を確保するようリストを調整
- **構成**: 最終的に **10か国・17名** (欧州、北米、アジア)。専門分野は集中治療医学、腎臓内科、麻酔科、小児集中治療、臨床生物統計。**パネルのうち女性は2名**。キャリア段階は若手研究者からシニア教授まで
- **手法**: RAND/UCLA 適切性評価法 (反復デルファイ調査 + 司会付きパネル討議)

- **進め方**: STARDaki チェックリストの初版を起草 → 自由記述の調査 → 5段階リッカート尺度による複数ラウンドの採点とフィードバック収集。参加者とフィードバックは固有IDで匿名化され、プロセスはデータ統合とは独立に管理された
- **合意の終了基準(3条件すべて)**: ①全チェックリスト項目の**平均合意スコアが4点超**(5点満点)、②**一致率(Agreement Ratio, AR)が80%に到達**、③**専門家パネルがプロセス終了を投票で決定**。加えてスコアの散らばり(SD)も算出した
- **最終化**: デルファイ終了後に暫定版を編成しパネルの確認を得て、協働的な改訂の後、最終投票で承認・正式公開

△ 注意

パネルの構成に関する率直な注記 **17名中女性は2名、そして著者の利益相反開示にはバイオマーカー企業(Biomerieux、Baxter、Astute、Spectral Medical、Cytosorbents 等)との関係が複数記載されている**。著者ら自身も「より広い公衆代表者との正式な議論は行われなかった」と限界として明記し、将来の更新ではより広範なステークホルダーの関与が有益だとしている。**バイオマーカーの報告基準を、バイオマーカー開発と近い立場の専門家が定める**という構造は、この種の合意文書に共通する読みどころである。

4. 結果① 文献検索と組み入れ

検索で **13,075件**。重複 **4,563件**を除外し、タイトル・抄録スクリーニングでさらに **8,372件**を除外。**122件**の全文を精査した。

この122件からの除外内訳(原著の記載):

- **5件** — AKI発生に関するデータを提供していない
- **5件** — 抽出可能な診断データを報告していない
- **9件** — バイオマーカー測定とアウトカム追跡の完全な記述がない
- **1件** — レターであり、バイアスリスク評価に必要な完全な証拠が入手できない

これにより **107件**が残り、このうち **バイオマーカー採取後48時間以内のAKIを報告したのは28件(27%)**。さらにこの28件のうち、ベースライン腎機能・AKI定義と病期分類・採取とイベントのタイミング・アッセイ手法といった十分な方法論的詳細を報告していたのは **19件**。**19件のうち11件が QUADAS-2 の最高評点(7点)を達成した**。

48時間基準を満たしながら除外された9件の理由は、**最も多くがベースライン血清クレアチニンと検体取り扱い手順の記載不足**だった。

△ 注意

⚠ 数字の内的不整合(批判的吟味の材料) **本論文には、抄録と本文のあいだ、および本文内部に無視できない数値の食い違いがある。**

- **除外件数**: 本文の除外内訳は $5+5+9+1=20$ 件だが、 $122-20=102$ で、本文が言う「107件が残った」と合わない。抄録は「15件が報告不十分」($122-15=107$)としており、**抄録の15件と本文の20件が一致しない**
- **48時間以内の研究数**: 抄録は「107件のうち **19** 件のみが採取後48時間以内のAKI診断を報告」とするが、本文は「**28件(27%)**が報告し、そのうち19件が十分な方法論的詳細を持っていた」とする。**抄録が中間段階を飛ばしている**
- **高質研究の数**: 抄録は「これらの研究のうち **16** 件のみが QUADAS-2 に基づき高質と判定された」とするが、本文と Table 1 周辺の記述はいずれも「19件のうち **11** 件が最高評点7点」である。**16と11が一致しない**
- **NGAL の研究数**: 本文は「serum NGAL (**4**研究)、urinary NGAL (**3**研究)」とするが、Table 1 は sNGAL 3研究、uNGAL 2研究と記載する
- **u[TIMP-2]×[IGFBP7] の感度**: 本文は「感度は **23~100%**」とするが、Table 1 は **23~92%**。sNGAL の特異度も本文「69~100%」に対し Table 1 は **69~88%**

報告の完全性を論じる論文自身が、抄録・本文・表の間で数値を一致させられていないのは、ジャーナルクラブで指摘すべき最大の弱点である。本ノートではより詳細な本文および Table 1 の値を優先して記載した。

5. 結果② 報告の質 — STARD準拠率 54.5%

107件すべてが STARD 準拠と QUADAS-2 の評価を受けた。

核心の数字: **各報告が適切に報告していた STARD 項目は平均 54.5%(範囲 14.7~76.5%)**。

報告パターンは項目によって極端に分かれた。

Table 1. STARD 2015 の項目別に見た報告のギャップ(原著本文の記載)

STARD 項目	内容	報告率
Core items (構造化抄録、研究目的)	論文の入口にあたる基本項目	97~100%
item 13b	参照基準の評価者が、臨床情報と指標検査の結果を利用できる状態だったか	5%
item 15	判定不能 (indeterminate) の結果をどう扱ったか	4%
item 18	サンプルサイズの根拠	17%
item 12a/12b	指標検査の陽性カットオフまたは結果カテゴリの定義と根拠	34~74%が不完全

△ 注意

このパターンが意味すること **読み手の目に触れやすい項目 (抄録・目的) はほぼ完璧に書かれ、結果の妥当性を左右する項目 (盲検化・カットオフの根拠・サンプルサイズ) は書かれていない** — これが実態である。特に **item 13b (参照基準の評価者の盲検化)** がわずか **5%** というのは深刻である。AKIの判定には「ベースラインクレアチニンをどう決めるか」など主観的判断が入る。判定者がバイオマーカー値を見ていれば、**バイオマーカーが高い患者をAKIと判定しやすくなる** (組み込みバイアス)。この情報がない論文の感度・特異度は、原理的に上振れしている可能性を排除できない。

QUADAS-2 の4ドメイン評価では:

- **患者選択・指標検査・フロー/タイミング**: 一部の研究が中等度のバイアスリスク。主な理由は**非代表的なサンプリング**または**一貫しない検査プロトコル**
- **適用可能性の懸念**: 大半の研究で最小限だが、**15~20%** は臨床文脈との部分的な不整合を示した
- **参照検査の実施**: 堅牢で、**85%の研究が低バイアスリスク**に分類された

図の解説

Figure 2(原著・無改変。© The Author(s) 2026, CC BY-NC) 組み入れられたAKIバイオマーカー研究の質評価。パネル a と b が縦に並ぶ(原PDFでは横向きに配置されている)。パネル a: 横軸に STARD 2015 の項目番号(1, 2, 3, 4, 5, 6, 7, 8, 9, 10a, 10b, 11, 12a, 12b, 13a, 13b, 14, 15, 16, 17, 18, 19, 20, 21a, 21b, 22, 23, 24, 25, 26, 27, 28, 29, 30)、縦軸に「完全に報告された研究の割合(0~100%)」を取った青緑色の棒グラフ。目で追うと 山と谷が極端である。100% 近い柱が立つのは項目 1・2・3・4(タイトル、構造化抄録、背景、目的)と 14・20・27。一方 項目 13b・15・17・21b・25・29 はほぼ地面すれすれ(数%)。中間帯に 5・6・7・8・10a・10b・12b・24・26・30 が 60~95% で並ぶ。左端の「書きやすい項目」が天井に張り付き、中盤~右の「方法の核心」が床に落ちるといふ、非対称な形が一目で分かる。パネル b: QUADAS-2 の結果を横積み棒で示す。上段が「Risk of Bias」の4ドメイン(Patient selection、Index test、Reference test、Flow and timing)、下段が「Applicability Concern」の3ドメイン(Patient selection、Index test、Reference test)。緑=低リスク、赤(ピンク)=高リスク、黄=不明。Reference test の行は緑がほぼ全幅(低バイアス85%)を占めるのに対し、Patient selection と Index test の行は赤が半分近くまで伸び、Patient selection には黄の帯も混じる。Applicability の Patient selection・Index test も赤が3~5割を占める。読み方: 参照基準(AKIの判定そのもの)は比較的しっかりしているのに、「誰を組み入れたか」「検査をどう実施したか」が信用できない という構図。つまり問題はAKIの定義側ではなく、研究の入口と検査実施の記述にある。

6. 結果③ バイオマーカーの性能 — 幅の広さは何を意味するか

19件(採取後48時間以内にAKIを評価)のなかで、最も広く評価されたのは u[TIMP-2]×[IGFBP7](10研究)、次いで sNGAL、uNGAL。

Table 2. 採取後48時間以内に評価されたバイオマーカーの個別研究結果(原表 Table 1 の日本語化)

バイオマーカー	研究数	患者数	感度	特異度	臨床設定	AKI病期	AKI定義
u[TIMP-2]×[IGFBP7]	10	728	23～ 92%	39～ 96%	心臓手術、 一般ICU	All, Stage 1– 2, Stage 2–3	KDIGO
sNGAL	3	542	45～ 93%	69～ 88%	心臓手術、 敗血症、一 般ICU	All, progressive	KDIGO, AKIN, AKIN & RIFLE
sCr	3	101	68～ 89%	56～ 91%	心臓手術	All, Stage 2– 3, progressive	KDIGO, AKIN
uNGAL	2	150	65～ 80%	60～ 84%	心臓手術	All, progressive	KDIGO, AKIN
sCysC	2	150	77～ 95%	81～ 91%	心臓手術	All	AKIN
uIL-18	2	150	51～ 73%	66～ 84%	心臓手術、 一般ICU	All	AKIN
uCysC	1	150	47%	84%	心臓手術	All	AKIN
sIL-18	1	150	98%	65%	心臓手術	All	AKIN
sUA	1	60	75%	65%	心臓手術	Progressive	KDIGO
uLFABP/uCr	1	197	73%	68%	心臓手術	All	AKIN
uNGAL/uCr	1	197	76%	76%	心臓手術	All	AKIN

略語：u＝尿中、s＝血清、TIMP-2＝メタロプロテアーゼ組織阻害因子2、IGFBP7＝インスリン様成長因子結合蛋白7、NGAL＝好中球ゼラチナーゼ関連リポカリン、Cr＝クレアチニン、CysC＝シスタチンC、IL-18＝インターロイキン18、UA＝尿酸、LFABP＝肝型脂肪酸結合蛋白、AKIN＝Acute Kidney Injury Network、RIFLE＝Risk, Injury, Failure, Loss, End-stage kidney disease。

この表の読み方：

- **感度23%という下限が何に由来するかが重要である。**それは、混合ICU集団において **0.3 (ng/mL)²/1000** のカットオフを **48時間にわたる stage 2–3 AKI の検出**に適用した研究に由来す

る。これは FDA承認の適応(12時間以内の中等度～重症AKIの「予測」とは実質的に異なる文脈である。
any-stage AKI かつより短い採取窓に限定すれば、感度は70%を超えた

- sNGAL の感度45～93%・特異度69～88% という幅は、臨床設定(心臓手術、敗血症、一般ICU)とAKI 定義(KDIGO、AKIN、RIFLE、AKIN+RIFLE)の多様性を反映している
- 19件のうち 11件が QUADAS-2 最高評点(7点)、STARD準拠70%の閾値を満たしたのは10件のみ、完全準拠はゼロ。質を制限したサブセット(QUADAS-2 が7点の7研究)でも、u[TIMP-2]×[IGFBP7] の性能は全データセットと同様だった

そして著者らの解釈が本論文の要である：

> 研究間で観察された広い性能の幅は、個々のバイオマーカーの欠点ではなく、異質な集団に固定カットオフを適用し、異なるAKI定義を用い、可変の採取窓を適用したことの予測可能な帰結である。

この観察が、STARDaki として実装される標準化報告の根拠を補強した。

△ 注意

「質の高い研究に絞っても性能が変わらない」ことの意味 QUADAS-2 最高評点の7研究に絞っても u[TIMP-2]×[IGFBP7] の性能が全データセットと同様だった、という所見は二通りに読める。①バイアスが結果を歪めているわけではない(性能の幅は本当に文脈依存である)——著者らの解釈

②QUADAS-2 が、この領域で重要な異質性を捉えられていない——別の可能性 7研究というサブセットのサイズを考えると、どちらが正しいかを判別する力はない。この一文を「質の高い研究でも同じ性能だった=信頼できる」と読まないことが、抄読会での注意点になる。

7. 結果④ 専門家パネルが同定した現行研究の限界 🔍

パネルは既存のAKIバイオマーカー研究に4つの重大な方法論的限界を認めた。

Table 3. パネルが同定した限界と、STARDaki での対応

#	限界	具体的な中身	STARDaki での対応
①	時間的な曖昧さ (temporal ambiguity)	大多数の研究が、バイオマーカー採取・AKIリスク曝露期間・診断確定のタイムラインの関係を定義しておらず、診断精度推定を損なっている	item 8(設定と日付)、item 22(指標検査と参照基準の間の時間間隔)を大幅に詳細化。臨床的役割ごとに時間窓を定義(早期検出／予後評価／病因分類)
②	臨床的粒度の不足	大半がAKI重症度の層別を省略。約 70%がベースライン腎機能データを欠く 。エンドポイント分類の信頼性とリスク調整解析の両方を損なう	item 6(適格基準)でベースラインCr の決定法を必須化。item 21a で KDIGO 各stage の人数と割合を要求
③	非標準的なアウトカム判定	独立委員会による臨床エンドポイントの検証を記録した研究がごく少数	item 13b で 参照基準の評価者の盲検化を必須(mandatory blinding) に格上げ
④	技術的な弱点	研究用グレードのアッセイを臨床グレードの検証なしに使用 。機能マーカー(クレアチニン)と傷害マーカー(u[TIMP-2]×[IGFBP7])の不一致が検証を複雑にする	item 10a でアッセイプラットフォーム(研究用 vs FDA/CE認証)、検体取り扱い、バッチ内/間CV%、ロット間変動、採取からアッセイまでの時間窓を要求

パネルは [TIMP-2]×[IGFBP7] と NGAL を、早期AKI検出について最も頑健なエビデンスを持つバイオマーカーとして支持し、バイオマーカー未使用(biomarker-naïve)コホートでの前向き検証を強く求めた。

8. 結果⑤ 修正デルファイの経過 📦

17名のパネルが **17項目**の STARDaki チェックリストを修正オンライン調査で評価した。

ラウンド	参加者	全項目の平均スコア	SD	平均一致率(AR)
第1ラウンド	16名	4.66 (範囲 4.44–4.94)	0.54(0.24–0.87)	95.40% (81.30–100%)
第2ラウンド	17名(全員)	4.54	—	94%

第1ラウンドの時点で既に「合意」の基準(平均 > 4点、AR ≥ 80%)を満たしていたが、**収集したコメントに基づき本文とチェックリストを改訂し、第2ラウンドの採点を実施した**。第2ラウンドは第1ラウンドで達成された合意を確認する結果となった。

図の解説

Figure 3(原著・無改変。© The Author(s) 2026, CC BY-NC) 修正デルファイのまとめ。**パネル A(上)が第1ラウンド、パネル B(下)が第2ラウンド。**パネル A(Delphi First Round Feedback): 横軸に Item1～Item30(10a/10b、12a/12b、13a/13b、21a/21b を含む34ラベル)。左縦軸が平均スコア(0～7)、右縦軸が一致率(0～120%)。灰色の縦棒が各項目の**一致率(Agreement Ratio)**で、ほぼすべてが 5.4～5.9 相当(右軸で90～100%)の高さに揃う。**濃青の折れ線が平均スコア**で、4.4～4.9 の狭い帯をほぼ水平に横断し、Item2 と Item4、Item28～30 でわずかに高く、Item18 と Item27 でわずかに低い。各点には黒い誤差バー(SD)が付き、下端でも 3.7 を下回らない。背景の淡い青緑の帯が「平均 ± 1.5」の合意範囲で、上端6.0～6.5、下端3.0～3.3 のあたりを緩やかに波打ちながら走る。**誤差バーが帯からはみ出す項目は1つもない**のが視覚的な結論。**パネル B(Delphi Second Round Feedback):**横軸は改訂した14項目のみ(Item 1, 3, 5, 6, 8, 14, 18, 20, 21a, 21b, 22, 24, 26, 27)。右縦軸が82～102%に拡大されているため、灰色の一致率バーの高さの差が誇張されて見える — **Item 1・18・22・26・27 が100%に達し、Item 6・8・20・24 は約88%にとどまる。**濃青の平均スコア線は 4.3～4.9 を横断し、Item 1 が最高(約4.85)。淡青緑の「平均±1.5」帯は上端が右軸100%付近に張り付く。**読み方: 第1ラウンドで既に合意が成立しており、第2ラウンドは「反対意見を潰した」のではなく「改訂版でも合意が保たれたことを確認した」プロセスである。**逆に言えば、このデルファイは意見の分裂を解消していない(そもそも分裂がなかった)。専門家パネルの同質性を考える材料になる。

9. STARDaki チェックリスト — STARD 2015 に何を上乗せしたか

パネルは最終的な STARDaki チェックリスト(原著 Table 2)を承認した。**STARD 2015 の各項目に対し「Unchanged(変更なし)」「Elaborated(詳細化)」のいずれかを示す構成である。**以下、詳細化された主要項目を実務的に読める形で整理する。

Table 4. STARDaki の主な追加要件(原著 Table 2 を日本語化・要約)

STARD項目	元の内容	STARDaki が追加で求めるもの
1 (タイトル)	少なくとも1つの精度指標を用いた診断精度研究であることを明示	AUPRC も精度指標として明示的に許容。 主に KDIGO で定義されるAKIの存在に対する診断精度の研究 に適用。AKI関連の他アウトカム(発症・持続・進行・回復、MAKE の構成要素、CKD への進展)にも関連しうるが、中核は AKIの診断
3 (背景)	指標検査の意図された用途と臨床的役割を含む科学的・臨床的背景	バイオマーカーの推定される病態生理 (例:ポドサイト傷害、局所活性酸素種、髄質血流の変化)を記述。機序が完全に解明されていない場合は前臨床・臨床エビデンスに基づく現行仮説を要約。 意図された臨床的役割 (リスク層別化、予後評価、病因分類)を明示
5 (前向き/後ろ向き)	データ収集が指標検査・参照基準の実施の前か後か	後ろ向き研究では、AKI判定のバイアスを最小化する手段 (標準化されたAKI診断基準の適用、2名の研究者による独立判定など)を簡潔に記載
6 (適格基準)	適格基準	臨床的役割に応じた集団選択の明確化 。診断研究(早期AKI検出)=AKI未診断でAKIが疑われる患者(急性疾患、腎毒性薬曝露)を組み入れ、参照基準とベースラインCr の決定法を規定。予後研究=KDIGO確定AKI患者を組み入れ、CKD の組み入れ/除外(例:eGFR < 60 mL/min/1.73m ² が3か月超)と解析上の調整を規定。 研究集団は共通のAKIリスク因子を共有する単一の集団でなければならない 。AKI患者 vs 健常対照のような別コホート比較は予後的有用性を正しく評価できないため不適
7 (同定の根拠)	適格候補をどう同定したか	EHRスクリーニング(敗血症/ICU入室フラグ)、検査モニタリング(Cr/バイオマーカー閾値)、AKIレジストリ、医師紹介の別を記述。使用したツール・アルゴリズム(EHR内のKDIGO基準アラート等)を特定
8 (場所と時期)	適格候補が同定された設定・場所・日付	登録時の患者の所在 (救急外来、心臓CCU、一般病棟等)。登録開始・終了日と総研究期間。 AKIリスク/誘因イベントへの曝露時刻(手術時刻、敗血症診断時刻)を明確に報告 。「市中発症」「院内発症」という語を使うなら操作的定義を明記。 発症時刻が不明確な患者の扱い (除外/別サブグループ/最良の証拠に基づく分類)を記載
10a (指標検査)	再現可能な詳細	アッセイプラットフォーム (研究用グレード vs FDA/CE認証の臨床キット)、 検体取り扱い (保存温度、輸送時間、反復測定)、 バッチ内/バッチ間CV%

STARD項目	元の内容	STARDaki が追加で求めるもの
		(例:尿バイオマーカーで $\leq 15\%$)、 ロット間変動の評価、採取からアッセイまでの時間窓 (例:尿検体は2時間以内に冷蔵)。尿マーカーでは 尿クレアチニン補正の有無 を明示
10b(参照基準)	再現可能な詳細	クレアチニン測定 (特定間隔で事前設計された標準化検査 vs 臨床医の判断による測定)。 ベースラインCr と 参照Cr の決定法 (過去値をどう決めたか、AKI判定に使うCr をどう決めたか、ベースライン欠測時に KDIGO 推奨 (eGFR 75<成人)/120<小児)からの逆算、または入院時Cr の低い方 を使ったか)。 尿量記録の方法 (1～2時間ごとなど特定間隔での標準化測定、24時間以上のモニタリング期間)。 AKI判定が盲検化されていたか (標的バイオマーカー結果にアクセスできない独立専門家パネルによるか)。 バイオマーカー採取に対するAKI診断の窓
11(参照基準の選択理由)	代替がある場合の選択根拠	AKI基準の選択理由(any stage か stage 2-3 か等)を記述。AKI基準を参照基準としない場合(日次クレアチンクリアランスのAUCなど動的バイオマーカーに焦点を当てる研究)は、代替参照基準とそのAKI病態生理との関連を正当化
12a(カットオフ)	陽性カットオフの定義と根拠	検証(事前規定カットオフの検定)か探索(新規カットオフの導出)かを宣言 。検証なら出典(文献/メーカー/生物学的根拠)を述べ臨床アウトカム(病期別死亡率等)に紐づける。探索なら導出法(Youden指数等)を特定し外部検証の必要性を明記。 検出限界未満(例:0.5×LLoD で代入)・上限超(打ち切り率)の扱い を報告。動的閾値を使うなら宣言
13b(参照基準評価者の盲検化)	臨床情報と指標検査結果が参照基準の評価者に利用可能だったか	盲検化を必須(Mandatory blinding):参照基準の評価者はバイオマーカー結果を知らされてはならない
14(解析手法)	診断精度の推定・比較の方法	該当する場合に適切に設計・明示すべき事項として: 縦断データの扱い (バイオマーカーとAKIのタイミングに対するランドマーク解析、反復測定に対するGEE、患者単位(時点単位ではない)のクラスターブートストラップ)。 サブグループ解析 (事前規定サブグループ、交互作用項の調整、多重性制御＝主コホート→サブグループの階層的検定)
17(欠測の扱い)	指標検査・参照基準の欠測データの扱い	クレアチニンの補完 (36時間以内なら線形補間)または破棄(プロトコル駆動測定間の36時間超のギャップ)。 尿量の補完 (最低2時間測定)または破棄(測定ギャップの数・持続)。 intent to diagnose(ITD) / per-protocol (PP) 等に基づく解析を適宜報告

STARD項目	元の内容	STARDaki が追加で求めるもの
18(サンプルサイズ)	予定サンプルサイズと決定法	パラメータ付きのサンプルサイズ計算式 (期待される感度/特異度、誤差の許容範囲、検出力)を提示。事前規定サブグループ解析については、そのサブグループでの診断精度評価の計画方法(計画サンプルサイズや検出力計算、または探索的性格の明示)を報告
20(背景特性)	参加者の背景人口統計・臨床特性	リスク曝露の特定 (造影剤量、アミノグリコシド投与期間、外傷、重症感染、大手術等)。 感受性と臨床状態 (年齢、性別、ベースライン腎機能、併存疾患、重症例では主要な血行動態パラメータ＝年齢別パーセントイル未満のMAPか否か、昇圧薬使用の有無)
21a(重症度分布)	標的病態を有する者の重症度分布	標的病態のスペクトラム(どのKDIGO stage を含むか)を明確に定義し、AKI重症度の分布を報告。KDIGO 各stage(1, 2, 3)の人数と割合を明示。 stage をさらに細分(1s, 1a, 1b、尿量ベース/クレアチニンベース)しているならそれも明示。 標的病態を有する患者のうち何人がRRTを受け、何人が死亡したかを明示
21b(代替診断の分布)	標的病態を有しない者の代替診断の分布	AKIのない参加者(対照群)の臨床的・診断的特徴を明確に記述。代替病態の分布を報告: 安定CKD患者、有効循環血液量減少によるAKI患者、AKIの証拠がない他の急性疾患患者(AKIのない敗血症、AKIのない術後)、該当すれば健常対照
22(時間間隔)	指標検査と参照基準の間の時間間隔と臨床介入	バイオマーカーの臨床的役割に基づく時間窓の定義: ①早期検出＝採取からAKI診断まで(血清Cr上昇前の早期予測なら24時間以内など)、②予後評価＝採取から臨床エンドポイントまで(RRTや30日死亡の予測なら7日など)、③病因分類＝曝露/傷害(腎毒性薬投与、敗血症発症)から採取まで(虚血再灌流傷害を捉えるなら人工心肺後6時間など)。 採取と参照基準評価の間に生じた 臨床介入(輸液蘇生、利尿薬) を報告。 Cr/尿量データのカバー範囲 (採取24時間前から採取48時間後まで等)を報告。 エンドポイントの独立性 (盲検化判定)を明確化。 プロトコル違反 (規定窓内のCr/尿量データが不完全な患者の除外等)を明確化
24(精度推定)	診断精度の推定値と精度(95%CI等)	感度、特異度、AUC、PPV、NPV、LR+、LR- を95%CI付きで報告。 標的病態が比較的稀な研究では、不均衡データに関連する指標(Precision＝PPV、Recall＝感度、 F1スコア、Youden指数)も検討。動的診断モデル(連続モニタリングデータ)や時間依存評価を要する研究では、時間/データ蓄積に伴う性能変化を反映する AMOC曲線下面積 の報告も検討

STARD項目	元の内容	STARDaki が追加で求めるもの
25(有害事象)	指標検査・参照基準の実施による有害事象	採取に関連する有害事象を明示的に報告(ゼロであっても)
26(限界)	バイアス源、統計的不確実性、一般化可能性を含む研究の限界	AKI診断研究に固有の限界を議論: 参照基準関連 (AKI臨床判定のバイアス＝指標検査への盲検化欠如、判定者間変動、ベースラインCr決定の主観性)、 データ品質関連 (ベースラインCr推定法、Cr/尿量モニタリングのギャップ)、 時間的・介入的交絡、一般化可能性、プロトコル逸脱と追跡不能 (ITD と PP の両方の結果を報告)
27(実践への含意)	意図された用途と臨床的役割を含む実践への含意	十分なエビデンスがあり適切な場合には: 行動可能な閾値とその意図された臨床的用途 (腎臓内科コンサルトを起動する特定のバイオマーカー値など)、 潜在的な医療経済的含意 (費用対効果)の議論を推奨

STARD 2015 のうち **item 2(構造化抄録)**、**4(研究目的と仮説)**、**9(連続・ランダム・便宜的サンプリングの別)**、**12b(参照基準のカットオフ)**、**13a(指標検査の実施者/読影者の盲検化)**、**15(判定不能の扱い)**、**19(フロー図)**、**23(クロス集計)**、**28(登録番号)**、**29(プロトコルの入手先)**、**30(資金源)** は「Unchanged」とされた。

10. 考察 — STARDaki が体系化する3原則と、適用範囲の境界

3つの原則

著者らは STARDaki が体系的限界に対処するために体系化した3原則を挙げる。

原則	内容	狙う問題
① 時間的感度(temporal sensitivity)	正確なバイオマーカー採取窓を必須とする	測定の違いによる妥当性の侵食を防ぐ
② 交絡制御(confounder control)	ベースライン腎機能と輸液状態の報告を強制する	バイオマーカーと疾患の関係を分離する
③ 標準の互換性(standard compatibility)	KDIGO/ADQI の枠組みと調和させる	新規バイオマーカー検証における循環論法(circularity)を防ぐ

参照基準そのものの限界に対する率直な認識

著者らは、現行のAKI基準が「実際の腎の健康状態への不完全な窓であり、傷害/機能障害という連続体のなかに恣意的なカットオフを持ち込んでいる」と明言する。そして重要な留保を置く：

> **STARDaki の推奨は、現行の KDIGO 標準に対してバイオマーカーを評価するためのものであり、「許容できる性能」のベンチマークを提供するものではない。**例えば TIMP-2 と IGFBP7 の性能は、現行のAKI標準を前提とすれば生物学的に達成可能な最大値に近いかもしれない。

さらに未来を見据えた指摘がある。新規バイオマーカーが将来のAKI定義に組み込まれれば、それらはゴールドスタンダードの一部として即座に完璧な性能を達成してしまう。そうした評価は本拡張の範囲外だが、STARDaki による標準化報告は、AKIを再定義しバイオマーカーを組み込む将来の取り組みにおけるバイアスを最小化するのに役立つ。

u[TIMP-2]×[IGFBP7] という「例外」

著者らは、報告の質の悪さが支配的ななかで **u[TIMP-2]×[IGFBP7]** を注目すべき例外として挙げる。初期の検証研究が **12時間以内の中等度～重症AKI予測**について良好な診断効率を示し、**2014年のFDA承認**につながった。その臨床応用における性能は、**標準化された採取プロトコル、AKI誘因との明示的な時間的整合、臨床グレードのアッセイ検証**という厳格な方法論的透明性に支えられている。**成人で唯一のFDA承認 AKIバイオマーカーパネル**として、高品質な報告がベンチの発見をベッドサイドのツールへ橋渡ししうることを例証している。

なお **尿中NGAL** は小児用にFDA承認されているが、本レビューで入手可能なエビデンスは推奨を支持するには不十分だった。

STARDaki と TRIPOD の線引き(実務上最も重要)

△ 注意

予測モデルの研究は **STARDaki** ではなく **TRIPOD に従う** STARDaki の適用範囲は、**AKIを早期に診断するバイオマーカーのDTA(診断精度)研究**であり、AKIの進行や予後アウトカムの評価にも及ぶ。しかし方法論的境界は明確にされている：

- 予測モデルに焦点を当てる研究は、**感度・特異度・AUC** といったDTA関連指標を用いていたとしても、**STARDaki** ではなく **TRIPOD 拡張に従うべきである**
- これは特に**バイオマーカーの組み合わせ**に関連する。単独であれ臨床データと合わせたリスク予測モデリングであれ、組み合わせは本文書の範囲外で、**TRIPOD 型の枠組み**を要する
- 両者はともに透明性と報告の完全性を重視するが、**中核的目的が構造的な差を生む**：DTA研究は**指標検査と参照基準(KDIGO基準等)の一致の検証**に焦点を当て、予測モデル研究は**モデル開発、内部/外部検証、臨床的有用性解析**に集中する
- AKI固有の複雑さ(参照基準の異質性、動的な時間依存変数)を踏まえると、将来的に **TRIPOD-AKI 拡張**の開発が正当化されるかもしれない

当院の実務への含意：AI/機械学習でAKIやRRS対象イベントを予測するプロジェクトは **TRIPOD+AI** (Collins GS, et al. BMJ 2024;385:e078378)を参照すべきであって、STARDaki ではない。

✓ Take home message

TAKE HOME

結論 **AKIバイオマーカーの感度・特異度が研究ごとに大きく違うのは、バイオマーカーが悪いからではなく、集団もAKI定義も採取タイミングもバラバラなまま固定カットオフを当てているからである**。論文や製品資料の数字を見たら、まず「どの集団の、どのAKI定義で、採取から何時間以内か」を確認する。そして自分たちが診断研究を書く/読むときは、この5つが書かれているかを見る — **ベースライン腎機能/KDIGO病期別の成績/採取からAKI診断までの時間窓/アッセイが臨床グレードか/AKI判定者がバイオマーカー値に盲検化されていたか**。**現行のAKIバイオマーカー研究は、STARD項目の平均54.5%しか報告していない。**

AKIバイオマーカーの
論文・資料を読む

どの集団が
明記されている?

明記


AKI定義と病期
KDIGO stage別?


明記

採取からAKI診断
までの時間窓は?

不明

不明





関連

- AKI診断の基礎とクレアチニンの限界: [AKI Update 2016\(クレアチニンの限界と診断のPitfall\)](#)
- AKI関連の最新トピック: [最近のAKI関連トピックまとめ\(ICM 2019 Focus on critical care nephrology\)](#) / [重症患者のAKI\(Critical Care Nephrology\)ICM2019](#)
- 敗血症関連AKI: [敗血症性AKIレビュー\(Bellomo 2017\)](#)
- AKIの長期予後: [AKIの長期アウトカムとケア改善戦略](#)

- 同じく「研究の質・報告の質」を論じる: 2026 メタ解析が食い違うとき — 統合推定値の先を読む (バイアスリスク層別でメルトニンの効果は消える・CC) / 2026 CLEANSE試験は「陰性」ではなく「解釈不能」 — 効果量の楽観・時刻0の非対称・アウトカム選択 (Matters Arising・CC)
 - ウォッチャー: Critical Care ウォッチャー
 - リファレンス: 医学・論文
-



批判的吟味 — ジャーナルクラブでの論点

- 1 **論文自身の数値が抄録・本文・表の間で一致していない。**除外件数(15 vs 20)、48時間以内の研究数(19 vs 28)、高質研究数(16 vs 11)、NGAL の研究数(本文4/3 vs Table 3/2)、u[TIMP-2]×[IGFBP7] の感度上限(本文100% vs Table 92%)、sNGAL の特異度上限(本文100% vs Table 88%)。報告の完全性を要求する文書としては痛い。査読・編集過程で拾われるべきだった。
- 2 **事前登録したメタ解析を実施しなかった判断は妥当か。**異質性が階層的サマリーROCの前提を破るという理由は説得的だが、「**メタ解析できない**」ことと「**範囲で記述する**」ことの間には、**メタ回帰やサブグループ別の統合など中間的な選択肢がある**。なぜ一切の定量統合を放棄したのか、感度分析すら示されないのは物足りない。
- 3 **専門家パネルの選定方法。**Expertscape.com の引用指標で同定するのは透明ではあるが、**引用数はバイオマーカー推進派に偏りうる**(否定的な研究は引用が伸びにくい)。17名中女性2名という構成、そして複数の著者がバイオマーカー企業との関係を開示している点も含め、「**バイオマーカーの報告基準を、バイオマーカー開発に近い立場の専門家が定める**」**構造的な利益相反**は明示的に議論されていない。
- 4 **デルファイが「合意」ではなく「同意」を測っている可能性。**第1ラウンドで既に全項目が平均4.66・AR 95.4% と極めて高い。**意見の分裂が最初から存在しなかった**ことは、パネルの同質性を示唆する。反対意見が出なかったチェックリストは、**現場で実行可能かどうかの検証を経ていない**とも言える。
- 5 **STARDaki 自体の実行可能性が検証されていない。**17項目の詳細化要件は網羅的だが、**これに完全準拠した研究が実際に実施可能か、パイロット適用による検証がない**。例えば item 10b が求める「AKI判定を、バイオマーカー結果にアクセスできない独立専門家パネルが盲検下で行う」は、多施設前向き研究では相当なコストになる。既存107件の平均準拠率が54.5%だった STARD よりさらに要求水準が上がることで、**準拠率がむしろ下がる**可能性も否定できない。
- 6 **「48時間」という組み入れ窓の妥当性。**生理学的根拠(クレアチニン上昇の遅れ24~36時間、GFR低下で半減期延長)は明快だが、**この窓を採用したことで107件中79件が解析から落ちた**。48時間より長い窓の研究(AKIの進行や予後を見る研究)が体系的に排除されており、「**早期診断**」に焦点を絞った結果として、AKIバイオマーカーの臨床的役割の一部しか評価していない。

- 7 QUADAS-2 最高評点の7研究でも性能が変わらなかったことの解釈。著者らは「性能の幅は文脈依存であってバイアスではない」と読むが、**QUADAS-2 がこの領域の重要な異質性(カットオフの由来、採取窓)を捉えていないという逆の解釈も等しく成立する。**n=7 では判別できない。
- 8 参照基準の循環性という根本問題への回答は先送りされている。著者らは「新規バイオマーカーが将来のAKI定義に組み込まれれば、ゴールドスタンダードの一部として即座に完璧な性能を達成する」と正しく指摘するが、**では今どうすべきかの答えは「STARDaki に従って報告せよ」に留まる。**傷害マーカーと機能マーカーの不一致をどう扱うかという実質的な方法論的解決は提示されていない。
- 9 臨床医にとっての実利は間接的である。本文書は**研究者向けの報告基準**であって、「TIMP-2×IGFBP7をいつ測るべきか」「カットオフをどこに置くか」には答えない。著者ら自身が「許容できる性能のベンチマークを提供するものではない」と明記している。**ベッドサイドの意思決定を今日変える論文ではない。**
- 10 公衆・患者代表の関与がない。著者ら自身が限界として認めている。診断検査の「臨床的役割」(腎臓内科コンサルトの起動、費用対効果)を論じる以上、患者側の視点は無関係ではない。

主要な引用文献

#	内容	出典
1	重症患者のAKI疫学(多国籍 AKI-EPI 研究)	Hoste EAJ, et al. Intensive Care Med. 2015;41:1411–23
6	AKI診断の国際標準	KDIGO Acute Kidney Injury Guideline
7	クレアチニンの生理から臨床応用まで(限界の整理)	Kashani K, Rosner MH, Ostermann M. Eur J Intern Med. 2020;72:9–14
11	細胞周期停止バイオマーカーの発見と検証	Kashani K, et al. Crit Care. 2013;17:R25
12	AKIバイオマーカーに関する ADQI 合意声明	Ostermann M, Zarbock A, Goldstein S, et al. JAMA Netw Open. 2020;3:e2019209
14	STARD 2015(本拡張の土台となる25項目)	Bossuyt PM, et al. BMJ. 2015;351:h5527
15	認知症領域のSTARD拡張(本研究が設計上手本にした)	Noel-Storr AH, et al. Neurology. 2014;83:364–73
18	QUADAS-2(診断精度研究のバイアスリスク評価)	Whiting PF, et al. Ann Intern Med. 2011;155:529–36
20	デルファイ法など合意形成手法のレビュー	Humphrey-Murto S, et al. Acad Med. 2017;92:1491–8
21	デルファイ研究における合意の測定	von der Gracht HA. Technol Forecast Soc Change. 2012;79:1525–36
22	細胞周期停止バイオマーカーの臨床用カットオフの導出と検証	Hoste EAJ, et al. Nephrol Dial Transplant. 2014;29:2054–61
27	細胞周期停止バイオマーカーの臨床判定による検証(FDA承認の基盤)	Bihorac A, et al. Am J Respir Crit Care Med. 2014;189:932–9
28	敗血症関連AKI の ADQI 第28回ワークグループ合意報告	Zarbock A, Nadim MK, Pickkers P, et al. Nat Rev Nephrol. 2023;19:401–17

#	内容	出典
30	TRIPOD(予測モデル研究の報告基準。 STARDaki の適用範囲外はこちら)	Collins GS, et al. Ann Intern Med. 2015;162:55–63
32	TRIPOD+AI(機械学習を用いる予測モデルの報告基準)	Collins GS, et al. BMJ. 2024;385:e078378

本ページは原論文の要約・解説です。数値は原論文から転記していますが、引用の際は必ず原論文(上記DOI)をご確認ください。
原著の図表は著作権のため本ページには掲載していません(本文の「図の解説」を参照)。作成: Claude Code(聖路加ICUジャーナルクラブ運用)。