

必要なときだけランダム化する強化学習が集中治療AIの第3の波 — 臨床・RCT・実世界データを一つにする構想 (What's New・ICM2026)

出典	Elbers P, Ercole A, Angus DC. Fully flexing the potential of AI in intensive care: reinforcement learning with randomization when needed. Intensive Care Med. 2026. DOI: 10.1007/s00134-026-08576-2
掲載誌	Intensive Care Medicine (2026)
原著	doi.org/10.1007/s00134-026-08576-2 (本文PDFは別途)
原題	Fully flexing the potential of AI in intensive care: reinforcement learning with randomization when needed



聖路加ICUでの実践への示唆

本稿は提言であり、明日から変わる診療は無い。だが当院はすでにバイタル自動収集とRRS (Rapid Response System: 院内急変対応システム) でデータ基盤を持っており、著者らの言う「第1の波」(予測AI) と「第3の波」(学習しながら治療する系) の分岐点に、当院自身が立っている。

病棟プロトコルへの落とし込み — いま変わらないこと／これから準備すること

- **変わらない**: RL (reinforcement learning: 強化学習) に基づく治療推奨をベッドサイドで使うことは、世界のどこでもまだ行われていない。当院でも現時点で臨床導入の対象にならない。
- **変わる(意思決定の設計)**: 当院のバイタル自動収集・RRSの出力を「アラートを出すもの」から「意思決定を記録するもの」へ位置づけ直す。本稿の中核は、アラートの精度ではなく **どの時点で・誰が・どちらの選択肢を選び・その後どうなったか** を欠損なく残せているかにある。この記録が無ければ、どんなAIも後から因果を推定できない。
- **RRSは「決定の連続」として設計できる**: 起動基準を満たした患者に対する「ICU入室／病棟でフォロー／専門科コンサルト」は、まさに逐次的意思決定である。ここは将来の学習系の入口になりうる。

当院で第3の波を検証するなら、必要になるものを4つに分けて考える。

要素	具体的に必要なもの	当院の現状に照らした論点
データ 基盤	バイタルの自動収集(時刻付き)、投薬・輸液・呼吸器設定の実施時刻、検査値、転帰。「実施されなかった」ことも記録として残る構造	自動収集は稼働中。弱点は「介入の時刻」と「意思決定の理由」が残らないこと。理由が無いと交絡(後述)を除けない
ランダム化の 埋め込み	不確実なときにだけ、妥当な選択肢の間で割付を行う仕組み。既存の電子カルテ・RRSのワークフローの中に、追加作業ゼロで組み込む	「臨床業務の中の試験」になるため、通常の治療フローとは別の同意・説明の設計が要る
倫理審 査・ガ バナ ンス	医療機器プログラム(SaMD)該当性の判断、IRB(臨床研究審査委員会)での枠組み、患者・家族への説明方法(包括同意か個別同意か)、モデル更新のたびの再審査の可否、監査ログ	「継続的に学習して方針が変わる系」は、承認時点の性能を保証する現行の審査になじまない。ここが最大の関門
評価指 標	臨床アウトカム(死亡・臓器不全・ICU在室日数)だけでなく、推奨の受け入れ率、推奨から逸脱した理由、アラート疲れ、記録作業時間、モデルの不確実性の推移	本稿が引く敗血症アラートの教訓(業務量だけ増えて転帰は改善せず)を繰り返さないため、業務負荷の測定を最初から指標に入れる

△ 注意

導入の前に確認すべきこと「**ロジスティック(業務効率)用途だから低リスク**」という分類は当院でも**成り立たない**。本稿が明確に指摘するとおり、ベッド配分・優先順位づけ・ワークフロー変更を通じて、業務系AIも患者転帰に影響する。RRSの起動優先順位づけに機械学習を使う場合、それは事務的AIではなく臨床AIとして審査すべきである。

この論文の位置づけ (Known / Unknown / What's new)

補足

リサーチ・イン・コンテキスト

- **Known**: 集中治療は高次元データが大量に取得される領域で、AIの応用先として自然な土壌である。ICU公開データベースの普及で、資源配分・再入室リスク・急変予測・敗血症予測・サブフェノタイプ分類・敗血症性ショックの逐次的治療戦略まで、幅広いタスク特化型の機械学習モデルが報告されてきた。
- **Unknown**: それらの多くはベッドサイドに実装されず、実装されたものも「行動につながらない」「効果がない」という点で期待外れだった。なぜ論文から実践へ渡れないのか、どうすればAIが集中治療の実践を本当に変えるのかは、まだ答えが出ていない。
- **What's new**: 著者らはAI革新を3つの波として整理する。第1の波＝予測AI・タスク特化型機械学習(すでに到来、しかし臨床変革には至らず)、第2の波＝生成AI/LLM/アンビエントAIスクライブ/エージェント型AI(到来しつつある)、そして第3の波＝オンライン強化学習にベッドサイドでの適応的ランダム化を埋め込み、日常診療そのものを継続学習システムに変える構想。これはRCT (randomised clinical trial: ランダム化比較試験) と実世界データ解析の分断を橋渡しし、EBM (evidence-based medicine) の新しいモデルになりうると主張する。

全体要約

要旨

ひとことで 集中治療AIの真価は予測でも文章生成でもなく、「**確信があるときは推奨し、不確実なときは妥当な選択肢の間でランダム化して学ぶ**」オンライン強化学習を診療に埋め込むことにある。ランダム化を残したまま学習を回すことで、因果の厳密さと実世界のスピードを同時に得られる、という構想である。

- 集中治療は「不確実性下での複雑・連続・逐次的な高リスク意思決定」の連なりであり、過去の全患者の高次元データでAIを訓練できる点でAIの自然な生息地である。
- 第1の波（予測AI）は数多くのモデルを生んだが、ベッドサイドに実装されたものは少なく、実装されたものも期待外れだった。敗血症アラートは臨床医の業務量を増やしただけで転帰の明確な改善を示さず、サブフェノタイプ分類は患者の異質性への認識を高めたが治療戦略をまだ変えていない。
- 失敗そのものは創薬パイプラインと同じで想定内かつ望ましい面もある。ただし「バイト（データ）とベッドサイドの隔たり」が広がるにつれ、論文から実践へという要求は強まっている。
- 実装を段階化する「AIレディネス」型の道筋（低リスク・低複雑度の事務的AI → ロジスティックAI → 臨床意思決定支援としての医療AI）は有用だが、事務系と臨床系の境界は見た目ほど明確ではない。純粋に業務系に見えるシステムも、資源配分・優先順位づけ・ワークフロー変更を通じて患者転帰に影響しうる。
- 第2の波＝生成AI。自己教師あり学習で大規模・非構造化データから訓練された基盤モデルは、タスク特化型の微調整をほとんど、あるいは全く必要とせず幅広いタスクへ汎化する。LLMは集中治療の専門家レベル試験問題で超人的成績を示した。
- 生成AIの一部は規制監督をすり抜けており、「最もよく臨床試験されたアルゴリズムは研究から現実へ進めないのに、最も試験されていないものが患者の近くで目立つ」というパラドックスを生んでいる。LLMチャットボットが医療者に診断・治療の示唆を求めて非規制のまま頻用されているのが典型例。
- アンビエントAIスクライブは外来領域に大規模に入り、診療記録と医師-患者コミュニケーションを変えつつある。ICUでは家族との面談記録などに使える可能性がある一方、回診や多職種カンファレンスをカバーするには技術的・運用上の障壁が残る。
- 次の地平は「エージェント型臨床AI」。自律的・目標志向の複数の専門モデルがデジタルの同僚として協働し、患者を継続監視し、悪化傾向を検出し、人工呼吸器設定を提案し、薬剤安全性を高め、日々の回診サマリーを準備する。集中治療ではまだ未実装。
- 第3の波（著者らが最も推す構想）＝AIと従来型RCTの分断の解消。RCTは強い因果的証拠を与えるが、狭く定義された意思決定の平均治療効果に限られ、遅く実施困難なため、現代のICUが直面する意思決定全

体のごく一部しかカバーできない。一方、実世界データのAI解析は速く安価だが、交絡と因果性の証明不足に悩まされる。

- 解決策は、オンライン強化学習にベッドサイドの適応的ランダム化を埋め込むこと。モデルが十分に確信できるときは治療を推奨し(エビデンスに基づく機会損失を減らす)、不確実性が大きすぎるときは妥当な選択肢の間で推奨をランダム化し、転帰を観察して方針(policy)を継続的に更新する。
- これはベイズ適応プラットフォーム試験の自然な延長である。適応プラットフォーム試験はすでに、多腕バンディット(multiarm bandits)と呼ばれる粗い強化学習モデルのアナログ版に似ている。第3の波の構想は、そのプロセス全体をデジタル化し、ケアの提供そのものと融合させる。
- リスクも明示されている。誤ったデータや意図的に操作された入力データ、同一患者に対して複数モデルを同時に走らせるスケーリングと運用の難しさ。厳格な監督・検証・悪用への安全装置が不可欠。
- 適切に実装されれば、第3の波は臨床ケア・ランダム化試験・実世界エビデンスを再統合し、最も速く安全に知識を得るEBMの新しいモデルとなり、集中治療の実践に革命をもたらす。

詳細

1. まず前提 — AI・強化学習・ランダム化の基礎(初めての人にも)

要旨

5分で背景を掴む この論文を読むには、「予測するAI」と「行動を選ぶAI」の違いが分かればよい。前者は結果を当てる。後者は何をするかを決める。集中治療の意思決定支援が難しいのは、後者だからである。

用語を初出で定義する。

用語	定義	集中治療での例
AI (artificial intelligence, 人工知能)	データから規則性を学び、予測や判断を行うシステムの総称	以下すべてを含む上位概念
機械学習 (machine learning)	正解ラベル付きデータから入力と出力の対応を学ぶ。多くは「予測」に使う	敗血症発症の予測、ICU再入室リスクの推定
教師あり学習	「この患者は敗血症になった／ならなかった」という正解を与えて学ぶ	急変予測モデル
自己教師あり学習 (self-supervised learning)	正解ラベルを人が付けず、データ自身から学習課題を作る (例: 次の単語を当てる)	LLMの事前学習。本稿の第2の波の技術的基盤
基盤モデル (foundation model)	大規模データで訓練され、タスク特化の微調整をほとんど／全く要せずに多様な課題へ汎化するモデル	GPT系・画像/音声の大規模モデル
LLM (large language model, 大規模言語モデル)	生成AIのうち言語を扱う代表格	集中治療の専門家レベル試験問題で超人的成績 (本稿引用8)
エージェント型AI (agentic AI)	自律的・目標志向で、複数の専門モデルが協働して一連の作業をこなす	継続監視・悪化傾向の検出・呼吸器設定の提案・回診サマリー作成
強化学習 (RL, reinforcement learning)	「状態」を見て「行動」を選び、その結果得られる「報酬」を最大化する方針 (policy) を学ぶ枠組み	患者の現在の状態から、その時点で最良の治療戦略を選ぶ
方針 (policy)	状態 → 行動 の対応関係。RLが学習する対象そのもの	「乳酸が上がり血圧が下がったらノルアドレナリンを増やす」というルールの束
オンライン学習／オフライン学習	オンライン＝実際に行動して結果を観察しながら学ぶ。オフライン＝過去の記録だけから学ぶ	現行のICU向けRL研究はすべてオフライン (後ろ向きデータ) に留まる

なぜ集中治療はRLと相性が良いのか。 本稿の出発点は「集中治療医学の全体を、ひとつの大きな連続的・逐次的な意思決定プロセスとして見る」という視点である。輸液を足すか、昇圧薬を切り替えるか、PEEPを上げるか、抜管するか。一つひとつの決定が次の患者状態を作り、その状態が次の決定を規定する。この構造はまさにRLが扱う問題設定と同型である。だからRLは集中治療医の「自然な相棒 (natural companion)」になりうる、と著者らは書く。

では何が問題か — オフラインRLの3つの落とし穴。本稿は「交絡」と「因果性の証明不足」という言葉で簡潔に述べるが、AIに詳しくない読者のために、後ろ向きデータだけからRLを学習させたときに起きる典型的な失敗を分けて説明する。

落とし穴	何が起きるか	ICUでの具体像
適応による交絡 (confounding by indication)	過去の記録では「その治療が選ばれた理由」=患者の重症度そのものである。理由が記録に残っていないと、モデルは「治療 → 悪い転帰」と学んでしまう	重症例ほど昇圧薬を早く多く使う。素朴に学習すると「昇圧薬は死亡を増やす」という方針が出る
分布シフト (distributional shift)	学習に使ったデータの中に存在しない行動をモデルが推奨しても、その行動の結果を誰も観測していないため、正しさを確かめる術がない	「この状態では輸液を2Lではなく200mLに絞れ」という推奨を出しても、過去にそう管理した症例が無ければ検証不能
価値の過大評価 (value overestimation)	観測が少ない行動ほど推定値のばらつきが大きく、最大値を取る学習の性質上、たまたま良く見えた稀な行動が「最良」として選ばれやすい	数例しかない特殊な薬剤の組み合わせが、あたかも最善策として浮上する

これら3つは互いに絡み合い、いずれも「実際にやってみた結果を観測していない」ことに由来する。だから、後ろ向きデータをどれだけ増やしても原理的には解けない。

そこでランダム化を戻す。上記3つを一撃で無効化する古典的な道具がランダム化である。割付が患者の状態と独立になれば、適応による交絡は消える。ランダム化によって普段は選ばれない行動もデータに入るので、分布シフトも埋まる。行動ごとの観測数が確保されるので、価値の過大評価も抑えられる。本稿の核心は「AIか、RCTか」ではなく、**RLの探索(exploration)をランダム化として実装する**という発想の転換にある。

関連する既存の試験デザインとの距離。

デザイン	何をするか	本稿の構想との関係
従来型RCT	あらかじめ決めた2群に固定確率で割付け、平均治療効果を推定	因果的妥当性は高いが、遅く・狭く・高コスト。ICUの意思決定の「ごく一部」しかカバーできない
多腕バンディット (multiarm bandit)	複数の選択肢を試しながら、成績の良い腕へ割付確率を寄せていく。探索と活用のトレードオフを扱う	本稿が「粗い強化学習モデル」と呼ぶもの。ただし患者状態を考慮しない点で、状態依存のRLより単純
ベイズ適応プラットフォーム試験	中間解析ごとに割付確率を更新し、効かない腕を落とし、新しい腕を追加する	著者らはこれを「バンディットのアナログ版」と位置づける。第3の波はこれをデジタル化し診療と融合させたもの
SMART (sequential multiple assignment randomized trial)	治療の各段階で再ランダム化し、逐次的な治療戦略(動的治療レジメン)を比較する	逐次的意思決定をランダム化で評価する既存の正攻法。第3の波は、この再ランダム化をモデルの不確実性が高いときだけ自動発動させる形と読める
第3の波(本稿の構想)	診療そのものの中で、確信があれば推奨、不確実なら妥当な選択肢間でランダム化し、転帰を観測して方針を継続更新	ケア提供・ランダム化試験・実世界エビデンスの再統合

2. 背景と目的

集中治療医学はAIの自然な生息地である、という一文から本稿は始まる。理由は2つ。第一に、これまでの重症患者の治療中に日常的に記録された膨大な高次元データを、そのままAIの訓練に使える。第二に、この領域の意思決定は複雑・連続的・逐次的で、しかも不確実性下の高リスク判断であり、AIによる支援がより適時で個別化された治療戦略を可能にしうる。

この背景のもと、初期の、そして今なお続くAI革新の第1波が急速に立ち上がった。公開ICUデータベースの利用可能性の高まりがそれを後押しした。目的は、この流れを3つの波として整理し、まだ試みられていないが理論的には可能な「第3の波」を提示することにある。

3. 本稿の位置づけ(原著研究ではない)

本稿は ICM の WHAT'S NEW IN INTENSIVE CARE 欄に掲載されたオピニオン／展望論文である。新たな患者データ・統計解析・アウトカムは含まない。主張は15件の引用文献に支えられており、その大半は

2024～2026年の総説・システマティックレビュー・合意文書である。したがって本ノートの「結果」に相当するのは、著者らの論証の構造そのものである。

なお著者らは、可読性と文体の改善、および図の作成に生成AIを使用したことを明記している。この論文自体が第2の波の実例になっている。

4. 第1の波 — 予測AI・タスク特化型機械学習

公開ICUデータベースの普及に支えられ、幅広いタスクに対する幅広い機械学習モデルが登場した。本稿が例示するのは以下である。

タスク	内容
ICU資源配分の支援	ベッド・人員の割り当てに関する情報提供
ICU再入室リスクの推定	退室後の再入室確率
臨床的悪化の予測	急変の事前検出
敗血症の予測 (forecasting sepsis)	発症前の警告
サブフェノタイプへのクラスタリング	治療反応性が異なりうる患者集団の同定
逐次的意思決定戦略の提示	敗血症性ショックの継続管理のような、複雑で反復的な臨床問題

5. なぜ第1の波は臨床を変えなかったか

論文上は多数の革新的解決策が記述された一方、実際に重症患者のベッドサイドで実装されたものはわずかである。さらに、臨床使用まで到達したAI由来のモデルや知見も期待外れだった。理由は2つに整理される。

失敗の型	具体例(本稿の記載)
行動可能性 (actionability) の欠如	サブフェノタイプ分類は、重症症候群における患者の異質性への認識は高めたが、治療戦略はまだ変えていない
有効性 (effectiveness) の欠如	敗血症アラートは臨床医の業務量を増やしたが、転帰の明確な改善はもたらさなかった

その結果、これまでのところAIは集中治療の実践に変革的な変化をもたらしていない、と著者らは断じる。

ただし著者らはこの現象を全否定しない。ある程度は予測可能であり、望ましくもある。創薬パイプラインで多くの候補薬がベッドサイドに届かないのと同じで、それは「テストの過程で適切に失敗している」からである。とはいえバイトとベッドサイドの隔たりが広がるにつれ、論文から実践へ移れという声は大きくなっている。

橋渡しの道筋とその限界。実装を阻むのは技術的・組織的・臨床的な課題である。段階的なAIレディネスに基づくアプローチが役立ちうる — 低リスク・低複雑度の事務的AIから始め、ロジスティックAIへ進み、最後に臨床意思決定支援システムとしての医療AIを統合する。しかし著者らはここに重要な留保を置く。事務系と臨床系の境界は見かけよりも曖昧である。純粋にロジスティックに見えるシステムでも、資源配分・優先順位づけ・ワークフロー変更を通じて患者転帰に影響しうるため、その分類が示唆する以上の厳格な精査を要求しうる。

6. 第2の波 — 生成AI、LLM、アンビエントスクライプ、エージェント型AI

その間に、生成AIの台頭が第2のAI革新の波に火をつけた。大規模でしばしば非構造化のデータセットを自己教師あり学習で訓練し、テキスト・画像・動画・音声などの新しいコンテンツを生成する。こうした基盤モデルは、タスク特化の微調整が最小限か全く無くても、幅広いタスクに汎化できる。LLMは生成AIの人気ある一部分であり、専門家レベルの集中治療試験問題で既に超人的な成績を示している。集中治療医学での他の応用先として、医学教育・研究・事務支援が挙げられている。

規制のパラドックス。一部の臨床的な生成AI応用は、現行の規制監督をすり抜けている。その結果、「最も臨床的にテストされたアルゴリズムが研究から現実へ進まない一方で、最もテストされていないものが患者の近くで目立つ」というパラドックスが生じている。LLMベースのチャットボットが遍在的に利用可能になったことで、医療専門職が診断・治療の示唆を求めて頻繁かつ非規制のまま使う状況が事実上生まれている。

アンビエントAIスクライプ。外来領域には既に大規模に入り込み、診療記録と医師-患者間のやり取りを作り変えつつある。集中治療医学でも、たとえば家族との会話の記録に使える可能性がある。ただし回診や多職種カンファレンスといった領域をカバーするには、技術的・ロジスティックな障壁をまだ越えられていない。

次の地平＝エージェント型臨床AI。自律的・目標志向のシステムで、専門化された複数のモデルが協調して「デジタルの同僚」として働くマルチエージェント方式を特徴とする。集中治療医学ではまだ実装されていないが、そうしたシステムは患者を継続的に監視し、悪化の傾向を提示し、人工呼吸器の調整を推奨し、薬剤安全性を改善し、日々の回診サマリーを準備しうる。著者らは、これが我々の働き方を根本的に作り変え、安全性を高め、臨床医の負担を減らし、ケアの継続性を改善する可能性が高いと述べる。

7. 第3の波 — オンライン強化学習+ベッドサイドの適応的ランダム化

最初の2つの波は既に来ている。しかし著者らは、いまはせいぜい「岸から遠い小さなさざ波」である第3の波を構想する。医療ではまだ試みられていないが、理論的には可能な応用群である。分かりやすい例としては、音声・動画・センサーを含むマルチモーダル入力を活用し、多数のAIエージェントのオーケストラで統率される完全ク

ローズドループのシステムが挙げられる。だが著者らのお気に入り、AIと従来型RCTの分断を橋渡しすることである。

背景にある問題。現代の集中治療医学は、不確実性下で下さねばならない膨大な数のケア判断を含み、その多くは一方の選択が他方より良いという信頼できるエビデンスをほとんど持たない。

アプローチ	強み	弱み
RCT	強い因果的エビデンスを提供する	狭く定義された意思決定の平均治療効果に限られる。遅く実施が難しく、得られるエビデンスは現代のICUが直面する意思決定全体のごく一部にしか対応しない
実世界データのAI解析	RCTと比べて速く安価	交絡に悩まされ、因果性の証明が不十分。ある決定に伴う行動が、その後の転帰の原因であるという保証をほとんど与えない

そこで著者らは問う。「両方の良いところを取れるとしたら？」

構想の中身は3段階である。

段階	システムの挙動	得られるもの
A. モデルが十分に確信できるとき	治療を推奨する	エビデンスに基づくケアの機会損失を減らす
B. 不確実性が大きすぎるとき	妥当な選択肢の間で推奨をランダム化する(学ぶ機会として)	ランダム化が保たれるため因果的に厳密なデータが生まれる
C. 常時	患者転帰を観察し、方針(policy)を継続的に更新する	ケアが継続学習システムになる — 実世界的・個別化・適応的、かつ因果的に厳密

現行のRLモデルは極めて有望だが、これまで後ろ向きデータを用いたオフライン設定でしか評価されておらず、目に見える臨床的インパクトをまだ生んでいない。この「オフラインの壁」を越える鍵が、ベッドサイドでの適応的ランダム化の埋め込みである。

既存の適応試験との関係。このアプローチはベイズ適応プラットフォーム試験の自然な延長である。適応プラットフォーム試験は既に、多腕バンディットとして知られる粗い強化学習モデルのアナログ版に似ている。第3の波の構想は、適応プラットフォームのプロセス全体を本質的にデジタル化し、ケア提供と融合させる。エビデンスが明確なところでは強い推奨を提供し、現在の知識が欠けているところでだけ学ぶ機会を作る。

図の解説

Figure 1. 集中治療におけるAIの第3の波 — 継続学習のための統合エコシステム。原図・無改変。横長の1枚図で、左・中央・右の3つのパネルが左右から中央へ矢印で合流する構成。左パネル「Traditional RCTs」には天秤(片方の皿に薬剤ボトル、もう片方に「VALIDITY」の分銅)と、緩やかに上昇する矢印のグラフが描かれ、下に「High causal validity but slow, narrow, and expensive」(因果的妥当性は高いが、遅く・狭く・高コスト)。右パネル「Offline AI & Real-World Data」にはデータベースの積層シリンダーと稲妻付きクラウド、そして疑問符・感嘆符が飛び交うモニタ画面に赤い×印が重なった図があり、下に「Fast and cheap, but plagued by confounding」(速く安価だが、交絡に悩まされる)。中央パネル「Online reinforcement learning with bedside adaptive randomization」は、ICUベッドに横たわる患者とモニタを中心に、時計回りの円環矢印で3つのカードが結ばれる。カードA「Model certainty → Recommend optimal treatment」(チェック印と脳のアイコン)、カードB「Model uncertainty → Adaptive Randomization」(疑問符と分岐する矢印)、カードC「Continuous Policy Update」(歯車と上昇するグラフ)。左右のパネルからはネットワーク状のノード図を介して中央へ矢印が入り、両者の長所が中央の継続学習ループに統合されることを示す。図はキャプションのとおり、エビデンスがある場所では明確な治療推奨を提供し、不確実性が残る場所では妥当な選択肢の間で安全にランダム化する系を表現している。なお本図は著者らが生成AIで作成したと明記されている。

8. リスクと必要な安全装置

著者らは構想を提示したうえで、同じ段落内で明示的にリスクを列挙している。過度に楽観的な提言に見えないよう、原文の慎重さのまま記す。

リスク	内容
入力データの誤り	誤ったデータがそのまま方針更新に流れ込む
入力データの意図的な操作	悪意ある改変 (deliberately manipulated input data)
スケーリングの困難	系を大規模に展開すること自体の難しさ
同一患者への複数モデルの同時実行	一人の患者に対して複数の学習モデルを並行して走らせる際の相互干渉

これらの限界があるため、厳格な監督 (rigorous oversight)、検証 (validation)、悪用に対する安全装置 (safeguards against misuse) が不可欠である、と結論づけている。

9. 結論部 — EBMの新しいモデル

言い換えれば、適切に実装された理想的な第3の波は、臨床ケアとランダム化試験と実世界エビデンスを再統合する、EBMの新しいモデルを事実上意味する。それは知識を最も速く、かつ安全に獲得する方法を保証する。そして、我々が知る集中治療医学の実践にとっての革命となる。

10. 批判的吟味(JCでの論点)

論点	内容
そもそもエビデンスの階層が違う	本稿はオピニオンであり、新規データを一切含まない。主張の検証可能性は引用文献に依存する。JCで扱う際は「提言として読み、実装可能性を我々が評価する」という前提を最初に共有すべき
「不確実なときにランダム化する」の閾値が未定義	何をもって「十分に確信がある(certain enough)」とするのか、何が「妥当な選択肢(reasonable options)」なのかは本稿では定義されない。この2つこそが臨床導入の可否を決める設計パラメータであり、最も難しい部分が空欄のまま残されている
同意の設計が語られていない	診療の中で自動的にランダム化が発動する系は、患者・家族への説明と同意をどう設計するかが最大の障壁になる。本稿は倫理的側面をリスク列举の1行(rigorous oversight)に圧縮しており、具体論は無い
規制の枠組みとの不整合	現行の医療機器プログラム規制は「承認時点の性能」を保証する設計である。継続的に方針を更新する系は、承認のたびにモデルが別物になる。著者らはこのミスマッチを指摘していない
報酬関数(reward)の設計問題が触れられていない	RLは報酬を最大化する。何を報酬に置くか(28日死亡か、臓器不全日数か、退院時ADLか)で学習される方針が変わる。集中治療の目標が単一指標に還元できない以上、これは技術ではなく価値判断の問題であり、本稿では言及されない
利益相反の濃さ	責任著者はICU向けAI企業からのロイヤリティと複数の医療機器メーカーからのコンサルタント料を、共著者はAI健康解析企業のアドバイザリーボード報酬を開示している。提言の方向とCOIの方向が一致している点は、読者として意識しておくべき
第1の波の総括が例示的	「敗血症アラートは業務量を増やしただけ」「サブフェノタイプは治療を変えていない」という総括は、それぞれ引用1本ずつに依拠している。分野全体の失敗の総括としては根拠が薄い
生成AI使用の自己言及	本文と図の作成に生成AIを使ったと開示している点は誠実だが、図の内容の正確性の担保は著者に残る。図はコンセプト図でありデータを含まないため実害は無いが、原理として押さえておきたい

11. 主要な引用文献一覧

#	内容	出典
1	集中治療医学へのAI実装:22名によるコンセンサス	Cecconi M, Greco M, Shickel B et al. Crit Care 2025;29:290
2	公開されているICUデータセットのシステムティックレビュー	Jagesar AR, Dam TA, Struja T et al. J Crit Care 2025;90:155205
3	ICUにおけるAI応用の実運用化:システムティックレビュー	Berkhout WEM, van Wijngaarden JJ, Workum JD et al. JAMA Netw Open 2025;8:e2522866
4	集中治療医学における機械学習:離陸の準備はできたか	Fleuren LM, Thorat P, Shillan D et al. Intensive Care Med 2020;46:1486-1488
5	広く実装された商用敗血症予測モデルの外部検証(アラートの限界の根拠)	Wong A, Otles E, Donnelly JP et al. JAMA Intern Med 2021;181:1065-1070
6	成人集中治療におけるAIとコンピュータ化意思決定支援:RCTのシステムティックレビュー	Muñoz J, Fernández-Araujo NJ, Ruíz-Cacho R, Muñoz-Visedo J. J Crit Care 2026;94:155600
7	重症医療におけるAI:未来へのロードマップ(AIレディネス段階論の出典)	Workum JD, Meyfroidt G, Bakker J et al. J Crit Care 2025;91:155262
8	LLMの専門家レベル重症医療問題での比較評価・ベンチマーク研究	Workum JD, Volkers BWS, van de Sande D et al. Crit Care 2025;29:72
9	アンビエントAIスクライプを多様な医療環境へ拡大する際の障壁と機会	Ohde JW, Thompson A, Liu Z et al. NPJ Dig Med 2026;1-8
10	臨床試験と診療の統合:分断された家を修復する	Angus DC, Huang AJ, Lewis RJ et al. JAMA 2024;332:153-162
11	重症患者のケアを改善する5つの大きなアイデア	Angus DC. JAMA 2026;335:e260506
12	AI・健康・医療の今日と明日:AIに関するJAMAサミット報告	Angus DC, Khera R, Lieu T et al. JAMA 2025;334:1650-1664
13	AI Clinician:敗血症の最適治療戦略を学ぶ(ICU向けRLの代表的原典)	Komorowski M, Celi LA, Badawi O et al. Nat Med 2018;24:1716-1720

#	内容	出典
14	敗血症性ショックにおけるバソプレシン開始の最適化:OVISS強化学習研究	Kalimouttou A, Kennedy JN, Feng J et al. JAMA 2025;333:1688-1698
15	強化学習は重症患者の転帰を改善するか: システマティックレビューとレディネス評価	Otten M, Jagesar AR, Dam TA et al. Crit Care Med 2024;52:e79-e88

✓ Take home message

TAKE HOME

結論 集中治療AIの本命は予測モデルでも文章生成でもなく、「**確信があれば推奨し、不確実なら妥当な選択肢の間でランダム化して学ぶ**」オンライン強化学習を診療そのものに埋め込むことである。後ろ向きデータだけで学習したRLは、適応による交絡・分布シフト・価値の過大評価という原理的な壁を越えられない。**壁を壊す道具はランダム化であり、それは既にベイズ適応プラットフォーム試験として我々の手元にある。**明日の診療は変わらない。だが当院で変えられることが1つある。**バイタル自動収集とRRSの記録を「アラートの精度」ではなく「いつ・誰が・どの選択肢を選び・その後どうなったか」が残る形に設計し直すこと。**この記録が無い施設は、第3の波が来ても参加できない。

本ページは原論文の要約・解説です。数値は原論文から転記していますが、引用の際は必ず原論文(上記DOI)をご確認ください。原著の図表は著作権のため本ページには掲載していません(本文の「図の解説」を参照)。作成: Claude Code(聖路加ICUジャーナルクラブ運用)。