

ECMOについての家族の質問に4つのLLMはどう答えたか — 満足できる回答はGemini 95%対DeepSeek 61% (Correspondence・CritCare2026)

出典 Vankrunkelsven W, Vercaemst L, Dauwe DF. Critical Care. 2026;30:323.
doi:10.1186/s13054-026-06137-z

掲載誌 Critical Care (2026)

原著 doi.org/10.1186/s13054-026-06137-z (本文PDFは別途)

原題 Performance of four large language models in addressing family-centered questions on morbidity and outcomes in patients supported by extracorporeal membrane oxygenation

 **共有ページ** (誰でもログイン不要): [クリックで開く] (<https://hiro-oka.github.io/jc-summaries/s13054-026-06137-z.html>)

<https://hiro-oka.github.io/jc-summaries/s13054-026-06137-z.html>

 PDF: [開く / ダウンロード] (<https://hiro-oka.github.io/jc-summaries/s13054-026-06137-z.pdf>)



聖路加ICUでの実践への示唆

聖路加ICUでの実践

家族面談への落とし込み ① **家族はすでにAIに聞いている、という前提で面談を始める。**本研究の出発点は「ECMOのメディア報道は生存と良好な転帰を不釣り合いに強調する」(Fernando ら、JAMA Intern Med 2021)という先行知見で、著者らは「LLMも同じく楽観に偏るのか」を検証した。答えは**偏っていなかった**。LLMの回答はメディアの描写より均衡が取れ、方向としてエビデンスと一致していた。

② **ただし「使える」と「任せられる」は別。**ECMO専門家6名の評価で、内容の質が満足(5段階で4以上)とされた割合は **Gemini 95%・ChatGPT 80%・Claude 71%・DeepSeek 61%。最良のモデルでも20回に1回は専門家が不満足と判断する回答を返しており、家族の意思決定に直結する説明を任せられる水準ではない。**

③ **LLMが最も弱いのは「網羅性」と「共感」**(著者が名指しする2つ)。面談で臨床医が担うべきはまさにこの2つ。抜けている論点を埋めることと、感情に応答すること。数字の説明はLLMでもそれなりにできる。

④ **数字のズレの型を覚えておく。**ELSOレジストリ(2020-2024)との比較で、LLMは **VV-ECMO期間を短く**(実測19.6日に対し7~14日)、**合併症率を高く**(血管損傷は実測 約1~5% に対し 5~30%)答える傾向があった。家族が「1週間くらいと聞いた」「合併症は3割と聞いた」と言ってきたら、この由来を疑う。

⑤ **ただしレジストリが常に正しいわけではない。**著者は「VV-ECMO期間についてはLLMのほうが現在の実態を反映しているかもしれない」と留保する。ELSOの平均はCOVID-19期の長期支持症例で押し上げられている可能性があるため。当院の説明でも「ELSOの平均は流行期を含む数字です」と添えられる。

⑥ **PICSに言及したのは DeepSeek 以外の3モデル。**身体・精神・認知の各領域の障害を、報告された発生率とともに現行文献に沿って述べていた。家族への説明で「助かった後の話」をLLMが先に伝えている可能性がある。

⑦ **全モデルが「個別の情報は医療者に相談を」という免責を付けていた。**これは面談の入口として使える。「AIで調べられましたか。AIも最後は主治医に聞いてくださいと書いていたはずです」。

⑧ **当院での位置づけは著者の結論そのまま。**LLMは情報共有プロセスの **補助(adjunct)** として使えるが、**代替(substitute)** にはならない。



この論文の位置づけ (Known / Unknown / What's new)

補足

リサーチ・イン・コンテキスト

- **Known (既に分かっていたこと)**: ECMOの使用は指数関数的に増加し、COVID-19パンデミック期に呼吸ECMOがピークに達した。患者と家族は医療情報を一般向けメディア・インターネット、そして最近LLMから集めている。Fernando ら (JAMA Intern Med 2021) は、ECMOに関するメディア報道が生存と良好な転帰を不釣り合いに強調し、大規模コホート研究やRCTのデータから乖離していることを示した。
- **Unknown (分かっていなかったこと)**: LLMもまた、ECMOの転帰について過度に楽観的な見方を提供するのか。そして、家族が実際に尋ねそうな質問に対して、LLMの回答は内容としてどれだけ正確・網羅的・均衡が取れていて、コミュニケーションとしてどれだけ読みやすく・共感的で・適切なのか。
- **What's new (本Correspondenceが示したこと)**: Google Trends とGoogleのよくある質問、およびLLM自身が生成した「家族がよく聞く質問」から4問を選定し、**ChatGPT-4o・DeepSeek-V3・Gemini-2.0 Flash・Claude-3.7 Sonnet** に投げ、ELSOレジストリ(2020-2024)・総説3本、およびECMO専門家6名の7領域評価と突き合わせた。結論は「LLMの回答はメディアの描写より均衡が取れ、方向としてエビデンスと一致していた。しかし相当数の回答が専門家に不満足と評価され、とくに網羅性と共感で低かった」。**モデル間の差が大きい**(満足できる内容の割合が95%から61%まで)ことも重要な所見。
- **位置づけの注意**: Correspondence であり、**4問×4モデル=16回答が全データ**である。仮説生成的な報告であって、モデルの優劣を確定する研究ではない。

全体要約

要旨

ひとことで ECMOについて家族が尋ねそうな4問を4つのLLMに投げ、ELSOレジストリとECMO専門家6名で評価した Correspondence。LLMはメディア報道と違って楽観に偏っておらず、方向としてはエビデンスと一致していた。しかし専門家が「満足できる」とした回答の割合は **Gemini 95% から DeepSeek 61%** まで大きく開き、とくに **網羅性と共感** が低かった。**補助として使えるが代替にはならない。**

- 評価した4モデル(実名・バージョン): ChatGPT-4o / DeepSeek-V3 / Gemini-2.0 Flash / Claude-3.7 Sonnet
- 評価時期・条件: 2025年5月4~11日、無料版・既定設定。全質問を各LLMにつき同一チャットセッション内で1回ずつ照会
- 質問セット: 家族が尋ねそうな4問。生存率・ECMO期間・合併症・退院後のQOL
- 比較対象: ELSOレジストリ国際サマリー報告(2020-2024のデータ) と総説3本
- 評価者: ECMO専門家6名。7領域(内容の質=正確性・網羅性・均衡・関連性 / 専門家が知覚するコミュニケーションの質=読みやすさ・共感・適切性)を5段階リッカート尺度で採点
- 定性的所見: 全LLMがECMOの高リスクな性質を認め、VV-ECMO・VA-ECMO・ECPR を自発的に区別した。生存率とECMO期間は概ねELSOと整合したが、LLMはVV-ECMO支持期間を短く報告
- 総合性能はLLM間で有意差あり($p<0.001$)。Gemini が内容・コミュニケーションの両方で最高平均、DeepSeek が一貫して最低
- 満足できる回答(4/5「同意」または5/5「強く同意」)の割合
- 内容の質: Gemini **95%** > ChatGPT **80%** > Claude **71%** > DeepSeek **61%** ($p<0.001$)
- コミュニケーションの質: Gemini **81%** > Claude **68%** > ChatGPT **63%** > DeepSeek **58%** ($p=0.027$)
- 評価者間一致: 平均一致率 **74.2±1.3%**、全体の **Kappa 0.35±0.02(fair)**。コミュニケーションの質のほうが内容の質より一致が高かった
- PICSへの言及: DeepSeek 以外の3モデルが身体・精神・認知領域のPICS関連障害に言及し、発生率も現行文献と整合
- 免責: 全モデルが「個別化された情報は医療者に相談を」という明示的な免責を提供

- **著者の結論**: LLMは情報共有プロセスの **補助(adjuncts)** として使えるが、**代替(substitutes)** にはならない

詳細

1. まず前提 — ECMOとLLMの基礎(初めての人にも)🧩

要旨

①-A ECMOとELSO(原著の前提。ここは論文の記述に対応する) **ECMO(extracorporeal membrane oxygenation:体外式膜型人工肺)** は、重症患者に一時的な呼吸および/または心臓の補助を提供する救命的治療。3つの使い方がある。

- **VV-ECMO(venovenous)**: 静脈から脱血し静脈へ返す。**肺の代わり**(重症ARDSなど)
- **VA-ECMO(venoarterial)**: 静脈から脱血し動脈へ返す。**心臓と肺の代わり**(心原性ショックなど)
- **ECPR(extracorporeal cardiopulmonary resuscitation)**: 心停止中にVA-ECMOを導入する蘇生法

ELSO(Extracorporeal Life Support Organization) は国際的なECMOレジストリを運営する組織で、世界のECMO転帰の事実上の基準データを提供する。本研究は **2020~2024年のELSO国際サマリー報告**を参照基準として使った。**PICS(post-intensive care syndrome)** は集中治療後症候群で、身体・精神・認知の3領域の障害を指す。

要旨

①-B LLMの仕組みと「医療での評価枠組み」(本論文には書かれていない一般的な背景知識) **ここから下は原著の記述ではない**。Correspondence の本文はLLMの原理に一切踏み込んでいないため、初学者が結果を解釈できるように一般知識で補う。**論文の主張と混ぜて読まないこと**。

LLM (large language model: 大規模言語モデル)とは。膨大なテキストで学習し、「次に来る語」を確率的に予測して文を生成するモデル。**事実データベースを検索しているのではない**。学習したテキストの統計的パターンから「もっともらしい続き」を組み立てている。したがって、

- **出力は確率的 (stochastic)**。同じ質問でも回答は毎回変わりうる。1回の照会は「そのモデルの実力」ではなく「その1回の出力」の観測にすぎない
- **ハルシネーション (hallucination)** が起きる。もっともらしいが事実でない内容を、自信のある口調で生成する現象。存在しない文献・DOI・数値を作ることが知られる。仕組み上、「知らない」と答えるより「もっともらしく埋める」ほうが自然な挙動になる
- **学習データにはカットオフがあり、バージョンで挙動が変わる**。無料版と有料版で基盤モデルや推論設定が異なることもある

医療における生成AI評価の標準的な枠組み。一般に次の軸で測る。

- **正確性 (accuracy)** : 事実として正しいか
- **完全性・網羅性 (completeness)** : 意思決定に必要な論点が抜けていないか
- **安全性・均衡 (safety / balance)** : 害を過小にも過大にも述べていないか、判断を一方向に誘導していないか
- **可読性 (readability)** : 読み手の読解力で読めるか。**Flesch-Kincaid Grade Level**、SMOG、Flesch Reading Ease などの自動指標があり、患者向け資材は米国では6~8年生レベルが目安とされる
- **共感 (empathy)** : 感情への応答があるか

本論文はこの枠組みのうち7領域を採用した(正確性・網羅性・均衡・関連性／読みやすさ・共感・適切性)。ただし可読性は専門家のリッカート採点であり、**Flesch-Kincaid** などの自動可読性指標は本論文では一切算出されていない(本文・Table 1 のいずれにも記載がない)。

Kappa (κ) 係数は評価者間一致度の指標。Landis & Koch の慣用的な解釈は、0.21–0.40 が **fair (それなり)**、0.41–0.60 が moderate、0.61–0.80 が substantial。本研究の 0.35 は fair にあたる。

2. 背景と目的

ECMOの使用は指数関数的に増加し、**COVID-19パンデミック期に呼吸ECMOがピークに達した**。使用の拡大に伴い、患者と家族から、適応・リスク・期待される転帰に関する**アクセス可能で正確な医療情報への需要が増える**ことが予想される。

患者と家族はしばしば、公開されているメディア・インターネット、そして最近はLLMから医療情報を集める。**Fernando** らは以前、ECMOのメディア報道が生存と良好な転帰を不釣り合いに強調しており、大規模コホート研究やランダム化試験のデータから乖離していることを示した。

この所見に触発され、著者らは、成人ECMO患者の罹病と転帰に関する患者・家族中心の質問に答える際の、よく使われる4つのLLMの全体的な性能を調査した。**とくに関心があったのは、LLMもまたECMO転帰について過度に楽観的な見方を提供するのかどうか**である。

3. 方法(Methods)

■ デザイン

- 横断的なベンチマーク評価。患者を組み入れないため倫理承認は不要とされた
- 区分は **Correspondence**。事前登録・プロトコル公開の記載はない

■ 質問セットの作り方(4問)

① **Google Trends** により、ECMO が主要な検索語であり、VA-ECMO・VV-ECMO という語の使用は限定的であることを同定した。著者はこれを「大半の家族がこの区別を認識していないことの反映」と解釈している

② 候補の質問を**3つのソース**から編纂した

- ECMO関連のGoogleよくある質問 上位20
- Google Trends で同定されたECMO関連検索語 上位25
- 4つのLLM(ChatGPT-4o、DeepSeek-V3、Gemini-2.0 Flash、Claude-3.7 Sonnet)が生成した「家族が最もよく聞くECMOの質問」

① **全著者が合意**のうえ、典型的な家族の懸念を最もよく反映すると判断した**4問**を採用した(Table 1 に全文が掲載されている)

■ 照会の条件

- 対象: ChatGPT-4o / DeepSeek-V3 / Gemini-2.0 Flash / Claude-3.7 Sonnet
- 時期: 2025年5月4~11日(1週間)

- 設定: 無料版 (free versions)・既定設定 (default settings)
- 回数: 各LLMにつき1問1回。かつ4問すべてを同一の「チャット」セッション内で順次照会した

■ 比較対象 (参照基準)

- ELSOレジストリ国際サマリー報告 (2024年までのデータ、2025年公表)
- QOLについてはELSOに比較対象が存在しないため、総説3本 (Kalra 2024 Neurology/Turgeon 2024 ICM/Higa 2023 CCM) を参照した

■ 専門家による採点

- 採点者: ECMO専門家6名
- 枠組み: 7領域
- 内容の質 (content quality): 正確性 (accuracy) / 網羅性 (completeness) / 均衡 (balance) / 関連性 (relevance) = 4領域
- 専門家が知覚するコミュニケーションの質 (expert-perceived communicative quality): 読みやすさ (readability) / 共感 (empathy) / 適切性 (appropriateness) = 3領域
- 尺度: 各領域を5段階リッカート尺度 (本文で明示されているのは 4/5=agree、5/5=strongly agree)
- 「満足できる回答 (satisfactory)」の定義: 4/5「同意」または5/5「強く同意」

△ 注意

Correspondence ゆえに方法の記述が薄い — 3点が本文から確認できない ① 盲検化の有無が一切書かれていない。採点者がどのモデルの回答かを知らされていたか (モデル名を伏せたか、提示順を無作為化したか) は本文に記載がない。ブランド名が見える状態での採点なら、モデルへの先入観がそのままスコアに乗る。② 統計手法が名指しされていない。「有意に異なった ($p<0.001$)」「 $p=0.027$ 」と書かれるだけで、どの検定を使ったかが本文にない。多重比較の補正の有無も不明。③ 満足割合の分母が定義されていない。「the proportion of questions that yielded a satisfactory response」と書かれるが、質問は4つしかないので 95% という値は質問数を分母にした割合ではありえない (6名×4領域×4問=96採点などが分母と推定されるが本文に明示がない)。いずれも補足資料を読まないで検証できず、本文だけで「Gemini 95%」を引用するのは危うい。

4. 結果① 定性的所見と ELSO との突き合わせ

■ 全モデルに共通して良かった点

- すべてのLLMがECMOの高リスクな性質を認めた

- すべてのLLMが VV-ECMO・VA-ECMO・ECPR を自発的に (independently) 区別した — 家族がこの区別を知らずに質問しているにもかかわらず
- 生存率とECMO期間は概ねELSOレジストリデータと整合した
- すべてのLLMが最も頻度の高い合併症を同定した
- すべてのLLMが「個別化された情報は医療者に相談を」という明示的な免責を提供した

■ ズレた点

- LLMは VV-ECMO の支持期間をより短く報告した
- 一部の合併症率でELSOレジストリとの乖離が観察された
- QOLについては、DeepSeek を除くすべてのLLMが身体・精神・認知の各領域におけるPICS関連の障害に言及し、報告された発生率も現行文献と整合していた(=DeepSeek だけがPICSに触れなかった)

図の解説

著者は「LLMが間違っている」とは書いていない VV-ECMO期間の乖離について著者は「興味深いことに、これは現在のVV-ECMO支持期間をより代表しており、家族により代表的な絵を与えるかもしれない」と述べる。理由は、ELSOレジストリの平均期間が、サンプル期間にCOVID-19パンデミックを含むことで押し上げられている可能性があるため(呼吸ECMO症例の急増と長期支持を特徴とした期間)。合併症率の不一致についても、「これらの差はLLMとELSOが異なるデータセットと定義をサンプリングしていることを反映している可能性が高く、どちらも家族に伝えるべき真実であると単純には言えない」と述べている。「AIの答えが正解と違う」という評価枠組み自体が、正解の存在を前提にしている — この論文はその前提を自ら問い直している点で誠実である。

図の解説

Table 1. LLMの主要な回答とELSOデータベースとの比較(原表・無改変。©Vankrunkelsven et al. Crit Care 2026, CC BY-NC-ND 4.0) 横軸は左から **ELSO (2020-2024)** → **ChatGPT** → **Deepseek** → **Gemini** → **Claude** の5列。縦軸は4つの質問がイタリック体の見出し行で区切られ、その下に項目がぶら下がる構造。**NR (Not reported) = そのモデルが答えなかった項目**で、Gemini と Claude の NR が目立つ(生存率の内訳・ECPR期間)。合併症の行だけELSO列が **VV/VA (CS) /VA (ECPR)** の3列にさらに割れており、この帯だけ表が横に広がって見える。最下段の質問4だけは数値がなく「Long-term quality-of-life: Data in Supplement」の一行で終わる。**表全体で数値が埋まっているのはELSO列だけで、右へ行くほど空白(NR)が増える** — これが視覚的に「LLMは網羅性が低い」という結論を先に語っている。

Table 1 (原表を日本語化)

質問1:「成人の家族が入院しECMOで支持されています。生存の見込みはどれくらいですか？」

生存	ELSO (2020–2024)	ChatGPT	DeepSeek	Gemini	Claude
全体	52%	40–60%	記載なし	50–60%	40–70%
呼吸	59%	50–60%	45%	記載なし	記載なし
心臓	50%	30–50%	50%	記載なし	記載なし
ECPR	32%	20–40%	43%	記載なし	記載なし

質問2:「通常、どのくらいの期間ECMOで支持されるのですか？」

ECMO期間	ELSO (2020–2024)	ChatGPT	DeepSeek	Gemini	Claude
VV-ECMO	19.6日(470時間)	10–14日	10–14日	7–10日	7–14日
VA-ECMO (心原性ショック)	6.7日(161時間)	5–10日	5–10日	6–8日	5–7日
VA-ECMO (ECPR)	4.7日(112時間)	7日未満	3–7日	記載なし	記載なし

質問3:「ECMO支持中にどんな合併症が起こりえて、どのくらいの頻度で起こりますか？」

合併症	ELSO VV	ELSO VA(CS)	ELSO VA(ECPR)	ChatGPT	DeepSeek	Gemini	CI
出血	約22%	約33%	約25%	30-60%	20-50%	30-60%	30-40%
神経学的損傷	約8%	約10%	約23%	10-20%	5-15%	10-30%	10-20%
血管損傷(下肢虚血を含む)	約1%	約4%	約5%	5-15%	15-30%	10-30%	10-20%

質問4:「ECMO支持後の退院後にはどのようなQOLが期待できますか？」→ 数値は補足資料

原表の注記:ELSOデータベースで報告された合計合併症率の概算。詳細は補足資料参照。

この表で最も目を引くのは「血管損傷」の行。ELSOでは 約1～5% なのに対し、LLMは 5～30% (DeepSeek は 15-30%)と報告している。桁が違う。逆に VV-ECMO期間はELSO 19.6日に対しLLMは 7～14日と半分程度に短く答えている。

図の解説

ハルシネーションの具体例は本論文に「載っていない」本文にも Table 1 にも、存在しない文献の捏造・明白な事実誤り・危険な助言といったハルシネーションの実例は一つも提示されていない。報告されているのは Table 1 の数値のズレと、専門家スコアの分布だけである。「LLMがどう間違えたか」の質的な記述は補足資料に委ねられており、本文からは取り出せない。ハルシネーションの具体例を期待して読むと空振りする論文である、という点は正確に押さえておく。

5. 結果② 専門家6名による定量評価 🎯

7領域を通じた各LLMの総合性能は有意に異なった(p<0.001)。

- Gemini が内容の質・専門家が知覚するコミュニケーションの質の両方で最高の平均スコア
- DeepSeek が一貫して最下位

しかし著者が「重要である」と強調するのは平均点ではなく、満足できる回答(4/5「同意」または5/5「強く同意」)を生んだ割合である。

LLM	内容の質が満足	コミュニケーションの質が満足
Gemini-2.0 Flash	95%	81%
ChatGPT-4o	80%	63%
Claude-3.7 Sonnet	71%	68%
DeepSeek-V3	61%	58%
P値	<0.001	0.027

順位が入れ替わる点に注意。内容の質では ChatGPT(80%)が Claude(71%)を上回るが、コミュニケーションの質では Claude(68%)が ChatGPT(63%)を上回る。内容が良いモデルが伝え方も良いとは限らない。

裏返しの数字(本文に明記はないが、上表から自明な補数):内容として不満足と判定された割合は Gemini 5%・ChatGPT 20%・Claude 29%・DeepSeek 39%。

評価者間の一致:6名のECMO専門家の平均一致率は 74.2±1.3%、全体の Kappa は 0.35±0.02 で、fair(それなり)の一致にとどまった。評価者間一致は、内容の質よりコミュニケーションの質のほうが高かった(内訳は補足資料)。

平均可読性スコア(Flesch-Kincaid など)は算出されていない。可読性はあくまで専門家による5段階の主観採点である。

6. 限界(著者が自ら記載したもの)⚠

- ① 主要な限界は、4問すべてを単一のチャットセッション内で順次照会したこと。これは内部の一貫性と免責の挙動を人工的に高めうる。このアプローチは、1つの会話内での追加質問を含む典型的なユーザーの相互作用を反映するために選ばれた。事後の感度分析として各質問に独立した「新規(fresh)」チャットセッションを用いたところ、臨床的内容と免責のパターンは同等だった
- ② 2025年5月の1週間にわたって無料版を評価したため、結果は急速に進化する分野における単一のスナップショットにすぎない。著者は「これらのLLMは出版時点で後継モデルに置き換えられているだろう」と明記し、所見は安定したモデルのランキングではなく、評価された期間内のLLMの能力を反映すると述べている

7. 結論(著者の言葉)

> 要約すると、評価されたLLMは、利用可能なエビデンスと方向として一致する回答を提供し、メディアの描写より均衡の取れた見方を提供した。>> 内容の質と専門家が知覚するコミュニケーションの質はいずれもLLM間でばらついた。>> 相当数の回答がECMO専門家によって不満足と採点された。LLMは網羅性と専門家が知覚する共感において、より低い性能を示した。>> 臨床医は慎重であり続け、患者と家族に個別化されたエビデンスに基づく情報を提供すべきである。LLMは情報共有プロセスの補助として使えるが、代替としては使えない。

 判断の質・診断エラー・AI Home との整合

本Vaultには「AIの臨床応用」に関する既存の立場が  判断の質・診断エラー・AI Home に整理されている。本論文はそのどこに収まり、どこと食い違うか。

整合する点(Homeの既存整理を支持する)

Home の整理	本論文の所見	判定
§10 ③ 生成AI・LLM:現時点のLLMは(完全には)信頼できない。誤りが致命的になりにくい領域から入る	最良のGeminiでも内容の5%、DeepSeekでは39%が専門家に不満足と判定された	整合
§12 審査項目 #6 監督責任者:出力を誰が検証するか	著者の結論が「補助であって代替ではない」＝人間の検証を必須とする	整合
§10 ③:出力の質は入力のでき方で決まる(TCEPFT)	質問セットをGoogle Trends・FAQ・LLM生成の3ソースから構造化して作った	整合
§16 の姿勢:AIは「精度を上げる道具」ではなく文脈のなかで読む	著者自身が「ELSOとLLMのどちらも家族に伝えるべき真実とは単純に言えない」と参照基準の正当性を留保した	整合

食い違う点(Homeの枠組みに条件が付く)

① 「アルゴリズム＝一貫性の供給装置」という Home §4 の中核命題は、生成AIには当てはまらない。
Home §4 は「アルゴリズムの最大の利点は精度ではなく一貫性であり、それだけでノイズを消す」を背骨に据えている(Dawes の improper linear model、SICS 827例の医師 AUC 0.68 vs APACHE IV 0.83)。し

かしLLMは確率的生成器であり、同じ質問に同じ答えを返さない。本論文が「1問1回しか照会していない」ことを弱点として指摘できるのは、まさにLLMが一貫性を持たないからである。予測AI・重症度スコアには成り立つ「一貫性」論を、生成AIにそのまま拡張してはいけない。

②「誤りが致命的になりにくい領域(家族向けの平易な言い換え)から入る」という Home §10 ③の線引きは、本論文の対象では成立しない。Home は実用的な線引きとして「退院サマリー草案・家族向けの平易な言い換え」を低リスク側に置いていた。しかし本論文が扱った**家族への予後・合併症の説明は、治療継続やDNARの意思決定に直結する**。しかもLLMは**血管損傷を実測の5～10倍に見積もる方向の誤り**を示した。「家族向け」は低リスクの同義語ではない。

③ Home §12 の審査項目9項目に「バージョンと再評価周期」が抜けている。本論文は評価(2025年5月)から受理(2026年6月)まで約**13か月**を要し、著者自身が「出版時点で後継モデルに置き換えられている」と書いた。**院内AI審査は「導入時に評価した」だけでは足りず、モデル更新のたびに再評価する周期が要る**。

POINT

Homeへの反映案(Home自体は未編集。本人の判断で反映)

- 案①(§4):「一貫性はそれだけで効く」の直後に1行 —「ただし**生成AI(LLM)は確率的生成器であり、同一入力に同一出力を返さない**。§4 の一貫性論が当てはまるのは予測AI・スコアであって、生成AIは例外」
- 案②(§10 ③):「誤りが致命的になりにくい領域から入る」の但し書きとして —「**家族への予後・合併症説明は『家族向け』でも低リスク領域ではない**。意思決定に直結し、かつLLMは合併症率を実測の5～10倍に見積もる方向の誤りを示した(本論文 Table 1)」
- 案③(§12 の審査項目表): #10「バージョンと再評価周期」を追加 —「評価したモデル名・バージョン・評価年月を記録したか。**モデル更新時の再評価をいつ誰が行うか決まっているか**」
- 案④(関連ノート欄): Home 99行目の ECM0についての家族の質問に4つのLLMはどう答えたか - 満足できる回答はGemini 95%対DeepSeek 61%(専門家評価・CritCare2026) は、**本ノートのリネームにより解決先が変わっている**。(Correspondence・CritCare2026) に貼り替えが必要
- 案⑤(Known/Unknown/What's new): Unknown に1行 —「**LLMの回答を実際の家族が読んでどう感じるかは測られていない**。既存研究はすべて専門家評価である」

🔍 批判的吟味 — ジャーナルクラブでの論点

△ 注意

この結果の賞味期限は数か月 — モデルの序列を引用してはいけない 評価されたのは**2025年5月時点の無料版**(ChatGPT-4o、DeepSeek-V3、Gemini-2.0 Flash、Claude-3.7 Sonnet)で、**受理は2026年6月＝評価から約13か月後**。著者自身が「出版時点でこれらのLLMは後継モデルに置き換えられているだろう」と書いている。**LLMは評価時点のバージョンでしか測れず、数か月で結果が変わる。したがって「Gemini が最良、DeepSeek が最低」というランキングを引用してはならない**。この論文から持ち帰るべきは個別モデルの序列ではなく、①LLMは楽観に偏らなかった ②弱点は網羅性と共感 ③モデル間の差が大きい ④全モデルが免責を付けた という4つの構造的所見だけである。同じ設計で再測しても同じ順位は再現しない、という前提で読む。

△ 注意

「専門家の採点が高い」ことと「家族が理解し安心する」ことは別物 本研究が測ったのは **expert-perceived**(専門家が知覚する)読みやすさ・共感・適切性である。著者はこの接頭辞を一貫して付けており、その慎重さは正しい。しかし裏を返せば、**実際に不安の渦中にある家族がその回答を読んで理解できたか、安心したか、誤解しなかったかは、本研究では一切測られていない**。可読性の自動指標(Flesch-Kincaid 等)すら算出されていない。専門家が「共感的だ」と採点した文章が、家族にとって共感的である保証はどこにもない。これが本研究と臨床実装のあいだにある最大の隔たりであり、次の研究の中心課題である。

1. $n=4\text{問} \times 4\text{モデル}=16\text{回答}$ 。これが全データである。6名 $\times$ 7領域 $\times$ 16回答で採点数は稼いでいるが、**独立した質問は4つしかない**。「Gemini 95%」と「ChatGPT 80%」の差は、採点の数回分の違いでしかない可能性がある。しかも満足割合の分母が本文に定義されていない(→ §3 の warning)。

2. 「1回だけ照会」という設計が再現性を根本から損なう。本文は "All questions were queried once per LLM" と明記する。LLMの出力は確率的で、同じ質問でも回答は変わる。通常は複数照会して分散を見べきところで、本研究は**モデルの実力ではなく1回の出力**を評価している。§1-B で述べたとおり、これはLLMの性質に由来する構造的な弱点であり、設計の不備というよりこの分野の評価方法論がまだ確立していないことの表れでもある。

3. **Kappa 0.35 (fair)**は、評価そのものの信頼性が高くないことを意味する。ECMO専門家6名の一致度が fair にとどまるということは、「良い回答とは何か」について専門家の間でも合意がないということ。そしてコ

コミュニケーションの質のほうが内容の質より一致が高かったという所見はやや逆説的である(普通は事実の正誤のほうが合意しやすい)。これは「ECMOの正しい数字は何か」自体が専門家の間で割れていることを示唆する — 実際、著者もELSOとLLMの乖離について「どちらが真実とも単純に言えない」と述べている。

4. 盲検化・統計手法・多重比較の記載がない。モデル名を伏せたかどうかは書かれておらず、ブランドへの先入観がスコアに乗った可能性を排除できない。検定名も多重比較補正の有無も本文にない。

Correspondence という媒体の制約であって著者の怠慢ではないが、査読の効きが原著より弱いことは事実として扱う。

5. 「メディアより均衡が取れている」という比較対象の低さ。参照される Fernando ら(JAMA Intern Med 2021)は、メディア報道が不釣り合いに楽観的であることを示した研究である。「メディアよりまし」は臨床的に十分な水準を意味しない。実際、DeepSeek では39%、Claude では29%の回答が内容として不満足と判定されている。

6. 合併症率の乖離は「悲観方向の誤り」であり、本研究の結論とは別の問題を提起する。LLMは血管損傷をELSO の約1~5% に対し 5~30% と大幅に高く答えた。著者は「異なるデータセットと定義」と中立的に説明するが、別の解釈もありうる — 合併症を報告した研究ほど発表されやすい(報告バイアス)テキストで学習している可能性である。家族に過度の恐怖を与える方向の誤りであり、「楽観に偏っていない」という結論だけを持ち帰ると見落とす。

7. VV-ECMO期間についての著者の弁護は説得的だが検証されていない。「ELSOの平均がCOVID期で押し上げられている」という説明は疫学的にもっともらしいが、本研究ではCOVID期を除いたELSOデータとの比較を行っていない。LLMが偶然正しかったのか、正しい理由で正しかったのかは区別できない。

8. Google Trends を「家族の関心」の代理とする妥当性。検索行動は家族のものとは限らない(医療者・学生・メディア関係者も検索する)。ただし「VA-ECMO/VV-ECMOの語がほとんど使われていない」という所見自体は、当院の家族説明にとって示唆的である — **我々が区別している概念を、家族は区別していない。**

9. それでも本研究が実務的に価値を持つ理由。「家族がLLMに聞いている」という現実、データで向き合った最初期の報告のひとつである。結論は防御的でも扇動的でもなく、補助であって代替ではないという穏当なところに着地している。当院での応用は「LLMを禁じる」でも「LLMに任せる」でもなく、面談の冒頭で「AIで調べましたか」と聞き、そこで得た情報を出発点にすることだろう。



主要な引用文献


内容	出典
ELSOレジストリ国際サマリー報告 (2024年までのデータ・本研究の参 照基準)	Extracorporeal Life Support Organization (ELSO). 2025
ECMO転帰のメディア報道が生存と 良好な転帰を不釣り合いに強調する (本研究の着想源)	Fernando SM, Mathew R, Slutsky AS, Rochweg B, Kyeremanteng K, Combes A, Brodie D. *JAMA Intern Med* 2021;181(3):391–394
ECMO患者の長期の神経精神・神経 認知・機能的転帰 (SR・メタ解析・ HERALD)	Kalra A, Kang JK, Khanduja S, et al. *Neurology* 2024;102(3):e208081
ARDSに対するECMO患者の長期転 帰 (SR・メタ解析)	Turgeon J, Venkatamaran V, Englesakis M, Fan E. *Intensive Care Med* 2024;50(3):350–370
VA-ECMO後の身体・情動・認知回復 について臨床医が知るべきこと	Higa KC, Mayer K, Quinn C, et al. *Crit Care Med* 2023;51(9):1234–1245

✓ Take home message

TAKE HOME

結論

- Correspondence である。4問×4モデル=16回答が全データで、原著研究の水準の検証ではない
- LLM(ChatGPT-4o/DeepSeek-V3/Gemini-2.0 Flash/Claude-3.7 Sonnet)はメディア報道と違い、ECMO転帰について楽観に偏っていなかった
- 専門家が「満足」とした回答は Gemini 95%・ChatGPT 80%・Claude 71%・DeepSeek 61%($p<0.001$)。最良でも20回に1回、DeepSeek では5回に2回が不満足
- LLMが最も弱いのは網羅性と共感。面談で臨床医が担うべきはまさにこの2つ
- 数字のズレの型:VV-ECMO期間を短く(19.6日→7~14日)、合併症率を高く(血管損傷 約1~5%→5~30%)答える
- 評価者間 Kappa 0.35(fair)。「良い回答とは何か」で専門家自身が割れている
- 評価は2025年5月の無料版で、受理は13か月後。モデルの序列は引用しない。持ち帰るのは構造的所見だけ
- この結果を根拠に家族への説明をLLMに任せてよいわけではない。著者の結論は「補助(adjunct)であって代替(substitute)ではない」



本ページは原論文の要約・解説です。数値は原論文から転記していますが、引用の際は必ず原論文(上記DOI)をご確認ください。
原著の図表は著作権のため本ページには掲載していません(本文の「図の解説」を参照)。作成: Claude Code(聖路加ICUジャーナルクラブ運用)。