

メタ解析が食い違うとき — 統合推定値の先を読む

出典 Lakbar I, Poole D. Crit Care. 2026;30:387. DOI: 10.1186/s13054-026-06216-1

掲載誌 Critical Care (2026)

原著 doi.org/10.1186/s13054-026-06216-1 (本文PDFは別途)

原題 When meta-analyses disagree: looking beyond the pooled estimate

 **共有ページ** (誰でもログイン不要で閲覧・右上のコピーで1クリック)

<https://hiro-oka.github.io/jc-summaries/s13054-026-06216-1.html>

 PDF (クリックでダウンロード): <https://hiro-oka.github.io/jc-summaries/s13054-026-06216-1.pdf>



聖路加ICUでの実践への示唆

聖路加ICUでの実践

聖路加ICUでの実装 ① **メラトニンについての当面の運用** この論説を踏まえた合理的な立ち位置は「**低バイアスリスク試験に限れば RR 0.86 (0.70–1.05) で、ルーチンの予防投与を支える根拠は薄い**」である。せん妄予防の第一選択は引き続き非薬物的介入（早期離床・睡眠環境・見当識支援・PADISバンドル）に置く。個別に使う場合でも、シグナルが観察されているのは術後患者・3～5 mg/日・7日以上という条件であり、確信度は low であることを申し送りに明記する。

② **抄読会の型として使う** メタ解析を読む回では、統合推定値を読み上げて終わりにせず、次の3点を必ず確認する運用にする。

確認事項	見るべき場所
バイアスリスク層別の結果があるか。あるなら層間で結論が変わるか	フォレストプロットのサブグループ、Figure の付録
統合推定値を動かしている試験はどれか (leave-one-out)	感度解析、なければ重みの大きい試験と極端な試験を目で確認
最大かつ最も質の高い試験は何を示しているか	重み最大の行が縦線のどちら側にあるか

③ **院内プロトコル改訂の判断基準に落とす** 「メタ解析で有意だったから採用」という運びを避ける。プロトコル改訂を提案する側に、**低リスク試験に限った推定値**を必ず併記させる。両者が同じ向きなら採用の後押しになり、食い違うなら条件付き（対象を絞る・期間限定・効果測定を伴う）に留める。

④ **自分たちの研究に返す** JIPAD などのレジストリ研究や院内データの解析でも同型の問題が起きる。主解析と、除外基準を厳しくした解析の**両方を最初から出す設計**にし、食い違ったときは「主解析を採用」ではなく「不確実性が高い」と報告する。



この論文の位置づけ (Known / Unknown / What's new)

補足

リサーチ・イン・コンテキスト

- **Known (既に分かっていたこと)**: メタ解析は複数RCTを統合する最高水準のエビデンスとされ、ICUのせん妄予防にメラトニン作動薬を使うかを検討した複数のシステマティックレビューが存在した。
- **Unknown (分かっていなかったこと)**: 同じ臨床疑問に答えた2本の厳密なレビュー (Chaves らは肯定的、Lakbar らは推奨するには不十分) がなぜ逆の結論に達したのか、その食い違いの主因は明らかでなかった。
- **What's new (本研究の新規性・意義)**: 差の主因が「組み入れ基準 (臨床的異質性)」ではなく「バイアスリスクの高い試験を統合に入れるか (方法論的異質性)」であることを分解して示した。メラトニン試験を ROB-2 で層別し直すと高リスク RR 0.46 (0.29–0.73) / 低リスク RR 0.86 (0.70–1.05)、交互作用 $P=0.01$ で、見かけの効果は高バイアスリスク試験に偏在していた。食い違いそのものが所見であり、不確実性を上げる方向に読むべきだと主張する。



全体要約

要旨

ひとことで ICUのせん妄予防にメラトニン作動薬を使うか、という同じ問いに対して、2本の厳密なメタ解析が逆の結論に達した。著者らはどちらが正しいかを争うのではなく、なぜ食い違ったのかを分解し、**差の主因が「組み入れ基準の違い」ではなく「バイアスリスクの高い試験を統合に入れるかどうか」だったことを示した**。高リスク試験に限れば RR 0.46 (0.29–0.73)、低リスク試験に限れば RR 0.86 (0.70–1.05)、交互作用 $P=0.01$ 。**食い違いそのものが所見であり、不確実性を増やす方向に読むべきだ**という主張である。

内容	
問い	同じ臨床疑問に答えた2本のメタ解析が異なる結論に至ったのはなぜか
区分	Editorial(*Critical Care* 2026)。本文中に著者らによる post hoc 層別解析と leave-one-out 解析の結果を含む
素材	メラトニン作動薬によるICUせん妄予防。Chaves らのレビュー(肯定的)と Lakbar らのレビュー(推奨するには不十分)
差の第1候補	臨床的異質性=適格基準。Chaves はメラトニン+ラメルテオン、Lakbar はメラトニンのみ。ただし Chaves のメラトニン限定サブグループは RR 0.77(0.62–0.97)で Lakbar の RR 0.86(0.71–1.04)と大きく重なる。 これでは説明しきれない
差の主因	方法論的異質性=バイアスリスクの扱い。Chaves は全試験を統合、Lakbar は低リスク試験に限定した解析を主解析とした
決め手の数値	Chaves の含めたメラトニン試験を著者らが ROB-2 で層別 → 高リスク RR 0.46(0.29–0.73)／低リスク RR 0.86(0.70–1.05)／交互作用 $P=0.01$ 。低リスク層の推定値は Lakbar 自身の RR 0.89(0.73–1.09)とほぼ一致
leave-one-out	両データセットで一致。Yin と Shi を順に外すと効果は減弱、PRO-MEDIC(Wibrow)を外すと逆方向に動く
結論	メタ解析は批判的吟味の終点ではなく出発点。バイアスリスク層別解析は「主解析を追認する感度解析」ではなく、 同じエビデンスに対する対等な視点 である
ガイドラインへの含意	この種の不確実性は、有効性だけを根拠に強い推奨を出すことをほとんど正当化しない。条件付き推奨か「エビデンス不十分」が妥当

押さえるべき5点

- ① 統合推定値は文献から抽出されるものではなく、**前提の置き方によって構築される**。メタ解析は自動的な真実の供給源ではなく分析ツールである
- ② 「どちらのメタ解析が正しいか」ではなく「なぜ食い違ったのか」を問う。分解すると、適格基準の差はごく一部しか説明しなかった
- ③ バイアスリスクによる層別で効果が消えるなら、**その食い違い自体が重要な所見**であり、不確実性を上げる方向に働かせる
- ④ 影響力の大きい試験を特定する leave-one-out は、個々の研究を無効化する道具ではなく「最も精査すべき試験」を指す道具である

5 統合推定値が「臨床的にも方法論的にも妥当な複数の解析にわたって頑健か」を、確信度の判断材料に格上げすべき

📖 詳細

まず前提 — この病態・治療の基礎(初めての人にも)🧩

要旨

5分で背景を掴む せん妄は集中治療室(ICU)で頻発する急性の意識・注意の障害で、予後悪化や在室延長につながるため予防が重要な課題になっている。メラトニンは睡眠・概日リズムを整えるホルモンで、その補充薬(メラトニン、受容体作動薬のラメルテオンなど)がせん妄を防ぐか、多くのランダム化比較試験(RCT)で検討されてきた。メタ解析とは、複数の試験結果を数量的に統合して1つの効果推定値(統合推定値)を出す手法で、リスク比(RR、1未満なら介入群でイベントが少ない)やオッズ比(OR)で示す。個々の試験より精密とされ、一般に最高水準のエビデンスと見なされる。ただし統合推定値は文献から自動的に取り出せるものではなく、「どの試験を入れるか」「試験ごとの信頼性の差をどう扱うか」という前提の置き方で構築される。バイアスリスクとは各試験に系統誤差(偏り)が入りやすいかの評価で、ROB-2などのツールで高/懸念あり/低に分類する。質の低い試験ほど治療効果を過大に見せやすい。だから同じ問い・同じデータでも、質の低い試験を統合に入れるか、低リスク試験だけに絞るかで結論が逆転しうる。本論説は、その実例をせん妄予防のメラトニンを題材に解剖している。

1. 背景 — メタ解析はなぜ「自動的な真実」ではないのか 📐

メタ解析は複数の研究を統合してより精密な効果推定値を与えるため、一般に最高水準のエビデンスと見なされている。著者らはこの期待が正当化される条件を明示する。すなわち、**統合される研究が本質的に同じ臨床疑問を扱い、方法論的な厳密さが同程度である場合**である。

しかし実際には、研究者は2種類の判断を下さなければならない。

- **どの研究を統合すべきか**(臨床的な仮定)
- **研究ごとの信頼性の差をどう扱うか**(方法論的な仮定)

したがって統合推定値は文献から単純に抽出されるものではなく、**これらの仮定を通じて構築される**。著者の言い方では、メタ解析は「自動的な真実の供給源(automatic source of truth)」ではなく「強力な分析ツ

ール」である。そして状況によっては、量的統合は最も信頼できる個々の研究の寄与を **明らかにするどころか覆い隠す** ことがある。

この論説の眼目は、この抽象的な主張を、実際に食い違った2本のレビューを解剖して具体化した点にある。

2. 素材 — 同じ問いに逆の答えを出した2本のレビュー 🔍

対象となったのは、重症患者のせん妄予防におけるメラトニン作動薬に関する2本のシステマティックレビューである。

	Chaves-Filho ら	Lakbar ら(著者ら自身)
掲載	Critical Care 2026;30:334	Intensive Care Med 2025
対象薬	メラトニン+ラメルテオン	メラトニンのみ
主解析の方針	適格な全試験を統合 (ROB-2 で質は評価)	低バイアスリスクRCTに限定した解析を主解析とし、広い解析は副次に
結論	メラトニン作動薬はせん妄を減らす(特にメラトニン、外科系ICU、7日以上)	ルーチンの予防投与を推奨するにはエビデンス不十分

著者らは冒頭で立場を明確にする。問うべきは「どちらのメタ解析が正しいか」ではなく、**なぜ類似した臨床疑問を扱った2本の厳密なレビューが異なる結論に至ったのか** である。

3. 議論の相手方 — Chaves らのメタ解析は何を報告したか 🇮🇹

論説の主張を評価するには、批判対象のメタ解析の中身を知っておく必要がある。以下は Chaves-Filho らの原著 (Crit Care 2026;30:334) から直接転記した数値である。

■ 規模とデザイン

- 対象: ICU成人へのメラトニンまたはメラトニン作動薬 vs プラセボ／無治療のRCT。**確立したせん妄の治療目的の研究は除外**(予防のみ)
- 検索: Embase／CENTRAL／PubMed／Web of Science／ClinicalTrials.gov。言語制限なし。
2025年5月30日～8月1日にスクリーニング
- PROSPERO 登録: CRD420251131699
- 組み入れ: **24研究・3,680例**

- 手法：ペアワイズ統合+用量反応メタ解析+メタ回帰+Trial Sequential Analysis(TSA)+GRADE+サブグループの信頼性評価(ICEMAN)

■ 主解析(累積せん妄発生率)

18試験・3,331例。イベントはメラトニン作動薬群 429例、プラセボ群 517例。

解析	RR (95% CI)	p	I ²	備考
全体(主解析・18試験)	0.77 (0.62–0.94)	0.01	57%	Chi ² =36.87、確信度 low、NNT 12.5 (8.33–33.33)
メラトニンのみ	0.77 (0.62–0.97)	0.03	61%	
ラメルテオンのみ	0.74 (0.40–1.39)	0.35	53%	
薬剤間のサブグループ差	—	0.90	0%	薬剤の違いでは説明されない
感度解析(20試験・3,424例)	0.76 (0.62–0.92)	0.006	53%	無治療対照・併用介入試験も加えたもの

■ 効果修飾因子として報告されたもの

サブグループ	RR (95% CI)	p	I ²	群間差の p
外科系ICU	0.64 (0.48–0.87)	0.005	33%	—
内科系・混合ICU	0.74 (0.55–0.99)	0.04	49%	—
投与期間 7日以上	0.73 (0.60–0.90)	0.002	41%	0.66 (群間差は非有意)
65歳以上	0.73 (0.55–0.97)	0.03	58%	0.83 (群間差は非有意)

用量反応解析では非線形の関係が示され、**累積メラトニン量 22 mg が最適** と推定された (RR 0.732、95% CI 0.599–0.895)。メタ回帰では、単変量で分散を説明できた唯一の因子が **連続変数としての治療期間** (P=0.0233、I²=9.66%、R²analog=0.88) であった。バイアスリスクを共変量に入れたモデルは分散をほとんど説明しなかった (P=0.5940、R²analog=–0.11)。

死亡(28-30日・ICU)と有害事象の発生率に差はなく、ICU在室日数・入院日数・人工呼吸期間はいずれも有意差なしだが最小重要差(MCID)の観点からは臨床的に意味のある傾向とされた。

■ バイアスリスクの分布と、Chaves ら自身の層別解析

ROB-2 による評価は **高リスク 8試験(33.33%)／懸念あり 9試験(37.50%)／低リスク 7試験(29.16%)** であった。

Chaves らは自ら Figure 2C としてバイアスリスク層別のフォレストプロットを提示しており、**低リスク／懸念あり RR 0.84(0.69-1.02、p=0.07、I²=51%)** に対し、**高リスク RR 0.50(0.35-0.72、p=0.0002、I²=0%)**、サブグループ間差 Chi²=6.03、df=1、P=0.01、I²=83.4% と報告している。彼ら自身の言葉でも「高リスク試験が実質的に大きい効果推定値を示したことは、真の治療効果というより **バイアスによる過大評価と整合的である**」と書かれている。

TSAでは、24%のリスク減少を想定したとき z曲線が従来型境界と無益性境界の双方を横切り、**登録済み患者数／必要数=3,594／6,527** の時点で結果は頑健と判定された。

4. 食い違いの第1の源 — 臨床的異質性(誰を統合するか)🧩

食い違いの最初の候補は、適格基準を決める **臨床的異質性** である。

Chaves らはメラトニンとラメルテオンの試験を併合し、著者らのレビューはメラトニンに限定した。両者は同じ薬理学的ファミリーに属するが、**受容体親和性・薬物動態・せん妄の病態生理に関わりうる機序が異なる**(ラメルテオンの薬物動態については Spadoni らのレビューを引用)。したがって量的に併合することは「妥当ではあるが自明ではない(reasonable, but not self-evident)」方法論的選択である、というのが著者らの評価である。断罪していない点に注意したい。

しかし著者らは、この差だけでは食い違いを説明できないと明言する。Chaves らはメラトニン試験に限定したサブグループ解析も報告しており、直接比較が可能だからである。

	効果推定値	95% CI
Chaves らのメラトニン限定サブグループ	RR 0.77	0.62-0.97
著者らのレビュー	RR 0.86	0.71-1.04

著者らはこれを「驚くほど似ており、信頼区間も大きく重なる」と評価する。**したがって適格基準の違いは観察された食い違いの一部しか説明しない。**

POINT

ここが読み方の勘所 点推定値 0.77 と 0.86 の差より、片方の信頼区間が 1.0 をまたぎ、もう片方がわずかに 1.0 を割っているという **有意性の境界をまたぐか否か** の差が、結論の言葉づかい(「減らす」対「不十分」)を分けている。同じデータでも、結論文は二値的な閾値の側に引きずられる。

5. 食い違いの第2の源 — 方法論的異質性(信頼性の差をどう扱うか)

臨床的に適格な研究が特定された後、研究者は **研究の信頼性の差を解析にどう組み込むか** を決めなければならない。著者らは、等しく擁護可能な2つの戦略があると整理する。

戦略	内容	得るもの	失うもの
A. 全包含	臨床的に適格な全試験を含める。質の差は解釈の段階で考慮する	精度(信頼区間が狭くなる)	系統誤差の混入を許す
B. 低リスク優先	低バイアスリスク試験を優先する	系統誤差からの保護	精度(症例数が減る)

著者らの評価は明確である。**どちらの戦略も本質的に正しいわけではない**。両者は偽陽性への防御と偽陰性への防御のバランスの取り方が違うだけである。

ここから重要な帰結が導かれる。バイアスリスクで層別した解析は、**好ましい主解析を確認するために行う単なる感度解析と見なされるべきではない**。それは同じエビデンス体に対する、方法論的に正当化されたもう一つの視点であり、**両者が食い違ったならばそれ自体が説明を要する重要な所見** である。

実際の運用は以下の通りだった。

- 著者らのレビュー: 低バイアスリスクのRCTに限定した解析を主解析とし、広い解析を副次として提示
- Chaves ら: バイアスリスクにかかわらず適格な全試験を統合し、質は ROB-2 で評価

著者らは Chaves らの方法も擁護可能だと認めたうえで、**主解析に含まれたメラトニン試験の約40%が高バイアスリスクと判定されていた以上、著者ら自身の ROB-2 評価に基づく層別が重要な追加情報を与えたはずだ** と述べる。

6. 決め手 — 著者らによる post hoc 層別解析

論説の中心にある実データがこれである。著者らは、Chaves らが組み入れたメラトニン試験を、Chaves ら自身が公表した ROB-2 評価を用いて 層別し直した。

層	RR	95% CI
高バイアスリスク試験	0.46	0.29–0.73
低バイアスリスク試験	0.86	0.70–1.05
(参考)著者ら自身のレビュー	0.89	0.73–1.09

層間の交互作用は統計学的に有意(P for interaction = 0.01)。

すなわち、**見かけの治療効果はほぼ高バイアスリスク試験に限局していた**。低リスク試験に限れば推定値は保守的になり、著者ら自身のレビューの結果とほとんど一致する。著者らの結論は「方法論的異質性を明示的に探索した時点で、2本のレビューの見かけの不一致の多くは消えた」というものである。

図の解説

Figure 2C (Chaves-Filho et al. Crit Care 2026;30:334 より。© The Author(s) 2026, CC BY-NC-ND 4.0) **バイアスリスク層別のフォレストプロット**。論説の主張の土台にあたる図で、上段が「低リスク／懸念あり」、下段が「高リスク」。**上段(5.1.1 Low-Risk/Some concerns)** : Bourne 2021、Burry 2025 (MELLOW)、Dessap 2025 (DEMEL)、Gandolfi 2020、Hatta 2014、Jaiswal 2019、Kinouchi 2023、Nishikimi 2018 (MELIT)、Shi 2021、S Oh 2021 (RECOVER)、Vijayakumar 2016、Wibrow 2022 (PRO-MEDIC)、Yin 2022 の13試験。イベント 405/1,399 対 465/1,388。四角のマーカはおおむね縦線(RR=1)の両側に散らばり、最大の重みを持つ PRO-MEDIC (13.4%) は 1.07 (0.88–1.29) と縦線の右にある。統合の菱形は 0.84 (0.69–1.02) で、**右端が 1.0 をわずかに越えている**。Chi²=24.54、df=12、P=0.02、I²=51%、全体効果 Z=1.80、P=0.07 **下段(5.1.2 High-Risk)** : Abbasi 2018、Bellapart 2020、Foreman 2015、Gupta 2022、Javaherforooshzadeh 2021、Javaherforooshzadeh 2023、Mahrose 2021 の7試験。イベント 35/318 対 72/319。菱形は 0.50 (0.35–0.72) と明らかに左に寄り、**信頼区間は 1.0 に届かない**。Chi²=5.35、df=6、P=0.50、I²=0%、Z=3.76、P=0.0002 目で見て最も強い印象を残すのは、**下段の菱形が上段より1目盛り近く左にあることと、下段の異質性が I²=0% と極めて小さいこと**である。バイアスの効いた試験どうしは互いによく一致する、という皮肉な図でもある。最下段: 総合 0.75 (0.62–0.92)、サブグループ間差 Chi²=6.03、df=1、P=0.01、I²=83.4%。※この図はメラトニンとラメルテオンの試験を併せたもの。論説の post hoc 解析は **メラトニン試験に限定**しているため、数値(高リスク 0.46 / 低リスク 0.86)はこの図の 0.50 / 0.84 とは一致しない。

図の解説

Figure 2A (Chaves-Filho et al. より。同ライセンス) **主解析のフォレストプロット**。上段 3.1.1 がメラトニン(13試験)、下段 3.1.2 がラメルテオン(5試験)。メラトニン小計は 0.77 (0.62–0.97)、 $\text{Tau}^2=0.07$ 、 $\text{Chi}^2=27.95$ 、 $\text{df}=11$ 、 $P=0.003$ 、 $I^2=61\%$ 、 $Z=2.23$ 、 $P=0.03$ 。ラメルテオン小計は 0.74 (0.40–1.39)、 $I^2=53\%$ 。総計 0.77 (0.62–0.94)、 $I^2=57\%$ 、薬剤間の差の検定 $\text{Chi}^2=0.02$ 、 $\text{df}=1$ 、 $P=0.90$ 、 $I^2=0\%$ 。個々の試験を見ると、**極端に左に振れているのは Javaherforooshzadeh 2021 (0.21, 0.07–0.67) や Mahrose 2021 (0.40, 0.17–0.95) といった小規模試験で、いずれも Figure 2C では高リスク層に入る。逆に最大の重み(13.9%)を持つ PRO-MEDIC は 1.07 (0.88–1.29) で無効を示す。この「小さく極端／大きく無効」の配置が、後段の批判的吟味の焦点になる。**

図の解説

Figure 2D (Chaves-Filho et al. より。同ライセンス) **Trial Sequential Analysis**。横軸が累積患者数(線形)、縦軸が累積Zスコア。赤い線が試験逐次モニタリング境界で、右端に「Required Information Size = 6527」と注記される。青い折れ線(Z曲線)は序盤に大きく上振れした後、**Z=2 の従来型有意水準の線をやや上回った位置で横ばいに推移し、n=3,594 の地点まで進む。Chaves らはこれをもって「結果は頑健」と述べているが、図を見る限り Z曲線は境界すれすれを這っており、必要情報量の約55%しか集まっていないことは押さえておきたい。**

7. より広い原理 — 一致は確信を高め、不一致は所見である 🧠

著者らは症例(メラトニン)から一般原理へ議論を上げる。

- 臨床的に整合した複数の解析が、異なる方法論的前提のもとで似た結果を出すとき → エビデンスへの確信は高まる
- 結論が「高バイアスリスク試験を含めるかどうか」に依存するとき → その食い違い自体が重要な所見になる

したがって、好ましい統合推定値を選ぶのではなく、**まず食い違いの起源を理解しようとすべき** である。

実務的な方法の一つとして著者らが挙げるのが、**統合推定値に最も大きな影響を与えている研究の同定** である。両データセットで実施した leave-one-out 解析は驚くほど一致した結果を出した。

除外した試験	統合推定値の動き
Yin と Shi を順次除外	見かけの治療効果が実質的に減弱
PRO-MEDIC (Wibrow ら) を除外	統合推定値は逆方向に動く

著者らはここでも慎重である。これらの観察はいずれの個別研究をも無効化しない。そうではなく、最も綿密な臨床的・方法論的精査に値する試験を特定するものである。丁寧に比較すれば、統合推定値だけを見ていては見えない、患者選択・介入プロトコル・アウトカム評価・方法論的实施の差が明らかになるかもしれない、と述べる。

8. ガイドラインへの含意 — 不確実性は推奨の強さに反映されるべき

論説の最終段は、エビデンス評価とガイドライン作成に向けた提言である。

- メタ解析は批判的吟味の **終点ではなく、より深い調査の出発点** と見なすべきである。方法論的に擁護可能な複数の解析が矛盾する結論を出すときには特にそうである
- バイアスリスクによる層別解析は、**主解析が受け入れられた後に参照される感度解析ではなく、エビデンス解釈の不可分の一部** とすべきである
- これらの解析が異なる結論に至るとき、**その食い違いは不確実性を増やす方向に働かせるべき**であり、「一方は副次解析だから」という理由で退けてはならない
- **臨床的にも方法論的にも擁護可能な複数の解析にわたる結論の頑健性** を、統合推定値への確信度の判断でより重視すべきである
- ガイドラインの観点からは、この種の不確実性が **有効性のみを根拠に強い推奨を正当化することはまずない**。最終的な推奨は、利益と害のバランス、資源使用、実施可能性、患者の価値観と選好を反映して、条件付き推奨が適切か、それともエビデンス不十分と扱うべきかを決めるべきである

9. Limitation

論説自身は限界の節を持たないが、読者として確認しておくべき制約がある。

- **これは論説であり、システマティックレビューではない**。文献検索も PRISMA も PROSPERO 登録もない。提示されている post hoc 解析はプロトコルに事前規定されたものではない
- **post hoc 層別解析は他者のバイアスリスク判定に依存している**。Chaves らの ROB-2 評価をそのまま使っており、その判定が変われば層別の結果も変わる

- **著者らは議論の当事者である。**比較される2本のうち1本は著者ら自身のレビューであり、post hoc 解析は自らの結論を支持する方向に出ている
- **利益相反：**責任著者は Viatris および AOP Health から講演料を受領している(本論説の主題との直接の関係は述べられていない)
- **データ利用可能性の記載：**「本研究では新たなデータセットは生成も解析もされていない」と記載されている一方、本文では post hoc 層別解析と leave-one-out 解析の結果を報告している。**記載と本文が整合していない**

🧐 批判的吟味 — ジャーナルクラブでの論点

⚠ 注意

⚠ 論説の主張のうち、原著と突き合わせると修正が要る箇所がある 著者らは「著者ら自身の ROB-2 評価に基づく層別が **重要な追加情報を与えたはずだ**」と書いているが、==Chaves らは Figure 2C として実際にバイアスリスク層別のフォレストプロットを報告しており、サブグループ間差 $P=0.01$ まで明示している。**さらに Chaves らは本文で「高リスク試験の大きな効果はバイアスによる過大評価と整合的」とまで述べている。論説の書きぶりは、批判対象がすでに行っていた解析を やっていないかのよう**に読ませる。**この論説の真の追加点は「層別をしたこと」ではなく、ラメルテオンを除いてメラトニン試験だけに層別を絞り直した ($0.50/0.84 \rightarrow 0.46/0.86$)**==ことにある。JCではここを最初に整理したい。

1. 批判される側の内的矛盾(Chaves 論文の側の弱点)

Chaves らは Figure 2C で高リスク 0.50 対 低リスク 0.84、交互作用 $P=0.01$ を示しながら、Discussion では「患者の年齢・性別・重症度は効果を修飾せず、**高バイアスリスク研究を除外した後も結果は同様であった**」と記している。同一論文内で、図と考察の記述が整合していない。この不整合こそが、論説が突く隙になっている。

2. バイアスリスクと試験規模の交絡

高リスク層は 7試験・318 対 319例、イベント 35 対 72 に過ぎない。一方の低リスク層は 13試験・1,399 対 1,388例。「**高バイアスリスク**」と「**小規模**」はほぼ同義になっているため、観察された差はバイアスの効果か、小規模研究効果 (small-study effects) か、あるいは publication bias か区別できない。Chaves らは Funnel plot で出版バイアスは(せん妄持続時間を除き)明らかでないとしているが、層別解析はこの区別に答える設計にはなっていない。

3. メタ回帰との不一致をどう読むか

Chaves らのメタ回帰では、バイアスリスクを共変量として投入したモデルは分散をほとんど説明しなかった ($P=0.5940$, $R^2_{\text{analog}}=-0.11$)。一方でサブグループ解析では交互作用 $P=0.01$ 。**同じデータで、層別解析とメタ回帰が逆の示唆を与えている。**サブグループ解析の検出力とメタ回帰の検出力は別物であり、どちらを主に置くかで結論は動く。論説はこの点に触れていない。

4. 交互作用検定の信頼性

サブグループ間差の検定は観察的な比較であり、ランダム化の恩恵を受けない。Chaves らは ICEMAN ツールでサブグループの信頼性を評価しているが、**バイアスリスク層別の ICEMAN 評価は本文ではなく補遺 (Table S5)にある。**JCで扱うなら補遺を開いて確認したい。

5. leave-one-out の解釈

「PRO-MEDIC を外すと逆方向に動く」というのは、**最大の重みを持つ中立的試験 (RR 1.07、重み 13.4%) を外せば統合値が有利側に動く**という、ほぼ機械的な帰結である。同様に「Yin と Shi を外すと減弱する」も、両者が有利側で重みの大きい試験である以上、驚くべき所見ではない。leave-one-out は影響力の地図であって、バイアスの証拠ではない。論説自身も「いずれの個別研究をも無効化しない」と正しく留保している。

6. TSA の「頑健」という言葉

Chaves らは z曲線が従来型境界と無益性境界を横切ったことをもって頑健と述べるが、必要情報量 6,527 に対して蓄積は 3,594 例 (約55%) である。必要情報量は想定リスク減少率 (24%) に依存し、想定を小さくすれば必要数は跳ね上がる。**「境界を越えた」は「決着した」ではない。**

7. 論説の側の透明性

post hoc 解析の結果 (RR、95% CI、交互作用 P値) は本文中の記述のみで、フォレストプロットも解析コードも補遺も提示されていない。データ利用可能性欄は「新たなデータセットは生成も解析もされていない」となっている。**再現できない形で提示された再解析**を、どこまで論拠にできるかは JC で議論する価値がある。

8. 臨床的な落とし穴

△ 注意

⚠ 「メタ解析で有意」だけでプロトコルを変えない 本件は、**統合推定値 RR 0.77 (0.62–0.94)・NNT 12.5** という一見説得的な数字が、**バイアスリスク層別で RR 0.86 (0.70–1.05) まで後退する** 実例である。せん妄予防のように **安価で害が少なく見える介入ほど、弱いエビデンスでも採用されやすい**。安全そうに見えることは、有効性の代わりにはならない。

9. JCで投げかける問い

- 自分たちが主解析を設計するなら、戦略A(全包含)と戦略B(低リスク優先)のどちらを主に置くか。その理由を偽陽性／偽陰性のどちらを恐れるかの言葉で説明できるか
- 「低リスク試験に限ると有意でなくなる」介入を、ガイドラインは条件付き推奨にすべきか、エビデンス不十分とすべきか
- 用量反応解析で得られた「最適累積量 22 mg」は、高リスク試験を除いても残るのか。論説はここに触れていない

主要な引用文献

#	内容	出典
1	批判対象となったメタ解析。メラトニン作動薬24研究・3,680例。主解析 RR 0.77 (0.62–0.94)	Chaves-Filho A, Medrado MF, Zamboni T, Cavalcanti AB, Shim SR, Quinn TJ, Veiga VC, Mavridis T. Effectiveness and safety of melatonergic agonists in preventing delirium in the ICU: an updated dose–response meta-analysis of randomized controlled trials. Critical Care. 2026;30:334
2	著者ら自身のレビュー。メラトニンのみ。ルーチン予防投与を推奨するにはエビデンス不十分と結論	Lakbar I, Poole D, Delamarre L, Chanques G, Pensier J, Monet C, Belafia F, Capdevila M, De Jong A, Jaber S. Melatonin and delirium in the intensive care units: a systematic review and meta-analysis of randomized controlled trials. Intensive Care Med. 2025. DOI: 10.1007/s00134-025-08143-1
3	ラメルテオンの薬物動態・薬力学。メラトニンと併合してよいかの根拠	Spadoni G, Bedini A, Lucarini S, Mor M, Rivara S. Pharmacokinetic and pharmacodynamic evaluation of ramelteon: an insomnia therapy. Expert Opin Drug Metab Toxicol. 2015;11(7):1145–56
4	leave-one-out で統合推定値を逆方向に動かした最大規模の中立的RCT	Wibrow B, Martinez FE, Myers E, et al. Prophylactic melatonin for delirium in intensive care (Pro-MEDIC): a randomized controlled trial. Intensive Care Med. 2022;48(4):414–25

本ページは原論文の要約・解説です。数値は原論文から転記していますが、引用の際は必ず原論文（上記DOI）をご確認ください。原著の図表は著作権のため本ページには掲載していません（本文の「図の解説」を参照）。作成：Claude Code（聖路加ICUジャーナルクラブ運用）。